

UNIVERSITÉ DE SHERBROOKE
Faculté de génie
Département de génie électrique et de génie informatique

Représentations textuelles structurées issues d'une chaîne multimodale pour la détection de moments saillants dans de longues vidéos

Mémoire de maîtrise
Spécialité : génie électrique

Alexandre LAFLEUR

Sherbrooke (Québec) Canada

Mars 2026

MEMBRES DU JURY

François GRONDIN

Directeur

François MICHAUD

Évaluateur

François FERLAND

Évaluateur

RÉSUMÉ

Ce manuscrit étudie une approche texte d’abord pour la détection de moments saillants dans de longues vidéos. Au lieu de confier la décision finale à une inférence multimodale directe sur la vidéo, nous transformons le contenu en un état textuel structuré et persistant, stocké en base de données, puis nous comparons plusieurs vues textuelles sur le jeu d’évaluation `validation29`. Les résultats montrent que des représentations textuelles surpassent l’entrée vidéo directe dans la comparaison contrôlée sous **Gemini 3.1 Flash Lite**, tout en coûtant moins cher à l’inférence finale. Ils montrent aussi que la textualisation visuelle actuelle n’aide pas automatiquement et que le choix entre enrichissement de contexte et ajustement fin dépend de la taille du modèle. La contribution centrale est donc double : une comparaison reproductible entre représentations texte et vidéo directe, et une représentation vidéo transformée en texte qui reste lisible, réutilisable et exploitable dans le temps.

Mots-clés : analyse vidéo, grands modèles de langage, représentation textuelle, détection de moments saillants, benchmark

TABLE DES MATIÈRES

1	Introduction	1
2	Travaux connexes	1
3	Jeu d'évaluation et construction des données	2
4	Chaîne de prétraitement multimodal	3
5	Représentation textuelle structurée	3
6	Configuration du sélectionneur et métriques d'évaluation	4
7	Résultats quantitatifs	5
8	Analyse des échecs et discussion	8
9	Conclusion	8

LISTE DES RÉFÉRENCES	13
-----------------------------	-----------

LISTE DES FIGURES

1	Vue d'ensemble du pipeline proposé, depuis le segment source jusqu'au span final sélectionné.	2
2	Exemple concret de transformation d'une vidéo en contexte structuré, puis en span sélectionné par le modèle.	5
3	Comparaison de deux cas de succès et de deux cas d'échec du meilleur run structuré complet. Les succès combinent recouvrement thématique et calibration temporelle ; les échecs gardent parfois un signal sémantique partiel mais ratent la bonne fenêtre temporelle.	9

LISTE DES TABLEAUX

2	Statistiques descriptives du benchmark validation29	3
3	Composantes principales du pipeline et sorties persistées	4
4	Variantes de contexte disponibles sur l'ensemble complet	4
5	Synthèse des pilotes exploratoires utilisés pour faire évoluer la représentation	6
6	Jalons où un changement de représentation ou de prompt améliore le meilleur score exploratoire connu	7
7	Conditions complètes sur 29 échantillons retenues pour les revendications principales	7
8	Comparaison contrôlée sous Gemini 3.1 Flash Lite : même modèle, même protocole de sortie, et variation explicite de la représentation d'entrée . . .	8
9	Impact du fine-tuning sur les petites variantes Gemini 2.5, avec les mêmes 29 cas de validation lorsqu'ils sont disponibles	8
10	Premiers essais d'augmentation visuelle par objets dans le contexte textuel	10
11	Comparaison des variantes Gemini 2.5 Pro : base, fine-tuning et entrée vidéo directe	10
12	Taxonomie initiale des échecs à valider dans l'analyse qualitative	11

LISTE DES ACRONYMES

LLM	Grand modèle de langage
IA	Intelligence artificielle
VTG	Ancrage temporel dans la vidéo (<i>Video Temporal Grounding</i>)
TAN	Réseaux temporels adjacents (<i>Temporal Adjacent Networks</i>)
LLoVi	Questions-réponses vidéo (<i>Language-based Long-range Video question answering</i>)
ExCL	Localisation extractive de segments vidéo (<i>Extractive Clip Localization</i>)
QD-DETR	Transformeur de détection adaptatif (<i>Query-Dependent DETection TRansformer</i>)
VLM	Modèle vision-langage
TOON	Token-Oriented Object Notation
IoU	Intersection over Union
ASD	Active Speaker Detection
API	Interface de programmation applicative
GT	Ground truth / référence annotée

1 Introduction

Les synthèses de Tang et al. [15], de Zhou et al. [21] et de Wadekar et al. [16], ainsi que l’architecture Video-LLaMA [20], montrent qu’analyser une vidéo longue directement avec un modèle multimodal est aujourd’hui possible, mais coûteux. Si l’on veut traiter beaucoup de vidéos, ou si l’on veut le faire avec une machine limitée, ce coût devient rapidement un vrai problème. C’est encore plus vrai quand la tâche finale est simple à formuler : choisir un seul bon moment dans une vidéo de plusieurs minutes.

Une première solution consiste à ne garder que la transcription. C’est beaucoup moins cher, mais cela enlève une partie de l’information utile. Un moment fort ne dépend pas seulement de ce qui est dit. Il peut dépendre d’un changement de scène, d’un cadrage, d’une personne qui apparaît, d’une réaction visuelle, ou d’un contraste entre le verbal et le visuel. À l’inverse, garder la vidéo jusqu’au bout laisse ce signal disponible, mais oblige à payer une inférence plus lourde à chaque exécution.

L’idée de cet article est de prendre une voie intermédiaire. Au lieu de demander au modèle final de raisonner directement sur la vidéo, nous transformons la vidéo en un état textuel structuré. Cet état garde l’ordre temporel, les scènes, la parole et certains indices visuels. Ensuite, différentes vues textuelles peuvent être dérivées de cet état et envoyées à un sélectionneur textuel. La vue la plus complète est `timeline-scenes-dialogue-typed-v1`. D’autres vues plus simples, comme `transcript-v1` et `typed-novlm-v1`, permettent de voir ce que chaque niveau de représentation apporte vraiment.

La contribution de l’article est donc triple. Nous présentons d’abord un jeu d’évaluation reproductible de 29 paires segment source / clip de référence. Nous décrivons ensuite une chaîne de traitement qui transforme la vidéo en données textuelles persistantes. Enfin, nous comparons plusieurs façons d’utiliser ces données, et nous montrons que des conditions texte d’abord dépassent l’entrée vidéo directe sur le jeu d’évaluation retenu. Le point important n’est pas seulement qu’une représentation texte fonctionne. C’est qu’elle peut fonctionner tout en étant beaucoup plus facile à réutiliser dans le temps.

2 Travaux connexes

Le travail s’inscrit d’abord dans la littérature sur la localisation temporelle et la détection de moments saillants. Localizing Moments in Video with Natural Language [6], ExCL [3], QVHighlights [8] et Towards a Complete Benchmark on Video Moment Localization [1] montrent qu’il faut non seulement trouver le bon passage, mais aussi bien le déliminer dans le temps. Cette distinction est importante pour nous, parce qu’un bon extrait doit être proche du clip de référence à la fois dans son contenu et dans ses bornes temporelles.




FIGURE 1 Vue d’ensemble du pipeline proposé, depuis le segment source jusqu’au span final sélectionné.

Le travail s’inscrit aussi dans la littérature sur les grands modèles vision-langage appliqués aux vidéos longues. Video-LLaMA [20], VTimeLLM [7], VTG-LLM [4], LongVLM [17], VideoLLM [2], Retrieval-based Video Language Model for Efficient Long Video Question Answering [18] et LLMs Meet Long Video [11] montrent bien qu’il est possible de raisonner sur des vidéos complexes avec des modèles très puissants. Le problème, pour notre question, n’est pas qu’elles ne fonctionnent pas. Le problème est plutôt leur coût et leur lourdeur lorsqu’on veut les utiliser souvent ou dans un système contraint. Lost in the Middle [12] renforce ce point en montrant que, même lorsque l’information tient dans un long contexte, elle n’est pas exploitée de manière uniforme par le modèle. Cela rend particulièrement importante la forme sous laquelle on présente l’information.

Enfin, CLIPBERT [9], UMT [13] et Slot-VLM [19] montrent qu’il est possible de compresser le signal vidéo avant la décision finale. Notre travail se situe dans cette direction, mais avec une différence importante : la représentation finale n’est pas cachée dans le modèle. Elle est lisible, stockée en base et réutilisable. C’est cette propriété qui manque souvent dans les approches plus directes, et c’est elle que nous voulons mettre de l’avant ici.

3 Jeu d’évaluation et construction des données

Le jeu d’évaluation principal est **validation29**. Il contient 29 paires composées d’un segment source relativement long et d’un clip de référence plus court provenant du même contenu. Les segments source durent en moyenne 320.5 s, alors que les clips de référence durent 53.5 s en

TABLEAU 2 Statistiques descriptives du benchmark `validation29`

Paires	Durée source moyenne (s)	Durée source min-max (s)	Durée GT moyenne (s)	Durée GT min-max (s)	Couverture VLM
29	320.5	120.1-605.0	53.5	17.3-75.0	29/29

moyenne. Le but est simple : retrouver, dans le segment source, le passage le plus proche possible du clip de référence.

Ce choix a deux avantages. D’abord, il donne une tâche concrète, proche d’un besoin réel de découpage. Ensuite, il permet de comparer plusieurs représentations sur exactement les mêmes cas. Tout est stocké dans SQLite : les vidéos, les échantillons, les contextes, les profils de modèles, les consignes, les exécutions, les coûts et les scores par cas. Cette structure est importante, parce qu’elle permet de refaire les tableaux, de revoir les itérations et de distinguer les essais rapides des comparaisons vraiment défendables.

4 Chaîne de prétraitement multimodal

La chaîne de traitement suit une logique simple. On commence par transcrire l’audio avec Whisper [14]. Ensuite, on découpe la vidéo en scènes et on ajoute plusieurs analyses visuelles : personnes visibles, visages, locuteur actif, cadrage et descriptions visuelles. Chaque étape produit des données intermédiaires qui sont conservées en base.

Le point important n’est pas seulement qu’il y a plusieurs modules. C’est que leurs sorties sont normalisées dans une même structure. Cela permet de reconstruire plusieurs vues textuelles sans devoir tout recalculer. En pratique, la chaîne sert donc à fabriquer un état vidéo textuel que l’on peut ensuite relire et transformer selon la tâche.

5 Représentation textuelle structurée

La vue la plus riche de cet état est `timeline-scenes-dialogue-typed-v1`. Elle garde la chronologie, les scènes, les blocs de dialogue et certains indices visuels. Ce n’est pas un résumé libre. C’est une structure de travail. Le modèle final peut y voir où une scène commence, qui parle, qui est visible et quels indices visuels ressortent à ce moment-là.

Il faut bien distinguer deux choses. D’un côté, cette vue est celle qui représente le mieux l’état complet de la vidéo. De l’autre, ce n’est pas elle qui donne le meilleur score dans toutes les comparaisons. C’est précisément pour cela que nous la comparons à d’autres vues. `typed-novlm-v1` garde la structure, mais enlève les descriptions visuelles textuelles. `transcript-v1` garde seulement la parole. Cette famille de vues permet de voir plus clairement ce qui aide vraiment.

TABLEAU 3 Composantes principales du pipeline et sorties persistées

Etape	Rôle	Sorties utiles pour la représentation
Whisper / diarization	Transcription et alignement de la parole	mots horodatés, segmentation des locuteurs
Scene detection	Découpage temporel	bornes de scènes
YOLO / faces / ASD	Visages, activité des locuteurs, association personnes	personnes visibles, locuteurs probables, activité
Scene classification	Typage A-roll / B-roll	type de scène et personnes visibles
Camera focus	Indice de cadrage et continuité	segments de focus caméra
VLM summaries	Description visuelle textuelle	descriptions d’images, résumés de scènes
TOON script	Représentation textuelle compacte	dialogue et structure scénique utilisables par le sélectionneur

TABLEAU 4 Variantes de contexte disponibles sur l’ensemble complet

Contexte	Couverture	Taille moyenne (car.)	Min	Max
typed-timestamps-v1	29	30923	9826	81154
typed-numbered-v1	29	30916	9797	81361
typed-v1	29	30662	9800	80132
typed-novlm-v1	29	10112	3077	35306
detailed-script-v1	29	9220	2279	44159
no-vlm-v1	29	9204	2706	30983
detailed-vlm-script-v1	29	8595	2372	23420
transcript-v1	29	5072	1841	11197

6 Configuration du sélectionneur et métriques d’évaluation

Les comparaisons sont organisées en trois niveaux. Le premier niveau est exploratoire : il sert à tester rapidement des variantes de contexte et de consigne sur peu de cas. Le deuxième niveau regroupe les exécutions complètes, qui servent aux conclusions principales. Le troisième niveau est une ablation contrôlée sous `google/gemini-3.1-flash-lite-preview`, où seule la représentation change.

Dans cette ablation, quatre conditions sont comparées : la transcription brute `transcript-v1`, la variante structurée sans descriptions visuelles `typed-novlm-v1`, la variante structurée avec descriptions visuelles `typed-v1`, et l’entrée vidéo directe. Le modèle sélectionneur, la logique de




FIGURE 2 Exemple concret de transformation d’une vidéo en contexte structuré, puis en span sélectionné par le modèle.

sortie et le jeu d’évaluation restent les mêmes. C’est ce qui permet d’isoler proprement l’effet de la représentation.

L’évaluation repose sur deux mesures principales : le *text IoU*, qui mesure le recouvrement textuel avec la référence, et le *temporal IoU*, qui mesure le recouvrement temporel. Le score combiné est la moyenne des deux. Nous rapportons aussi les coûts, à la fois pour le sélectionneur seul et pour une première exécution incluant la création des données lorsque cette étape existe.

7 Résultats quantitatifs

Les résultats se lisent en trois temps. Le premier est exploratoire. Il montre comment la représentation a évolué. Les premières variantes très simples donnent des scores faibles. En structurant davantage la chronologie, les scènes et le dialogue, les scores montent progressivement jusqu’à 0.528 sur cinq cas. Ce n’est pas une conclusion finale, mais c’est important pour comprendre pourquoi certaines représentations ont été retenues et d’autres abandonnées.

TABLEAU 5 Synthèse des pilotes exploratoires utilisés pour faire évoluer la représentation

Contexte	Prompt pilote	Modèle pilote	n pilote	Score combiné	n max
transcript-v1	transcript-selector-v1-tool-v1	gemini-3.1-flash-lite	1	0.301	1
scene-grouped-dialogue-script-v1	selector-v2	claude-sonnet-4.6	5	0.470	5
scene-grouped-v1	selector-v2	gpt-5.3-codex	5	0.150	5
timeline-scenes-inline-v1	selector-v2	claude-sonnet-4.6	5	0.324	5
scenes-dialogue-inline-v1	selector-v2	claude-sonnet-4.6	5	0.434	5
timeline-dialogue-inline-v1	selector-v2	claude-sonnet-4.6	5	0.471	5
scene-details-dialogue-inline-v1	selector-v2	gemini-3.1-flash-lite	5	0.333	5
typed-v1	selector-v2	gemini-3.1-flash-lite	5	0.528	28
typed-numbered-v1	selector-sentences-v1	gemini-3.1-flash-lite	5	0.308	5
typed-timestamps-v1	selector-timestamps-v1	claude-sonnet-4.6 (r :med)	5	0.422	15
no-vlm-v1	scenes-selector-tool-v1	gemini-3.1-flash-lite	24	0.343	24
typed-novlm-v1	selector-v2-tool-v1	gemini-3.1-flash-lite	28	0.319	28

Le deuxième temps est celui des exécutions complètes. Sur **validation29**, le meilleur score complet observé est obtenu par la transcription brute sous **Gemini 3.1 Flash Lite**, avec 0.323. La meilleure exécution complète de **typed-v1** atteint 0.301 sous **Grok 4.1 Fast**. L'entrée vidéo directe sous **Gemini 3.1 Flash Lite** atteint 0.273. Ce que ces chiffres montrent, c'est d'abord qu'une approche texte d'abord est tout à fait viable. Ils montrent aussi que la vue la plus riche de l'état vidéo n'est pas forcément celle qui maximise le score brut du sélectionneur.

Le troisième temps est l'ablation contrôlée sous Gemini. C'est elle qui permet de comprendre ce qui se passe vraiment. La transcription brute atteint 0.323. La variante structurée sans descriptions visuelles atteint 0.315. L'entrée vidéo directe reste à 0.273. Et la variante **typed-v1** avec descriptions visuelles textuelles descend à 0.240 lorsque l'échec d'alignement restant est compté à zéro. La lecture la plus simple est donc la suivante : la structure temporelle et dialoguée reste utile, mais les descriptions visuelles textuelles actuelles n'aident pas le sélectionneur. Elles alourdissent plutôt le contexte sans gain net. *Lost in the Middle* [12] va dans le même sens : ajouter de l'information ne suffit pas, encore faut-il que le modèle sache la retrouver et l'utiliser au bon moment.

Le coût confirme cette lecture. Si l'on regarde seulement le sélectionneur final, les approches textuelles coûtent beaucoup moins cher que l'entrée vidéo directe. Si l'on ajoute le coût de création

TABLEAU 6 Jalons où un changement de représentation ou de prompt améliore le meilleur score exploratoire connu

Date	Contexte	Prompt	Modèle	n	Score
2026-03-01	transcript-v1	basic-selector	llama-3.3-70b-versatile	1	0.031
2026-03-03	scene-grouped-dialogue-script-v1	selector-v2	gpt-5.3-codex	5	0.152
2026-03-04	scene-grouped-dialogue-script-v1	selector-v2	claude-sonnet-4.6	5	0.470
2026-03-04	timeline-dialogue-inline-v1	selector-v2	claude-sonnet-4.6	5	0.471
2026-03-04	typed-v1	selector-v2	gemini-3.1-flash-lite	5	0.528

TABLEAU 7 Conditions complètes sur 29 échantillons retenues pour les revendications principales

Condition	Modèle	Contexte	Txt IoU	Temp IoU	Score	Tokens	Run/video	Contexte/video	1er pa
Structured text	gemini-3.1-flash-lite	transcript-v1	0.388	0.257	0.323	2047	0.001	0.004	
Structured text	grok-4.1-fast	typed-v1	0.372	0.230	0.301	11885	0.003	0.005	
Direct video	gemini-3.1-flash-lite	video-direct-v1	0.338	0.208	0.273	29191	0.008	0.000	

des données, la transcription brute reste la condition la plus économique sur une première exécution, alors que les vues structurées rejoignent l’ordre de grandeur de l’entrée vidéo directe. Cela ne retire pas leur intérêt. Cela veut dire que leur valeur devient surtout claire lorsqu’on réutilise le même état vidéo plusieurs fois.

Une base historique complémentaire, `test_llms.db`, permet d’ajouter un autre angle d’analyse. Elle montre l’effet de l’ajustement fin sur plusieurs variantes Gemini, et elle est pertinente parce qu’elle a représenté un coût amont d’environ 1000 USD en crédits Google. Le cas le plus frappant est **Gemini 2.5 Flash**, qui passe d’environ 0.300 à 0.437 après ajustement fin texte. En revanche, **Flash-Lite** passe de 0.361 à 0.316. La conclusion proposée est qu’il existe une limite de capacité : **Flash-Lite** semble trop petit pour vraiment apprendre la tâche, alors que **Flash** semble être au bon niveau de taille pour en bénéficier. SHED [5] va dans le même sens en montrant qu’un ajustement fin bien ciblé peut tirer beaucoup de valeur d’un ensemble de données choisi avec soin plutôt que d’un volume maximal.

Cette base permet aussi de voir l’effet d’un premier enrichissement par objets. Une variante différentielle reste presque neutre, alors qu’une variante plus lourde dégrade le score. Enfin, sur **Gemini 2.5 Pro**, le modèle de base atteint 0.392, la version ajustée sur le texte seul tombe à 0.363, et la version ajustée avec texte et objets remonte à 0.405. La lecture la plus convaincante est donc la suivante : les grands modèles profitent davantage d’un meilleur contexte que d’un ajustement fin trop étroit, alors que certains modèles plus petits peuvent bénéficier d’un meilleur alignement. Revisiting Catastrophic Forgetting in Large Language Model Tuning [10] est cohérent

TABLEAU 8 Comparaison contrôlée sous Gemini 3.1 Flash Lite : même modèle, même protocole de sortie, et variation explicite de la représentation d’entrée

Condition	Couverture	Txt IoU	Temp IoU	Score	Tokens	Run/video	Contexte/video	1er pas
Structured text + VLM	29 cas (1 échec d’alignement compté à 0)	0.310	0.170	0.240	10053	0.003	0.005	
Structured text sans VLM	29 cas (28 run principal + 1 retry ciblé)	0.382	0.248	0.315	4433	0.001	0.005	
Transcript brut	29 cas (run complet)	0.388	0.257	0.323	2047	0.001	0.004	
Entrée vidéo directe	29 cas (run complet)	0.338	0.208	0.273	29191	0.008	0.000	

TABLEAU 9 Impact du fine-tuning sur les petites variantes Gemini 2.5, avec les mêmes 29 cas de validation lorsqu’ils sont disponibles

Variante	n	IoU moy.	Δ vs base	Temps (s)	Coût / 100 vid.
Flash de base	29	0.300	0.000	2.0	0.127
Flash fine-tune texte	27	0.437	0.137	21.6	0.110
Flash-Lite de base	29	0.361	0.000	2.0	0.032
Flash-Lite fine-tune texte	29	0.316	-0.045	1.2	0.027

avec cette baisse après ajustement fin texte seul, puisqu’il montre qu’une spécialisation trop serrée peut dégrader des capacités déjà acquises lors de l’ajustement d’un grand modèle.

8 Analyse des échecs et discussion

Les meilleurs cas montrent que les représentations textuelles peuvent vraiment porter un bon raisonnement. Quand la structure du contexte est bonne, le modèle retrouve non seulement le bon sujet, mais aussi le bon moment.

Les échecs, eux, suivent des motifs assez clairs. Il y a d’abord les cas où le bon passage est trouvé de manière approximative, mais mal délimité dans le temps. Il y a ensuite les cas où le modèle choisit un passage voisin, plausible, mais moins bon que le bon moment. Enfin, il y a les cas où la représentation est trop chargée et où les descriptions visuelles deviennent plus distractives qu’utiles.

Le point important est que ces échecs ne disent pas seulement « il manque de l’information ». Ils montrent surtout que la forme de l’information compte. C’est exactement ce que la campagne sur l’ajustement fin vient renforcer. Le vrai problème n’est pas simplement d’avoir plus de contexte ou moins de contexte. Le vrai problème est de donner à chaque modèle le type d’aide qu’il sait exploiter. Lost in the Middle [12] va dans ce sens. Revisiting Catastrophic Forgetting in Large Language Model Tuning [10] y conduit aussi : un modèle peut avoir accès à plus d’information ou être plus spécialisé, sans pour autant mieux s’en servir.

9 Conclusion

Cet article montre qu’une approche texte d’abord peut servir de support principal à la sélection de moments saillants dans des vidéos longues. Sur `validation29`, plusieurs conditions textuelles



FIGURE 3 Comparaison de deux cas de succès et de deux cas d'échec du meilleur run structuré complet. Les succès combinent recouvrement thématique et calibration temporelle ; les échecs gardent parfois un signal sémantique partiel mais ratent la bonne fenêtre temporelle.

TABLEAU 10 Premiers essais d’augmentation visuelle par objets dans le contexte textuel

Variante	n	IoU moy.	Δ vs texte	Car. entrée	Temps (s)
Texte seul	29	0.369	0.000	5088	15.2
Texte + objets différentiels 7 s	29	0.369	0.001	7009	15.7
Texte + objets complets 7 s	29	0.343	-0.026	7398	14.8

TABLEAU 11 Comparaison des variantes Gemini 2.5 Pro : base, fine-tuning et entrée vidéo directe

Variante	n	IoU moy.	Δ vs base	Temps (s)	Coût / 100 vid.
Pro de base	29	0.392	0.000	22.1	0.841
Pro fine-tune texte	29	0.363	-0.028	26.3	0.879
Pro fine-tune texte + objets	29	0.405	0.013	23.6	0.879
Pro entree video directe	28	0.358	-0.033	45.6	cout non journalise

font mieux que l’entrée vidéo directe. Cela suffit déjà à montrer qu’il n’est pas nécessaire de garder toute l’inférence multimodale jusqu’à la fin.

Mais la conclusion la plus importante est ailleurs. Transformer la vidéo en un état textuel structuré change la nature du problème. Au lieu de refaire une analyse lourde à chaque fois, on obtient une base de travail que l’on peut relire, comparer et réutiliser. C’est cette idée qui donne le plus de valeur à la représentation **typed-v1**, même si sa forme actuelle n’est pas encore optimale pour le sélectionneur final.

La suite logique du travail est donc claire. Il faut d’abord mieux choisir quel signal visuel vaut la peine d’être textualisé. Il faut ensuite continuer à distinguer, selon la taille du modèle, ce qui doit être réglé par le contexte et ce qui doit être réglé par l’ajustement fin. C’est à cette condition qu’une approche texte d’abord pourra vraiment devenir une solution robuste pour des systèmes contraints.

TABLEAU 12 Taxonomie initiale des échecs à valider dans l'analyse qualitative

Type d'échec	Description opérationnelle	Preuve attendue
Mauvaise frontière temporelle	Le bon sujet est choisi, mais le span ne recouvre pas la référence	IoU temporel faible avec similarité textuelle non nulle
Mauvais pic local	Le modèle s'arrête sur un segment voisin moins fort	Comparaison qualitative GT / prédiction
Signal visuel insuffisant	La transcription seule ou un contexte partiel manque un indice de mise en scène	Gain après ajout des résumés visuels
Biais dialogue-only	Le clip choisi est sémantiquement correct mais visuellement faible	Cas où le texte est plausible sans appui visuel clair
Sensibilité au contexte	Le résultat varie selon la forme du contexte plus que selon le contenu	Comparaison entre variantes de contexte

LISTE DES RÉFÉRENCES

- [1] J. CHAE, D. KIM, K. KIM, D. LEE, S. LEE, S. HA, J. MUN, W. KANG, B. ROH et J. LEE : Towards a complete benchmark on video moment localization. *In Proceedings of the International Conference on Artificial Intelligence and Statistics*, volume 238, pages 4168–4176. Machine Learning Research, 2024.
- [2] G. CHEN, Y.-D. ZHENG, J. WANG, J. XU, Y. HUANG, J. PAN, Y. WANG, Y. WANG, Y. QIAO, T. LU et L. WANG : VideoLLM : Modeling video sequence with large language models. *arXiv preprint*, arXiv :2305.13292, 2023.
- [3] S. GHOSH, A. AGARWAL, Z. PAREKH et A. HAUPTMANN : Excl : Extractive clip localization using natural language descriptions. *In Proceedings of the Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies, Volume 1*, pages 1984–1990. Association for Computational Linguistics, 2019.
- [4] Y. GUO, J. LIU, M. LI, X. TANG, X. CHEN et B. ZHAO : Vtg-LLM : Integrating timestamp knowledge into video LLMs for enhanced video temporal grounding. *arXiv preprint arXiv :2405.13382*, 2024.
- [5] Y. HE, Z. WANG, Z. SHEN, G. SUN, Y. DAI, Y. WU, H. WANG et A. LI : Shed : Shapley-based automated dataset refinement for instruction fine-tuning. *In Advances in Neural Information Processing Systems*, 2024.
- [6] L. A. HENDRICKS, O. WANG, E. SHECHTMAN, J. SIVIC, T. DARRELL et B. RUSSELL : Localizing moments in video with natural language. *In Proceedings of the IEEE International Conference on Computer Vision*, pages 5804–5813, 2017.
- [7] B. HUANG, X. WANG, H. CHEN, Z. SONG et W. ZHU : VtimeLLM : Empower LLM to grasp video moments. *In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14271–14280, 2024.
- [8] M. Bansal J. LEI, T. L. Berg : Qvhighlights : Detecting moments and highlights in videos via natural language queries. *In Proceedings of the International Conference on Neural Information Processing Systems*, pages 11846–11858. Neural Information Processing Systems, 2021.
- [9] J. LEI, L. LI, L. ZHOU, Z. GAN, T. L. BERG, M. BANSAL et J. LIU : Less is more : CLIP-BERT for video-and-language learning via sparse sampling. *In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 7327–7337, 2021.
- [10] H. LI, L. DING, M. FANG et D. TAO : Revisiting catastrophic forgetting in large language model tuning. *In Findings of the Association for Computational Linguistics : EMNLP 2024*, pages 4297–4308. Association for Computational Linguistics, 2024.
- [11] Y. LI, X. CHEN, B. HU et M. ZHANG : LLMs meet long video : Advancing long video question answering with an interactive visual adapter in LLMs. *arXiv preprint*, arXiv :2402.13546, 2024.
- [12] N. F. LIU, K. LIN, J. HEWITT, A. PARANJAPPE, M. BEVILACQUA, F. PETRONI et P. LIANG : Lost in the middle : How language models use long contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173, 2024.
- [13] Y. LIU, S. LI, Y. WU, C. W. CHEN, Y. SHAN et X. QIE : Umt : Unified multi-modal transformers for joint video moment retrieval and highlight detection. *In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 3032–3041, 2022.

-
- [14] A. RADFORD, J. KIM, T. XU, G. BROCKMAN, C. MCLEAVEY et I. SUTSKEVER : Whisper : Robust speech recognition via large-scale weak supervision. *In Proceedings of the International Conference on Machine Learning*, pages 28492–28518, 2023.
 - [15] Y. TANG, J. BI, S. XU, L. SONG, S. LIANG, T. WANG, D. ZHANG, J. AN, J. LIN, R. ZHU, A. VOSOUGHI, C. HUANG, Z. ZHANG, F. ZHENG, J. ZHANG, P. LUO, J. LUO et C. XU : Video understanding with large language models : A survey. *arXiv preprint*, arXiv :2312.17432, 2023.
 - [16] S. N. WADEKAR, A. CHAURASIA, A. CHADHA et E. CULURCIELLO : The evolution of multimodal model architectures. *arXiv preprint arXiv :2405.17927*, 2024.
 - [17] Y. WENG, M. HAN, H. HE, X. CHANG et B. ZHUANG : Longvlm : Efficient long video understanding via large language models. *In Proceedings of the European Conference on Computer Vision*, 2024.
 - [18] J. XU, C. LAN, W. XIE, X. CHEN et Y. LU : Retrieval-based video language model for efficient long video question answering. *arXiv preprint*, arXiv :2312.04931, 2023.
 - [19] J. XU, C. LAN, W. XIE, X. CHEN et Y. LU : Slot-vlm : Slowfast slots for video-language modeling. *arXiv preprint arXiv :2402.13088*, 2024.
 - [20] H. ZHANG, X. LI et L. BING : Video-llama : An instruction-tuned audio-visual language model for video understanding. *In Proceedings of the Conference on Empirical Methods in Natural Language Processing : System Demonstrations*, pages 543–553. Association for Computational Linguistics, 2023.
 - [21] P. ZHOU, L. WANG, Z. LIU, Y. HAO, P. HUI, S. TARKOMA et J. KANGASHARJU : A survey on generative ai and LLM for video generation, understanding, and streaming. *arXiv preprint*, arXiv :2404.16038, 2024.
-