

UNIVERSITÉ DE SHERBROOKE
Faculté de génie
Département de génie électrique et de génie informatique

DÉTECTION DES MOMENTS SAILLANTS D'UNE VIDÉO EN UTILISANT UNE REPRÉSENTATION TEXTUELLE

GEI 727 Définition du projet de recherche

Alexandre LAFLEUR

Sherbrooke (Québec) Canada

Mai 2025

MEMBRES DU JURY

François GRONDIN

Directeur

François MICHAUD

Évaluateur

François FERLAND

Évaluateur

RÉSUMÉ

À ce jour, le traitement automatique de longs segments vidéo requiert souvent l'utilisation de modèles multimodaux complexes, qui exigent une puissance de calcul élevée, ce qui n'est pas toujours désirable pour utilisation sur une très grande quantité de données ou réalisable dans des systèmes embarqués avec des contraintes de ressources.

Ce projet consiste à représenter intégralement les informations vidéo sous la forme d'une description textuelle détaillée et structurée, englobant les dialogues, les événements visuels, l'ambiance sonore et même les expressions émotionnelles. L'objectif est de démontrer que cette méthode pourrait simplifier considérablement l'analyse vidéo, en réduisant la dépendance aux modèles visuels et multi-modaux habituellement utilisés. La performance du modèle développé serait évaluée en comparant systématiquement les moments saillants trouvés par le modèle à des segments de référence sélectionnés par des humains, à partir d'une base de données de vidéos Youtube et de leur extraits populaires correspondants. Le choix de cette base de données se justifie par l'abondance de données disponibles et leur pertinence pour la tâche visée qui est l'analyse de vidéos de tous genre en robotique.

La principale contribution scientifique de la recherche est la création d'un standard de représentation textuelle de vidéos qui permettrait l'analyse complète du vidéo par un grand modèle de langage textuel, permettant la détection automatisée des événements importants d'un vidéo. En évitant le recours à des méthodes d'analyse multimodales intensives, cette approche pourrait permettre l'intégration d'une détection efficace des moments forts à des applications pour lesquelles c'est actuellement impossible soit financièrement dû aux coûts d'utilisation faramineux des LLMs multimodaux ou techniquement dû à l'impressionnante puissance de calcul requise. La recherche apporterait donc une contribution directe au monde de l'analyse vidéo, facilitant l'exploitation des grands modèles de langage pour le traitement de données vidéo complexes dans des contextes avec ressources limitées.

Mots-clés : Intelligence artificielle, résumé vidéo, LLM

TABLE DES MATIÈRES

1	INTRODUCTION	1
2	Synthèse des contributions pour l'extraction automatique de moments clés dans les vidéos longues	3
2.1	Modélisation vidéo-textuelle et multimodale pour la sélection de clips . . .	3
2.2	Localisation et segmentation temporelle des moments clés	5
2.3	Détection des faits saillants et filtrage du bruit	6
2.4	Fusion multimodale et alignement pour une narration cohérente	6
2.5	Optimisation des modèles et traitement des vidéos longues	8
2.6	Analyse comparative approfondie des solutions existantes et différenciations de la solution proposée	9
3	PROBLÉMATIQUE	11
4	APPROCHE PROPOSÉE, MÉTHODOLOGIE ET ÉCHÉANCIER	13
4.1	Élaboration d'une représentation textuelle structurée	13
4.2	Utilisation d'un grand modèle de langage pour identifier les segments clés .	14
4.3	Comparaison des résultats avec des références existantes	15
4.4	Processus itératif d'optimisation	15
4.5	Échéancier	16
5	CONCLUSION	19
	LISTE DES RÉFÉRENCES	21

LISTE DES FIGURES

4.1	Échéancier du projet	17
-----	--------------------------------	----

LISTE DES ACRONYMES

Acronyme	Définition
LLM	Grand modèle de langage
IA	Intelligence artificielle
VTG	Ancrage temporel dans la vidéo (<i>Video Temporal Grounding</i>)
TAN	Réseaux temporels adjacents (<i>Temporal Adjacent Networks</i>)
LLoVi	Questions-réponses vidéo (<i>Language-based Long-range Video question answering</i>)
ExCL	Localisation extractive de segments vidéo (<i>Extractive Clip Localization</i>)
QD-DETR	Transformeur de détection adaptatif (<i>Query-Dependent DETection TRansformer</i>)

CHAPITRE 1

INTRODUCTION

L’analyse de longs flux vidéo constitue un défi technique significatif en raison du volume important de données à traiter et des coûts élevés en ressources informatiques associés aux approches llms multimodales actuellement disponibles. Ces modèles exigent une puissance de calcul élevée, entraînant des coûts substantiels lorsqu’exécutés sur des serveurs informatiques via des API ou une grande puissance de calcul lorsqu’exécutés sur des plateformes embarquées, ce qui limite leur utilisation pratique dans des contextes où les ressources informatiques ou financières sont restreintes.

Pour réaliser cette tâche avec peu de ressources, l’approche multimodale conventionnelle n’est pas adaptée. L’architecture est plus sophistiquée qu’un LLM textuel, car elle doit utiliser des encodeurs spécialisés aux différents médias et les fusionner en utilisant la fusion profonde via de l’attention croisée et de la fusion précoce [32]. Cette complexité mène à des entraînements plus coûteux qui requiert significativement plus de données et de puissance de calcul qu’un LLM textuel et à une structure plus volumineuse qui mène à un plus grand nombre de paramètres [40].

Une alternative émergente consiste à exploiter les avancées récentes obtenues avec les grands modèles de langage (LLM), qui atteignent maintenant un niveau remarquable en matière de compréhension et d’analyse sémantique de textes [34]. Cette recherche propose de convertir et d’ordonner l’intégralité des données audiovisuelles issues d’un robot en une représentation purement textuelle, pour que le traitement analytique soit confié exclusivement à un modèle linguistique, réduisant ainsi la dépendance aux méthodes multimodales complexes et coûteuses en ressources [40].

Cette solution soulève quand-même plusieurs questions techniques et scientifiques importantes. Il faut vérifier si la représentation textuelle de la vidéo peut être assez fidèle et exhaustive pour permettre une analyse complète de la vidéo par le texte. Une description textuelle complète nécessite non seulement de retranscrire fidèlement les dialogues ou les voix hors champ, mais pourrait également bénéficier de capter efficacement l’essentiel des informations visuelles et non verbales telles que les expressions faciales, le langage corporel, les éléments contextuels et les transitions scénaristiques. Il faut également déterminer si les grands modèles de langage textuel ont une compréhension assez avancée pour identifier

correctement les moments clés d’une vidéo avec une précision comparable à celle obtenue par un humain en utilisant la représentation textuelle du vidéo.

L’objectif scientifique principal est de démontrer la faisabilité technique d’un processus entièrement textuel de détection d’événements, adapté aux contraintes spécifiques de l’analyse de long flux vidéos avec des ressources matérielles ou monétaires limitées. Le succès de cette approche mènerait à l’implémentation d’analyse vidéo automatisée sur de long flux vidéos dans des applications qui ne pouvait jusqu’à présent pas justifier les coûts computationnel et monétaires associés. Comme analyser des flux de caméras de surveillance résidentielle ou automatiser l’assurance qualité d’un centre d’appel en vidéo-conférence en recueillant les moments problématiques.

Sur le web, plusieurs plateformes alimentées par l’IA ont émergé pour simplifier et accélérer le processus de création de clips courts. Ces plateformes offrent aux créateurs de contenu, aux équipes marketing et aux utilisateurs sans compétences la possibilité de générer des clips attractifs à partir des moments saillants issus de vidéos longues. Même si elles ne sont pas adaptées pour la recherche académique, elles comblent un besoin très semblable à ceux des chercheurs qui désirent extraire les moments forts d’un long flux vidéo avec des ressources limitées. Elles doivent générer un très grand nombre de clips pour un très faible coût monétaire dû à la forte compétition entre plateformes. Ces solutions purement logicielles et automatisées gardent leurs coûts bas en utilisant des modèles de langage optimisés et des techniques de traitement vidéo à faible puissance de calcul. Ce choix technologique est lié aux mêmes contraintes rencontrées par les chercheurs qui désirent analyser le flux vidéo issu des capteurs embarqués sur des appareils disposant de ressources computationnelles limitées comme des robots ou des ordinateurs portables. De manière similaire aux plateformes web devant minimiser leurs coûts de calcul pour offrir des solutions abordables aux consommateurs, les chercheurs pourraient bénéficier d’approches légères d’analyse vidéo pour conserver des performances acceptables avec des ressources computationnelles limitées. Ainsi, étudier les techniques employées par ces plateformes web offre des pistes utiles pour développer des méthodes d’analyse vidéo adaptées aux systèmes embarqués avec ressources limitées.

Le chapitre 2 présente l’état de l’art de la détection de moments forts dans de long flux vidéos et analyse les solutions webs existante. Le chapitre 3 explique la problématique en détails. Le chapitre 4 propose une approche pour régler la problématique et montre une méthodologie et un échéancier possible pour mener à terme la maitrise.

CHAPITRE 2

Synthèse des contributions pour l'extraction automatique de moments clés dans les vidéos longues

Les travaux présentés dans cette synthèse ont été sélectionnés pour leur pertinence dans l'adaptation des méthodes d'analyse vidéo aux ressources limitées des plateformes robotiques. La conversion des données audiovisuelles en représentations textuelles pour traitement par des modèles de langage offre une alternative aux approches multimodales traditionnelles comme MiniGPT4-Video [19] et Video-LLaMA [14], qui nécessitent des ressources computationnelles importantes. En se concentrant sur la fidélité et l'exhaustivité de la représentation textuelle, ces travaux visent à démontrer que les modèles de langage peuvent identifier efficacement les moments clés d'une vidéo, même en l'absence de traitement visuel direct.

2.1 Modélisation vidéo-textuelle et multimodale pour la sélection de clips

Pour réussir à trouver les moments saillants d'une vidéo, une intelligence artificielle (IA) pourrait devoir analyser et comprendre le contenu vidéo, non seulement en termes de ce qui est vu à l'écran, mais également en intégrant les éléments textuels et auditifs de la vidéo. Cette étape explore les modèles et techniques vidéo-textuelles et multimodales qui permettent d'enrichir la pertinence et la précision de la sélection des segments dans le cadre de l'automatisation du montage.

Des modèles comme CLIP [24] (*Contrastive Language Image Pre-training*) et BuboGPT [47] jouent un rôle fondamental dans la correspondance entre le contenu visuel et les descriptions textuelles. CLIP a été développé pour relier directement des images à des textes, permettant une correspondance directe entre des concepts visuels et des descriptions narratives. Cette capacité est précieuse pour un résumé automatique, car elle permettrait de sélectionner les segments visuels les plus pertinents par rapport aux requêtes textuelles ou aux tendances narratives [12][30]. Cependant, CLIP est principalement entraîné sur des

images statiques, ce qui limite sa capacité à traiter efficacement les dimensions temporelles et narratives des vidéos.

Dans un montage vidéo, la continuité visuelle et le contexte narratif sont essentiels, et cette lacune peut réduire la pertinence des segments identifiés. BuboGPT, quant à lui, renforce cette capacité en ajoutant une couche d'ancrage visuel, permettant une identification et une localisation précises des objets dans chaque image en fonction des descriptions textuelles [39][31]. Par exemple, une scène de nature pourrait être identifiée et extraite si elle est associée à un texte comme « aventure en plein air ». Cette granularité fine est un atout, mais elle dépend fortement de la qualité des descriptions textuelles fournies. Si les textes sont vagues, ambigus ou contradictoires, le modèle risque de sélectionner des segments non pertinents, réduisant ainsi l'efficacité du montage.

Si l'image et le texte offrent des informations importantes pour la sélection des segments, l'intégration de l'audio permet une compréhension encore plus riche de la vidéo [14][8]. Les modèles Valley [29] et Video-LLaMA [14] démontrent comment des signaux auditifs peuvent être exploités en parallèle des indices visuels et textuels pour un alignement complet des modalités. Valley utilise un alignement multimodal qui intègre des signaux audio pour fournir une compréhension contextuelle approfondie des vidéos [3], tandis que Video-LLaMA emploie des modules spécialisés qui séparent et intègrent les indices visuels et auditifs en requêtes interprétables par les modèles de langage [18]. Cette approche permet de prendre en compte des éléments sonores tels que les dialogues, les changements d'intonation et la musique, qui influencent fortement l'engagement émotionnel et narratif.

Cependant, l'efficacité de ces modèles dépend de la qualité des signaux audio disponibles. Par exemple, dans des environnements bruités ou des vidéos amateurs, la performance de Valley peut diminuer, compromettant ainsi la précision de l'analyse contextuelle. De plus, Video-LLaMA, bien que très performant, est coûteux en termes de calcul, ce qui peut le rendre moins adapté à des vidéos longues ou à des systèmes nécessitant des réponses en temps réel. La fusion multimodale de ces approches (image-texte-audio) ouvre la voie à une sélection de clips qui ne se limite pas aux caractéristiques visuelles d'une vidéo, mais qui intègre une compréhension complète des signaux auditifs et textuels [45][22].

Néanmoins, l'intégration de multiples modalités peut également introduire des biais ou des conflits entre les signaux. Par exemple, une musique dramatique superposée à des visuels calmes pourrait créer une ambiguïté dans l'interprétation de la scène. La capacité des modèles à hiérarchiser ces signaux ou à arbitrer entre eux reste un défi à relever.

2.2 Localisation et segmentation temporelle des moments clés

Pour garantir une continuité narrative et un résumé fluide, il faut être capable d’identifier non seulement les moments clés dans une vidéo, mais également leurs limites temporelles précises. Les techniques de localisation temporelle et de segmentation des vidéos jouent ici un rôle essentiel, permettant à l’IA de découper les séquences tout en conservant leur sens et en respectant la chronologie narrative. Cette section explore les approches avancées de segmentation temporelle et de localisation des moments clés, nécessaires pour une sélection précise et cohérente.

Les modèles comme VTimeLLM [3] et VTG-LLM (*Video Temporal Grounding*) [41] apportent des solutions novatrices pour la délimitation précise des segments vidéo en intégrant des indicateurs temporels explicites. VTimeLLM, par exemple, utilise une stratégie d’entraînement en plusieurs étapes pour renforcer la précision temporelle, permettant de mieux comprendre les débuts et fins des segments d’intérêt [8][16]. VTG-LLM, quant à lui, exploite des incorporations (*embeddings*) de séquence-temps et des jetons de temps absolus pour ancrer précisément les moments dans le temps, évitant ainsi les erreurs de quantification qui peuvent survenir dans des vidéos complexes ou de longue durée [41][13].

Cette intégration de l’horodatage permet au modèle de maintenir une continuité temporelle, essentielle pour les montages vidéo nécessitant une précision d’alignement entre les scènes. Ces modèles démontrent l’importance de la localisation temporelle dans les vidéos longues. En intégrant l’horodatage de manière explicite, il serait alors possible non seulement de sélectionner les moments clés avec une plus grande précision, mais aussi de s’assurer que chaque segment est correctement positionné dans l’ordre narratif, évitant ainsi les coupures abruptes ou incohérentes [16][22].

Pour organiser les segments dans un ordre fluide, des modèles comme le *Moment Context Network (MCN)* [22] et 2D-TAN (*Temporal Adjacent Networks*) [33] utilisent des techniques de cartographie temporelle et contextuelle. MCN associe des caractéristiques locales et globales pour identifier des débuts et fins de moments spécifiques, en analysant non seulement chaque segment individuellement, mais aussi en tenant compte du contexte général de la vidéo [20][4]. 2D-TAN adopte une approche de cartographie bidimensionnelle pour modéliser les relations temporelles entre segments adjacents, garantissant ainsi que chaque segment sélectionné conserve une continuité narrative par rapport aux autres [28][33].

2.3 Détection des faits saillants et filtrage du bruit

Pour être capable de repérer les moments saillants et de filtrer les segments de moindre intérêt ou redondants, plusieurs modèles ont été explorés. Ils se concentrent sur la détection des faits saillants et l'élimination des segments non pertinents, permettant ainsi une sélection précise des passages qui ont le plus de chances d'être intéressants.

HL-CLIP [8] et GPTSee [43] sont deux modèles innovants pour la détection des faits saillants. HL-CLIP utilise une technique de regroupement par saillance (*saliency pooling*) pour stabiliser la détection de moments intéressants en moyennant les scores de saillance à travers plusieurs trames adjacentes. Cette approche permet une détection plus robuste des segments pertinents, même dans des séquences complexes, et évite les sélections incohérentes [13][43]. GPTSee, quant à lui, repose sur une analyse de similarité sémantique entre les descriptions des images extraites et les requêtes textuelles pour identifier les moments saillants les plus engageants [43][42].

En ajoutant un filtrage sémantique, GPTSee affine la sélection pour ne retenir que les segments en lien direct avec les thèmes ou intentions de la narration. HL-CLIP et GPTSee démontrent comment la détection de faits saillants peut être renforcée par des scores de similarité et de saillance, améliorant ainsi la pertinence des extraits retenus pour le montage.

Dans le domaine du filtrage de contenu, LLoVi (*Language-based Long-range Video question answering framework*) [5] propose une méthode de résumé multi-étapes pour éliminer le bruit et affiner la qualité des segments choisis [29][4]. L'approche de LLoVi consiste à générer des descriptions textuelles pour chaque clip court, puis à les résumer en plusieurs étapes pour éliminer les informations redondantes ou non pertinentes. Ce processus de résumé successif permet de concentrer l'attention sur les passages ayant la plus forte valeur narrative.

2.4 Fusion multimodale et alignement pour une narration cohérente

Pour maximiser les chances qu'un passage vidéo soit réellement l'un de ses moments forts, il pourrait être utile d'intégrer des informations provenant de plusieurs modalités en une seule structure cohérente, qu'elles soient visuelles, textuelles ou auditives. La fusion multimodale et l'alignement des informations semblent donc essentiels pour sélectionner des clips à fort potentiel d'être intéressants. Dans cette section, nous explorons les techniques

qui permettent d'enrichir la narration vidéo en utilisant des approches multimodales sophistiquées.

Les modèles UMT (*Unified Multi-modal Transformers*) [42] et Slot-VLM [18] offrent des solutions complètes pour intégrer des informations visuelles, textuelles et auditives dans une seule structure cohérente. UMT exploite les données audio et visuelles pour extraire des moments spécifiques en fonction des requêtes textuelles, en intégrant un générateur et un décodeur de requêtes pour transformer les attentes narratives en points de détection temporels [42]. Cette méthode de fusion permet de traiter les vidéos comme un ensemble multimodal complet, assurant que les segments sélectionnés tiennent compte de tous les signaux disponibles.

Slot-VLM [18] introduit une autre dimension avec son système de *SlowFast Slots*, qui décompose les vidéos en jetons centrés sur les objets (*slow-slots*) et jetons centrés sur les événements (*fast-slots*). Cette technique permet d'adapter l'analyse des vidéos selon la fréquence d'apparition des objets et la dynamique temporelle des événements, en maintenant une cohérence entre les objets fixes et les mouvements rapides. Cette approche est particulièrement utile pour une narration fluide, car elle prend en compte les éléments stables, comme les décors, et les éléments en mouvement, assurant une transition naturelle entre les segments.

Les modèles ExCL (*Extractive Clip Localization*) [30] et QD-DETR (*Query-Dependent Detection TRansformer*) [43] permettent d'adapter dynamiquement les choix de segments en fonction des descriptions narratives et des requêtes textuelles. ExCL utilise une approche extractive qui prédit les trames de début et de fin en fonction de la pertinence avec les descriptions narratives. Ceci permet de sélectionner des segments qui s'alignent étroitement avec les attentes narratives, assurant que chaque clip choisi apporte une valeur ajoutée à la continuité de l'histoire.

QD-DETR utilise un encodeur à attention croisée qui intègre explicitement les requêtes dans la représentation des clips vidéo, offrant un niveau d'adaptabilité élevé pour correspondre précisément aux intentions narratives des spectateurs [17]. Grâce à un mécanisme d'appariement flexible, il est possible de discriminer entre les segments en fonction de la demande, filtrant les moments qui ne correspondent pas aux critères recherchés.

2.5 Optimisation des modèles et traitement des vidéos longues

Pour les vidéos de longue durée, il serait essentiel d'optimiser les ressources sans compromettre la précision de la sélection des segments. Il faudrait non seulement pouvoir identifier les moments clés dans des vidéos longues, mais aussi le faire de manière efficace et rapide. Les modèles suivants se concentrent sur des techniques d'optimisation qui permettent un traitement plus rapide et moins gourmand en ressources, tout en maintenant une sélection de clips pertinente.

Les modèles LongVLM [46] et *Less is More*(CLIPBERT) [16] mettent en avant des techniques d'échantillonnage éparses et de segmentation optimisée pour éviter le traitement de chaque trame dans les vidéos longues. LongVLM segmente les vidéos longues en clips courts et extrait pour chaque segment les caractéristiques locales, avant de les fusionner dans un contexte global [46]. Cette approche réduit le volume de données à traiter tout en maintenant une compréhension précise des segments.

Less is More(CLIPBERT), quant à lui, utilise un échantillonnage éparses pendant l'entraînement pour capturer les informations essentielles tout en réduisant les besoins en mémoire. Lors de l'inférence, CLIPBERT applique un échantillonnage dense, permettant ainsi de conserver un haut niveau de précision dans la sélection des moments saillants sans traiter chaque trame individuellement [16]. En utilisant des méthodes d'échantillonnage et de segmentation, il serait possible de traiter les vidéos longues de manière efficace, en s'assurant que seuls les segments pertinents sont extraits. Par exemple, dans un enregistrement de caméra de surveillance ou dans un flux vidéo de la caméra embarquée d'un robot de plusieurs heures, cette optimisation permettrait de cibler des moments clés sans engorger les ressources de traitement.

Les modèles VTG-LLM [41] et VTimeLLM [3] utilisent des techniques de compression des données visuelles pour réduire la surcharge de traitement sans sacrifier la qualité de l'information. VTG-LLM introduit une compression par compartiment (*slot*) qui regroupe les informations visuelles en blocs, permettant un échantillonnage étendu avec une capacité de traitement plus élevée [41]. Cette technique est particulièrement utile pour les vidéos longues et complexes, où chaque bloc compressé conserve des détails essentiels pour la narration.

VTimeLLM, de son côté, utilise une stratégie d'entraînement par étapes pour améliorer la localisation temporelle dans des vidéos longues, permettant ainsi de mieux appréhender les séquences d'événements sans pertes de données importantes [3]. Grâce à des jetons

compressés, ce modèle permet de traiter des vidéos volumineuses tout en conservant une précision optimale. En utilisant des techniques de compression et de traitement par *slots*, il serait possible de gérer de grandes quantités de données sans ralentir le processus de sélection, tout en assurant la précision nécessaire pour maintenir l'intérêt narratif et visuel des clips.

Ainsi, les techniques d'optimisation proposées par LongVLM [46], *Less is More* (CLIPBERT) [16], VTG-LLM [41], et VTimeLLM [3] permettent de réduire considérablement la complexité de traitement dans des vidéos longues, tout en maintenant la qualité de sélection des segments pertinents.

2.6 Analyse comparative approfondie des solutions existantes et différenciations de la solution proposée

Les plateformes d'édition vidéo automatisée reposent sur une série de technologies et d'approches IA variées pour analyser, sélectionner et transformer des vidéos longues en clips courts adaptés aux réseaux sociaux. Descript [9] se distingue dans le domaine de l'édition vidéo en proposant une interface qui permet de modifier directement le contenu vidéo à partir de la transcription texte, une innovation qui rend l'édition de contenu aussi intuitive que la modification d'un document texte. En intégrant une transcription rapide et précise des fichiers audio et vidéo, Descript simplifie la création de contenu en offrant une base textuelle pour éditer et réviser les enregistrements. La simplicité d'utilisation et la rapidité de la transcription permettent aux utilisateurs d'éditer les vidéos de manière efficace, sans avoir à manipuler directement les clips vidéo. Cette approche basée sur le texte, bien que puissante, enlève tout l'aspect visuel de la vidéo et requiert souvent une deuxième édition visuelle pour les détails plus fins.

Captions.ai [7], 2short.ai [1], Ssemble [36] et OpusClip [26] automatisent l'extraction des moments clés d'une vidéo en analysant des indicateurs d'engagement et de viralité pour sélectionner les segments qui ont le plus de potentiel de capter l'attention d'une personne qui regarde la vidéo. Ces outils scannent le contenu vidéo et identifient automatiquement les moments saillants en fonction de critères préétablis, offrant aux créateurs un moyen rapide de créer des clips engageants. Ces technologies permettent un gain de temps considérable pour les créateurs de contenu, réduisant la nécessité d'explorer manuellement la vidéo pour trouver les moments engageants.

2short.ai [1], Framedrop [11], Powder [27] et Munch [25] se concentrent sur des techniques de détection et de retouche visuelle, comme le suivi facial ou l'ajout d'effets visuels et

sonores. Par exemple, 2short.ai utilise la technologie de suivi facial pour garder le focus sur les intervenants principaux, ce qui améliore l'impact visuel, tandis que Powder [27] se concentre sur les enregistrements de jeux vidéo en détectant les moments d'action et en appliquant des modèles de montage spécifiques au contenu de jeu. Ces outils permettent d'améliorer l'impact visuel en utilisant des ajustements centrés sur les éléments clés, comme les visages ou les objets importants, tout en optimisant la vidéo pour des plateformes spécifiques. Par contre, ces fonctionnalités peuvent être restreintes à des types de contenu particuliers, ce qui limite leur utilisation pour des vidéos plus variées.

Klap [21], SendShort [35] et Recast Studio [37] permettent aux utilisateurs de personnaliser les clips en ajoutant des effets visuels et des légendes afin de renforcer l'identité visuelle du contenu. Bien que chaque plateforme offre des options de personnalisation, elles sont souvent limitées à des ajustements de base et peuvent nécessiter des compétences en édition pour des modifications avancées. Cette personnalisation permet aux utilisateurs de mettre encore plus en valeur une partie de la vidéo, comme pour un robot qui voudrait mettre un carré rouge autour de la chose précise qu'il a remarquée qu'était anormale.

Ces plateformes d'édition vidéo automatisée présentent des avantages notables qui les rendent intéressants pour des utilisateurs voulant générer rapidement des clips à partir de longs vidéos. La majorité des plateformes existantes offrent une interface intuitive, simplifiant l'édition vidéo même pour les utilisateurs novices. L'automatisation des tâches de segmentation, d'extraction de moments clés et d'ajout de sous-titres réduit le besoin de compétences avancées en montage vidéo. Ceci rend ces plateformes idéales pour ceux qui souhaitent produire rapidement des clips sans maîtriser les outils d'édition traditionnels.

Les outils d'ajustement et d'optimisation sont spécifiquement conçus pour maximiser l'attention, en créant des clips dynamiques qui captent l'attention de l'audience. Un robot qui génère un clip de ce genre aurait plus de chance que son clip soit écouté au complet, ce qui maximiserait le transfert d'information humain-machine. Avec la mondialisation du contenu numérique, plusieurs plateformes, comme Captions.ai [7], OpusClip [26] et Framedrop [11], ont intégré le support de plusieurs langues. Cette fonctionnalité permet aux utilisateurs de s'adresser à des audiences diversifiées et d'augmenter leur portée. Les plateformes sont capables de générer des sous-titres dans plusieurs langues et d'inclure des options de traduction, rendant le contenu plus accessible et inclusif.

CHAPITRE 3

PROBLÉMATIQUE

D'un côté, les méthodes classiques d'analyse automatisée des contenus vidéo reposent souvent sur des architectures multimodales complexes, intégrant à la fois des traitements visuels, audio et textuels. L'utilisation de grands modèles de langage multimodaux pour la tâche d'analyse vidéo demande des ressources computationnelles significatives, ce qui les rend peu accessibles, spécialement dans des contextes contraints par une capacité limitée de calcul ou de stockage comme les systèmes embarqués en robotique. Il serait important de développer une méthode d'analyse vidéo qui utilise moins de ressources pour faciliter son utilisation en contexte de robotique mobile. Parallèlement, la popularité des vidéos courtes tirées de longues vidéos, parfois appelées *shorts*, porte à croire que les moments forts (ou saillants) d'une longue vidéo peuvent systématiquement être extraits et isolés comme particulièrement importants. Ce fait, d'apparence non relié au domaine de la robotique, est pourtant un aspect très important à ce projet de recherche. Ces clips extraits de longues vidéos se rapprochent beaucoup des moments intéressants du long flux vidéo que peut produire un robot muni de caméras. Si des données vidéos librement disponibles sur internet et libres de droits peuvent être transcrites au format textuel et utilisées pour entraîner et tester un grand modèle de langage pour la détection de moments forts, un des plus gros problèmes à l'entraînement de ces modèles, le nombre de données astronomique requis pour le faire n'est plus un enjeu. Donc, en combinant le besoin de méthodes moins énergivores pour l'analyse vidéo en robotique, et la disponibilité d'une base de données très similaire aux besoins de la détection de moments forts sur de longs flux vidéos en robotique, la question de recherche suivante émerge :

Dans quelle mesure est-il possible de représenter fidèlement et exhaustivement le contenu d'une vidéo exclusivement par des descripteurs textuels, afin de permettre à un grand modèle de langage (LLM) d'identifier automatiquement les segments les plus saillants ? Cette question conduit à deux dimensions interdépendantes de la problématique :

1) La fidélité et l'exhaustivité de la représentation textuelle du contenu vidéo

La principale difficulté réside dans l'identification, puis dans l'octroiement des éléments pertinents à inclure dans la représentation : les actions visibles à l'écran, les dialogues entendus, l'ambiance sonore, les variations émotionnelles, les transitions entre les scènes

ou tout autre élément contextuel. Aussi, une réflexion, et surtout une rétroaction, doit être menée sur la granularité optimale de cette représentation textuelle afin d'éviter une perte significative d'information tout en gardant une taille restreinte rester traitable par des modèles de langages avec une petite taille de contexte.

2) La capacité du LLM à identifier les moments clés à partir d'une représentation strictement textuelle

Le modèle doit être en mesure de détecter des segments porteurs d'intérêt particulier (émotion, intensité narrative, action décisive) sans accès direct aux aspects visuels et sonores d'origine. Il faut alors avoir une façon d'entraîner et de valider le modèle pour cette tâche précise.

Ce qui amène à l'objectif général du projet, qui consiste à vérifier la faisabilité et l'efficacité d'une représentation strictement textuelle des vidéos pour l'identification automatisée de segments clés par un LLM , et ses quatre sous-objectifs :

- 1) Élaborer une représentation textuelle complète et structurée du contenu vidéo
 - 2) Évaluer la possibilité d'identifier les moments forts, à partir de cette représentation textuelle, d'un grand modèle de langage (LLM)
 - 3) Comparer objectivement les extraits sélectionnés par le modèle avec des extraits de référence.
 - 4) Optimiser progressivement la méthode de représentation textuelle et l'utilisation du modèle afin d'améliorer la concordance avec les références
-

CHAPITRE 4

APPROCHE PROPOSÉE, MÉTHODOLOGIE ET ÉCHÉANCIER

L’objectif consiste à définir et valider une méthode d’encodage textuel capable de représenter de façon fidèle et précise les dimensions visuelles, auditives et narratives d’une vidéo. Le tout, en restant assez concis pour permettre que le traitement soit fait par un LLM le moins énergivore possible et en utilisant le moins de jetons possible. Une des hypothèses sur laquelle repose cette partie est qu’avec une représentation suffisamment détaillée et avec un choix judicieux des composantes détaillées, le problème d’analyse vidéo pourrait être simplifié, permettant à un modèle moins puissant de l’analyser correctement. En bref, il s’agit d’encoder à l’avance les données jugées pertinentes, pour réduire la charge d’inférence du LLM.

La question de examiner s’il est possible de générer une description textuelle suffisamment exhaustive d’une vidéo pour permettre à un grand modèle de langage (LLM) purement textuel d’identifier automatiquement les moments saillants d’une vidéo, dans le but de minimiser les ressources nécessaires pour l’analyse et pour l’utiliser dans des systèmes embarqués ou des situations de ressources limitées.

La première étape consiste à élaborer une représentation textuelle structurée du contenu vidéo, la deuxième étape évalue la capacité d’un LLM à identifier les segments clés à partir de cette représentation, la troisième étape compare les résultats obtenus avec des références existantes, et enfin, la quatrième étape met en place un processus itératif d’optimisation pour améliorer la précision et l’efficacité de l’approche.

4.1 Élaboration d’une représentation textuelle structurée

La représentation textuelle inclurait une transcription des dialogues et des narrations, une segmentation temporelle de la vidéo en scènes ou en événements distincts et, si possible, l’inventaire des objets présents dans la scène et des informations sur l’intonation ou sur l’émotion perçue. Il serait important que le tout soit structuré de façon claire et constante pour aider un grand modèle de langage à travailler avec.

Pour ce faire, il faudrait réaliser l'évaluation comparative de plusieurs outils existants en reconnaissance automatique de la parole, par exemple Whisper [2], et des modèles de reconnaissance visuelle d'objets et de scènes basés sur des réseaux neuronaux pré-entraînés disponibles dans la littérature, par exemple les modèles convolutifs comme YOLOv12 [44]. Le choix final des outils sera justifié par une analyse quantitative de leur précision (taux d'erreur des transcriptions ou taux de reconnaissance d'objets validés sur jeux de données publics, comme COCO [38] ou ActivityNet [10]).

Il faudrait également mettre en place un prototype de séquence de traitement automatisé combinant tous les outils. L'efficacité de cette combinaison sera validée en mesurant le nombre de ressources utilisées, afin de s'assurer que la séquence de traitement complète qui permet d'utiliser un LLM purement textuel n'est pas en fait plus gourmand en ressources qu'un LLM multimodal. Il faudrait alors comparer l'usage en ressources d'un LLM multimodal pour une même vidéo, et pour une analyse vidéo avec une précision et exactitude similaire.

La validation se fera sur un échantillon réduit de vidéos libres de droits choisis par le chercheur lui-même, afin d'ajuster empiriquement la granularité optimale et les éléments présents dans la représentation. La représentation fonctionne quand le LLM peut l'utiliser pour extraire un moment de façon constante. Ce sera alors dans la dernière étape d'itération et d'optimisation que la représentation textuelle pourra être testée davantage et modifiée pour obtenir de meilleurs résultats, soit des moments plus saillants, plus proches de ceux choisis dans la base de données.

4.2 Utilisation d'un grand modèle de langage pour identifier les segments clés

Pour cet objectif, il faut faire la sélection d'un LLM approprié et l'évaluation rigoureuse de sa capacité à localiser correctement les segments clés, en comparant ses résultats à une référence établie par les vidéos et clips associés par le chercheur lui-même. Le but est de vérifier, parmi les modèles de langage existants, lequel peut répondre le plus adéquatement à la tâche d'analyse vidéo via représentation textuelle, et de vérifier de quelle façon il est possible d'augmenter les capacités d'un modèle pré-entraîné pour réaliser la tâche spécifique en utilisant différents principes d'ajustements fins et d'interrogations du modèle.

Le modèle retenu (par exemple GPT-4) traitera chaque description selon une consigne unique et standardisée. La validation se fera quantitativement. Un indice d'intersection temporelle sera utilisé pour quantifier la correspondance entre l'extrait identifié automati-

quement par le LLM et l'extrait associé dans la base de données. Cet indice correspond au ratio du chevauchement temporel par rapport à la durée totale de l'extrait de référence. En partant de l'hypothèse qu'un moment fort est précisément circonscrit dans le temps, tandis que ses limites peuvent légèrement varier selon le degré de contexte recherché, un seuil d'environ 10 pour cent semble adéquat car selon la littérature, un indice d'intersection temporelle de 0.1 mesure la capacité à tomber globalement sur le bon passage, même si le début et la fin sont flous. Il serait aussi intéressant de graduellement mesurer la précision du modèle en utilisant des seuils plus stricts comme 0.3, 0.5 et 0.7, encore une fois en suivant les recommandations de [15].

4.3 Comparaison des résultats avec des références existantes

Cette étape vise à mesurer concrètement si les choix effectués par le modèle concordent avec les moments considérés comme saillants par la base de données, qui elle-même serait créée à partir de vidéos libres de droits disponibles en ligne. Il faudrait d'abord monter cette base de données, puis l'utiliser pour comparer la performance des différentes représentations et modèles. Selon LIMA [6], la qualité, la diversité et la spécificité de format des données ont plus d'impact que la taille brute du jeu de données sur la performance du modèle. Après mille exemples bien choisis, les bénéfices d'en ajouter d'autres sont négligeables.

Le corpus inclura des vidéos et des extraits courts libres de droits provenant de la plateforme YouTube, sélectionnées selon les critères suivants : diversité des genres (documentaires, tutoriels, humour, vlogs), afin de tester la robustesse de l'approche face à différents contextes, puisqu'un robot peut être utilisé dans toutes sortes de situations. Présence d'extraits courts (*shorts*) déjà populaires, servant de référence externe fiable pour l'évaluation du modèle. Chaque vidéo retenue ainsi que ses extraits courts associés seront convertis à un format textuel avec des horodatages en utilisant des outils comme Whisper [2]. Il faudra alors utiliser des algorithmes de type fenêtre glissante pour trouver où exactement dans la vidéo ce moment fort est présent [15].

4.4 Processus itératif d'optimisation

Pour cet objectif, un processus itératif sera mis en place pour affiner progressivement la description textuelle, l'entraînement fin et les instructions données au LLM. Chaque itération sera motivée par les performances mesurées à l'étape précédente. Des améliorations pourront inclure l'ajout de descripteurs textuels complémentaires comme les expressions faciales, les nuances émotionnelles ou les annotations temporelles supplémentaires.

Par exemple, si l’absence d’informations émotionnelles ou contextuelles essentielles, marquée par le fait que l’extrait de référence est hautement chargé en émotion, mais que le LLM ne semble pas être capable d’utiliser cette information pour le trouver, il faudrait procéder à une itération. Dans ce cas, la description textuelle serait enrichie en intégrant des descripteurs supplémentaires (annotations émotionnelles, variations d’intonation), dont l’importance est déjà confirmée par la littérature sur l’analyse multimodale.

Un éventuel ajustement du modèle de langage avec un entraînement fin sur les données récoltées pourrait être également envisagé si les premiers résultats démontrent une nécessité claire d’améliorer la sensibilité du modèle aux indices spécifiques au contexte vidéo. Pour ce faire, il faudrait générer une représentation temporelle complète des vidéos de référence afin de se générer des données d’entraînement propres à la situation. Chaque itération serait documentée, justifiée scientifiquement et suivie d’une nouvelle validation selon les mêmes critères quantitatifs et qualitatifs mentionnés précédemment.

4.5 Échéancier

Phase 1 (6 mois) : Conception de la représentation textuelle et du protocole d’extraction automatique

Phase 2 (6 mois) : Constitution d’une base de données de vidéo et clips associés

Phase 3 (6 mois) : Interaction avec le grand modèle de langage et validation comparative

Phase 4 (6 mois) : Processus itératif d’optimisation

	2024					2025					2026													
	Mai	Juin	Juillet	Août	Septembre	Octobre	Novembre	Décembre	Janvier	Février	Mars	Avril	Mai	Juin	Juillet	Août	Septembre	Octobre	Novembre	Décembre	Janvier	Février	Mars	Avril
Phase 1: Conception de la représentation textuelle et du protocole d'extraction automatique																								
Création de la représentation textuelle																								
Création des outils pour populer la représentation textuelle																								
Phase 2: Constitution d'une base de données de vidéo et clips associés																								
Générer la liste de vidéos et clips associés au format textuel																								
Préparer ces données pour l'entrainement fin, et pour la validation																								
Phase 3: Interaction avec le grand modèle de langage et validation comparative																								
Tests des différents llms et choix du llms à utiliser																								
Procéder à l'entrainement fin et au prompting pour permettre au llm d'utiliser la représentation textuelle pour l'analyse																								
Phase 4: Processus itératif d'optimisation																								

FIGURE 4.1 Échéancier du projet

CHAPITRE 5

CONCLUSION

Cette définition de projet de recherche propose une étude qui vise à déterminer la possibilité de représenter fidèlement et exhaustivement une vidéo par une représentation exclusivement textuelle, pour permettre à un grand modèle de langage (LLM) d’identifier automatiquement les moments les plus pertinents de la vidéo. Le projet vise à utiliser les avancées des grands modèles de langages pour analyser une vidéo en utilisant moins de ressources qu’avec une approche multimodale plus complexe et coûteuse en ressources. La recherche a pour but d’évaluer si une transcription détaillée, intégrant des éléments visuels, narratifs et sonores sous forme textuelle structurée, permettrait à un LLM de détecter efficacement des événements saillants dans une séquence vidéo.

La contribution scientifique majeure de cette étude serait de démontrer que des systèmes purement textuels peuvent effectivement remplacer, dans certaines situations précises, des méthodes multimodales gourmandes en puissance de calcul, tout en conservant une capacité d’analyse satisfaisante.

Sur le plan pratique, les retombées potentielles incluent la réduction significative des ressources nécessaires pour réaliser l’analyse automatisée de vidéos. Des mesures quantitatives seront présentées comme résultat, comparant les ressources utilisées par une intelligence artificielle multimodale à celles utilisées par notre modèle pour un résultat similaire de détection de moments forts. De telles avancées ouvriraient la voie à des robots autonomes capables de surveillance intelligente, d’inspection automatisée ou de reconnaissance rapide d’événements critiques dans des environnements variés (sécurité, exploration, assistance aux humains), tout en minimisant les contraintes matérielles et énergétiques. Elles permettraient également aux robots disposant de peu de ressources computationnelles de réaliser l’analyse vidéo directement sur leur matériel embarqué, renforçant la sécurité et la confidentialité des données en évitant leur transmission via internet et l’interaction avec des *API* infonuagiques, un enjeu important pour des robots comme T-Top [23].

À plus long terme, ce projet contribuerait à la communauté scientifique en clarifiant les avantages et les limites d’une représentation purement textuelle pour des contenus audiovisuels. Il permettrait également de mieux cerner les conditions sous lesquelles l’information

visuelle peut être traduite efficacement en descripteurs textuels sans perte critique de données, ainsi que les risques potentiels liés à une simplification excessive.

LISTE DES RÉFÉRENCES

- [1] 2SHORT : 2short tool. [En ligne]. Disponible : <https://2short.ai>. Consulté le 2024-11-04.
- [2] T. Xu G. Brockman C. McLeavey I. Sutskever A. RADFORD, J. Kim : Whipser : Robust speech recognition via large-scale weak supervision. *Dans Proceedings of the International Conference on Machine Learning*, pages 28492–28518, 2023.
- [3] H. Chen Z. Song W. Zhu B. HUANG, X. Wang : VtimeLLM : Empower LLM to grasp video moments. *Dans Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14271–14280, 2024.
- [4] W. Li C. Fang G. Lin R. Yang D. Thalmann C. FAN, X. Zhu : Heterogeneous memory enhanced multimodal attention model for video question answering. *Dans Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 1999–2007, 2019.
- [5] M. M. Islam Z. Wang S. Yu M. Bansal G. Bertasius C. ZHANG, T. Lu : A simple LLM framework for long-range video question-answering. *arXiv preprint*, arXiv :2312.17235, 2023.
- [6] P. Xu S. Iyer J. Sun Y. Mao X. Ma A. Efrat P. Yu L. Yu S. Zhang G. Ghosh M. Lewis L. Zettlemoyer O. Levy C. ZHOU, P. Liu : Lima : Less is more for alignment. *Dans Proceedings of the International Conference on Neural Information Processing Systems*, volume 36, pages 55006–55021. Neural Information Processing Systems, 2023.
- [7] CAPTIONS : Captions tool. [En ligne]. Disponible : <https://www.captions.ai/tools/ai-clip-generator>. Consulté le 2024-11-04.
- [8] E. Park S.-U. Nam N. Kwak D. HAN, S. Seo : Unleash the potential of clip for video highlight detection. *arXiv preprint arXiv :2404.01745*, 2024.
- [9] DESCRIPT : Descript tool. [En ligne]. Disponible : <https://www.descript.com/>. Consulté le 2024-11-04.
- [10] B. Ghanem J. Niebles F. HEILBRON, V. Escorcia : Activitynet : A large-scale video benchmark for human activity understanding. *Dans Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 961–970, 2015.
- [11] FRAMEDROP : Framedrop tool. [En ligne]. Disponible : <https://www.framedrop.ai/>. Consulté le 2024-11-04.
- [12] J. Wang J. Xu Y. Huang J. Pan Y. Wang Y. Wang Y. Qiao T. Lu L. Wang G. CHEN, Y.-D. Zheng : VideoLLM : Modeling video sequence with large language models. *arXiv preprint*, arXiv :2305.13292, 2023.
- [13] Z. Gan X. Du B. Zhang Z. Wang L. Cao S.-F. Chang Y. Yang H. YOU, H. Zhang : Ferret : Refer and ground anything anywhere at any granularity. *arXiv preprint arXiv :2310.07704*, 2023.
- [14] L. Bing H. ZHANG, X. Li : Video-llama : An instruction-tuned audio-visual language model for video understanding. *Dans Proceedings of the Conference on Empirical Methods in Natural Language Processing : System Demonstrations*, pages 543–553. Association for Computational Linguistics, 2023.

-
- [15] K. Kim D. Lee S. Lee S. Ha J. Mun W. Kang B. Roh J. Lee J. CHAE, D. Kim : Towards a complete benchmark on video moment localization. *Dans Proceedings of the International Conference on Artificial Intelligence and Statistics*, volume 238, pages 4168–4176. Machine Learning Research, 2024.
 - [16] L. Zhou Z. Gan T. L. Berg M. Bansal J. Liu J. LEI, L. Li : Less is more : CLIP-BERT for video-and-language learning via sparse sampling. *Dans Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 7327–7337, 2021.
 - [17] M. Bansal J. LEI, T. L. Berg : Qvhighlights : Detecting moments and highlights in videos via natural language queries. *Dans Proceedings of the International Conference on Neural Information Processing Systems*, pages 11846–11858. Neural Information Processing Systems, 2021.
 - [18] W. Xie X. Chen Y. Lu J. XU, C. Lan : Slot-vlm : Slowfast slots for video-language modeling. *arXiv preprint arXiv :2402.13088*, 2024.
 - [19] E. Abdelrahman E. Sleiman D. Zhu J. Ding M. Elhoseiny K. ATAALLAH, X. Shen : Minigt4-video : Advancing multimodal llms for video understanding with interleaved visual-textual tokens. *arXiv preprint arXiv :2404.03413*, 2024.
 - [20] F. Sha K. Grauman K. ZHANG, W.-L. Chao : Video summarization with long short-term memory. *Dans Proceedings of the European Conference on Computer Vision*, pages 766–782. Springer, 2016.
 - [21] KLAP : Klap tool. [En ligne]. Disponible : <https://klap.app>. Consulté le 2024-11-04.
 - [22] E. Shechtman J. Sivic T. Darrell B. Russell L. A. HENDRICKS, O. Wang : Localizing moments in video with natural language. *Dans Proceedings of the IEEE International Conference on Computer Vision*, pages 5804–5813, 2017.
 - [23] D. Létourneau F. Michaud M.-A. MAHEUX, C. Caya : T-top, a sar experimental platform. *Dans Proceedings of the 2022 ACM/IEEE International Conference on Human-Robot Interaction*, pages 904–908, 2022.
 - [24] G. Varol A. Zisserman M. BAIN, A. Nagrani : A clip-hitchhiker’s guide to long video retrieval. *arXiv preprint*, arXiv :2205.08508, 2022.
 - [25] MUNCH : Munch tool. [En ligne]. Disponible : <https://www.getmunch.com>. Consulté le 2024-11-04.
 - [26] OPUSCLIP : Opusclip tool. [En ligne]. Disponible : <https://www.opus.pro>. Consulté le 2024-11-04.
 - [27] POWDER : Powder tool. [En ligne]. Disponible : <https://powder.gg>. Consulté le 2024-11-04.
 - [28] M. Rohrbach J. Feng K. Saenko T. Darrell R. HU, H. Xu : Natural language object retrieval. *Dans Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 4555–4564, 2016.
 - [29] M. Yang J. Dong D. Li P. Lu T. Wang L. Hu M. Qiu Z. Wei R. LUO, Z. Zhao : Valley : Video assistant with large language model enhanced ability. *arXiv preprint arXiv :2306.07207*, 2023.
 - [30] Z. Parekh A. Hauptmann S. GHOSH, A. Agarwal : Excl : Extractive clip localization using natural language descriptions. *Dans Proceedings of the Conference of the*
-

- North American Chapter of the Association for Computational Linguistics : Human Language Technologies, Volume 1*, pages 1984–1990. Association for Computational Linguistics, 2019.
- [31] M. Maaz H. A. Rasheed S. Khan M. Shah F. Khan S. MUNASINGHE, R. Thushara : Pg-video-llava : Pixel grounding large video-language models. *arXiv preprint arXiv :2311.13435*, 2023.
 - [32] A. Chadha E. Culurciello S. N. WADEKAR, A. Chaurasia : The evolution of multi-modal model architectures. *arXiv preprint arXiv :2405.17927*, 2024.
 - [33] J. Fu J. Luo S. ZHANG, H. Peng : Learning 2D temporal adjacent networks for moment localization with natural language. *Dans Proceedings of the AAAI Conference on Artificial Intelligence*, pages 12870–12877, 2020.
 - [34] Y. Zhu C. Xi P. Gao X. Zhou K. C.-C. Chang S. ZHENG, Y. Zhang : Gpt-fathom : Benchmarking large language models to decipher the evolutionary path towards gpt-4 and beyond. *arXiv preprint arXiv :2309.16583v5*, 2023.
 - [35] SENDSHORT : Sendshort tool. [En ligne]. Disponible : <https://sendshort.ai>. Consulté le 2024-11-04.
 - [36] SSEMBLE : Ssemble tool. [En ligne]. Disponible : <https://www.ssemble.com>. Consulté le 2024-11-04.
 - [37] RECAST STUDIO : Recast studio tool. [En ligne]. Disponible : <https://recast.studio>. Consulté le 2024-11-04.
 - [38] S. Belongie J. Hays P. Perona D. Ramanan P. Dollár-C. Zitnick T. LIN, M. Maire : Microsoft coco : Common objects in context. *Dans Proceedings of the European Conference on Computer Vision*, pages 740–755. Springer International Publishing, 2014.
 - [39] H. Chen Z. Zhang Z. Song Y. Zhou W. Zhu W. FENG, X. Wang : LLM4vg : Large language models evaluation for video grounding. *arXiv preprint arXiv :2312.14206*, 2023.
 - [40] L. Luo S. Iyer N. Dong C. Zhou G. Ghosh-M. Lewis W.-t. Yih L. Zettlemoyer X. V. Lin W. LIANG, L. Yu : Mixture-of-transformers : A sparse and scalable architecture for multi-modal foundation models. *Transactions on Machine Learning Research*, 2025.
 - [41] M. Li X. Tang X. Chen B. Zhao Y. GUO, J. Liu : Vtg-LLM : Integrating timestamp knowledge into video LLMs for enhanced video temporal grounding. *arXiv preprint arXiv :2405.13382*, 2024.
 - [42] Y. Wu C. W. Chen Y. Shan X. Qie Y. LIU, S. Li : Umt : Unified multi-modal transformers for joint video moment retrieval and highlight detection. *Dans Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 3032–3041, 2022.
 - [43] Z. Xie Y. Shu S. Du Y. SUN, Y. Xu : Gptsee : Enhancing moment retrieval and highlight detection via description-based similarity features. *Dans Proceedings of the IEEE Signal Processing Letters*, pages 521–525, 2024.
 - [44] D. Doermann Y. TIAN, Q. Ye : Yolov12 : Attention-centric real-time object detectors. *arXiv preprint arXiv :2502.12524*, 2025.
 - [45] J. Liang Y. Wang Q. Liu D. Zhao Y. WANG, X. Meng : Hawkeye : Training video-text LLMs for grounding text in videos. *arXiv preprint arXiv :2403.10228*, 2024.
-

- [46] H. He X. Chang B. Zhuang Y. WENG, M. Han : Longvlm : Efficient long video understanding via large language models. *Dans Proceedings of the European Conference on Computer Vision*, 2024.
 - [47] D. Zhou Z. Huang J. Feng B. Kang Y. ZHAO, Z. Lin : Bubogpt : Enabling visual grounding in multi-modal LLMs. *arXiv preprint arXiv :2307.08581*, 2023.
-