

UNIVERSITÉ DE SHERBROOKE
Faculté de génie
Département de génie électrique et de génie informatique

DÉTECTION DES MOMENTS SAILLANTS D'UNE VIDÉO EN UTILISANT UNE REPRÉSENTATION TEXTUELLE STRUCTURÉE

Mémoire de maîtrise
Spécialité : génie électrique

Alexandre LAFLEUR

Sherbrooke (Québec) Canada

Mars 2026

MEMBRES DU JURY

François GRONDIN

Directeur

François MICHAUD

Évaluateur

François FERLAND

Évaluateur

RÉSUMÉ

Ce mémoire étudie la possibilité de représenter un segment vidéo long par une structure textuelle suffisamment riche pour permettre à un grand modèle de langage textuel d'identifier automatiquement un moment saillant. La contribution centrale du travail est un pipeline qui transforme un segment vidéo en représentation textuelle structurée combinant transcription, segmentation en scènes, association personnes-visages-locuteurs, indices de cadrage et résumés visuels issus d'un modèle vision-langage. Cette représentation est ensuite utilisée comme contexte d'entrée pour un modèle sélectionneur de clips.

L'évaluation repose sur un benchmark de 29 paires composées d'un segment source et d'un clip de référence correspondant. Les résultats consolidés actuellement montrent qu'une condition textuelle structurée complète atteint un score combiné moyen de 0.301 sur l'ensemble complet, contre 0.273 pour une condition baseline en entrée vidéo directe. Le mémoire adopte un format combiné centré sur un article unique; les chapitres entourant l'article situent la contribution, documentent le benchmark et discutent le transfert vers une application de production.

Mots-clés : Intelligence artificielle, LLM, analyse vidéo, représentation textuelle, benchmark

ABSTRACT

Salient Moment Detection in Long Videos with a Structured Textual Representation

This memoir studies whether a long video segment can be converted into a structured textual representation rich enough for a text-only large language model to automatically recover a salient moment. The core contribution is a pipeline that converts video into structured text by combining transcription, scene segmentation, person-face-speaker association, camera-focus cues, and visual summaries produced by a vision-language model. The resulting representation is then used as context for a clip-selection model.

Evaluation currently relies on a benchmark of 29 source-segment / reference-clip pairs. Consolidated results show that the full structured-text condition reaches a mean combined score of 0.301 on the complete set, compared with 0.273 for a direct-video baseline. The memoir follows a combined format centered on one article; the surrounding chapters position the contribution, document the benchmark, and discuss transfer toward a production application.

Keywords: artificial intelligence, LLM, video analysis, textual representation, benchmark

REMERCIEMENTS

Ce fichier contient un espace réservé pour les remerciements finaux. Remplacer ce texte par une version d'une page maximum avant le dépôt.

TABLE DES MATIÈRES

1	Introduction	1
1.1	Mise en contexte et problématique	1
1.2	Question de recherche	2
1.3	Objectifs du projet de recherche	2
1.4	Contributions originales	3
1.5	Plan du document	3
2	Etat de l’art	5
2.1	Modélisation vidéo-textuelle et multimodale pour la sélection de clips . . .	5
2.2	Localisation et segmentation temporelle des moments clés	7
2.3	Détection des faits saillants et filtrage du bruit	7
2.4	Fusion multimodale et alignement pour une narration cohérente	8
2.5	Optimisation des modèles et traitement des vidéos longues	9
2.6	Analyse comparative approfondie des solutions existantes et différenciations de la solution proposée	10
2.7	Conclusion de l’état de l’art	12
3	Articulation du memoire combine	13
3.1	Pourquoi un memoire combine centré sur un seul article	13
3.2	Lien entre l’article, l’infrastructure de représentation et l’application	13
3.3	Ce que l’article couvre, et ce que le memoire ajoute	14
3.4	Etat actuel des preuves	14
4	Article central	15
4.1	Introduction	16
4.2	Travaux connexes	16
4.3	Jeu d’évaluation et construction des données	17
4.4	Chaîne de prétraitement multimodal	18
4.5	Représentation textuelle structurée	18
4.6	Configuration du sélectionneur et métriques d’évaluation	19
4.7	Résultats quantitatifs	20
4.8	Analyse des échecs et discussion	23
4.9	Conclusion	23
5	Discussion generale et transfert	27
5.1	Retour sur le DPR	27
5.2	Portée des résultats actuels	27
5.3	Enseignements complémentaires sur l’ajustement fin	28
5.4	Lien avec l’application de production	28
5.5	Limites et menaces a la validité	29
5.6	Travaux futurs	30

6	Conclusion generale	31
6.1	Réponse à la question de recherche	31
6.2	Contributions validées par le mémoire	31
6.3	Perspectives	32
LISTE DES RÉFÉRENCES		33

LISTE DES FIGURES

4.1	Vue d'ensemble du pipeline proposé, depuis le segment source jusqu'au span final sélectionné.	17
4.2	Exemple concret de transformation d'une vidéo en contexte structuré, puis en span sélectionné par le modèle.	20
4.3	Comparaison de deux cas de succès et de deux cas d'échec du meilleur run structuré complet. Les succès combinent recouvrement thématique et calibration temporelle ; les échecs gardent parfois un signal sémantique partiel mais ratent la bonne fenêtre temporelle.	24
5.1	Positionnement respectif du DPR, de l'article central et du transfert vers l'application de production.	29

LISTE DES TABLEAUX

1.1	Correspondance entre les contributions et les chapitres du mémoire	4
4.1	Statistiques descriptives du benchmark validation29	18
4.2	Composantes principales du pipeline et sorties persistées	19
4.3	Variantes de contexte disponibles sur l'ensemble complet	19
4.4	Synthèse des pilotes exploratoires utilisés pour faire évoluer la représentation	21
4.5	Jalons où un changement de représentation ou de prompt améliore le meilleur score exploratoire connu	22
4.6	Conditions complètes sur 29 échantillons retenues pour les revendications principales	22
4.7	Comparaison contrôlée sous Gemini 3.1 Flash Lite : même modèle, même protocole de sortie, et variation explicite de la représentation d'entrée . . .	23
4.8	Impact du fine-tuning sur les petites variantes Gemini 2.5, avec les mêmes 29 cas de validation lorsqu'ils sont disponibles	23
4.9	Premiers essais d'augmentation visuelle par objets dans le contexte textuel	25
4.10	Comparaison des variantes Gemini 2.5 Pro : base, fine-tuning et entrée vidéo directe	25
4.11	Taxonomie initiale des échecs à valider dans l'analyse qualitative	26

LISTE DES ACRONYMES

LLM	Grand modèle de langage
IA	Intelligence artificielle
VTG	Ancrage temporel dans la vidéo (<i>Video Temporal Grounding</i>)
TAN	Réseaux temporels adjacents (<i>Temporal Adjacent Networks</i>)
LLoVi	Questions-réponses vidéo (<i>Language-based Long-range Video question answering</i>)
ExCL	Localisation extractive de segments vidéo (<i>Extractive Clip Localization</i>)
QD-DETR	Transformeur de détection adaptatif (<i>Query-Dependent DETection TRansformer</i>)
VLM	Modèle vision-langage
TOON	Token-Oriented Object Notation
IoU	Intersection over Union
ASD	Active Speaker Detection
API	Interface de programmation applicative
GT	Ground truth / référence annotée

CHAPITRE 1

Introduction

L’analyse de longues vidéos pose un problème assez simple à comprendre. Plus la vidéo est longue, plus il faut traiter d’information. Les synthèses de Tang et al. [36], de Zhou et al. [48] et de Wadekar et al. [37] montrent que, si l’on utilise directement un modèle multimodal pour tout analyser, le coût en calcul, en jetons et en argent monte rapidement. Cela devient vite difficile à justifier dans des contextes où les ressources sont limitées, par exemple pour un service qui doit traiter beaucoup de vidéos, ou pour un système embarqué qui ne dispose pas d’une grosse capacité de calcul.

Le problème n’est pas que les approches multimodales directes ne fonctionnent pas. Au contraire, elles sont puissantes. Le problème est plutôt qu’elles sont lourdes. The Evolution of Multimodal Model Architectures [37] montre bien que leur architecture est plus complexe qu’un grand modèle de langage textuel, parce qu’elles doivent encoder plusieurs modalités puis les fusionner. Mixture-of-Transformers [23] va dans le même sens : cette complexité entraîne plus de calcul, plus de coût et une difficulté plus grande à les utiliser dans des systèmes contraints. Si l’objectif est de choisir un bon moment dans une vidéo, il devient alors légitime de se demander s’il est vraiment nécessaire de garder toute cette complexité jusqu’au dernier moment.

Le point de départ de ce mémoire est justement là. L’idée est de déplacer une partie du travail d’analyse vers une représentation textuelle structurée de la vidéo, puis de laisser le choix final à un modèle textuel. Autrement dit, au lieu de demander au modèle final de regarder directement la vidéo, on lui donne une version textuelle organisée de ce que la vidéo contient. L’hypothèse est qu’une telle représentation peut conserver l’information utile tout en coûtant moins cher à exploiter qu’une entrée vidéo directe, même si des travaux comme Video-LLaMA [44], VTimeLLM [17] et VTG-LLM [12] montrent déjà la force des approches multimodales directes.

1.1 Mise en contexte et problématique

Une transcription brute ne suffit pas toujours. Elle garde les paroles, mais elle perd beaucoup de ce qui rend un moment fort dans une vidéo : les changements de scène, les personnes visibles, certains gestes, le cadrage ou le contraste entre ce que l’on voit et ce que l’on entend. Si l’on veut qu’un modèle textuel fasse un bon travail, il faut donc lui donner plus qu’une simple transcription. En même temps, si on lui donne trop d’information ou une information mal organisée, le contexte devient lourd, bruyant et plus difficile à utiliser.

La vraie question du mémoire est donc la suivante : comment transformer une vidéo en texte de manière assez riche pour garder les bons indices, mais assez claire et assez compacte pour que le modèle final puisse encore prendre une bonne décision ?

Pour répondre à cette question, le mémoire utilise la détection de moments saillants comme tâche de validation. Cette tâche est un bon choix parce qu'elle est concrète, exigeante et mesurable. Localizing Moments in Video with Natural Language [15], ExCL [11], QVHighlights [18] et Towards a Complete Benchmark on Video Moment Localization [5] montrent bien qu'il ne suffit pas de comprendre de quoi parle une vidéo. Il faut aussi être capable de choisir un bon passage et de le situer correctement dans le temps. Si la représentation texte est mauvaise, l'erreur se voit tout de suite dans l'extrait choisi.

1.2 Question de recherche

La question de recherche du mémoire peut être formulée ainsi :

Comment représenter une longue vidéo sous forme textuelle de manière assez fidèle et assez structurée pour qu'un grand modèle de langage puisse identifier un moment saillant avec une qualité comparable à une approche multimodale directe, tout en consommant beaucoup moins de ressources ?

Cette question a deux dimensions. La première porte sur la représentation elle-même : qu'est-ce qu'il faut garder de la vidéo, sous quelle forme, et avec quel niveau de détail ? La deuxième porte sur l'utilisation de cette représentation : est-ce qu'un modèle textuel peut vraiment s'en servir pour choisir le bon moment ?

L'article central du mémoire traite cette question en insistant davantage sur la représentation comme état textuel durable. Le mémoire, dans son ensemble, garde un angle un peu plus large : le compromis entre qualité de sélection, coût et possibilité de déploiement dans des systèmes contraints.

1.3 Objectifs du projet de recherche

L'objectif général est de montrer qu'une représentation textuelle structurée peut servir de support principal à la sélection de moments saillants dans de longues vidéos, avec une performance compétitive et un coût plus faible qu'une entrée vidéo directe.

Cet objectif se décline en plusieurs sous-objectifs :

1. construire une chaîne de traitement capable de transformer une vidéo en données textuelles et temporelles persistantes ;
 2. définir une représentation textuelle structurée qui conserve l'ordre temporel, les scènes, le dialogue et certains indices visuels ;
-

3. mettre en place un jeu d'évaluation reproductible et une base de données permettant de comparer plusieurs représentations, plusieurs consignes et plusieurs familles de modèles ;
4. mesurer le compromis entre qualité de sélection, volume de contexte, temps de réponse et coût ;
5. examiner, dans une campagne complémentaire, si l'ajustement fin de modèles plus petits peut lui aussi servir à déplacer une partie du calcul vers l'amont.

Ces objectifs ne sont plus seulement des intentions. La chaîne a été construite, le jeu `validation29` a été monté, plusieurs conditions ont été comparées, et une campagne historique sur l'ajustement fin des modèles Gemini a pu être réintégrée à l'analyse.

1.4 Contributions originales

Les contributions du mémoire se situent à plusieurs niveaux. La première est la construction d'une chaîne locale qui transforme la vidéo en texte structuré exploitable par un modèle textuel. La deuxième est la mise en place d'un jeu d'évaluation reproductible, avec une base SQLite qui conserve les contextes, les exécutions, les coûts et les scores.

La troisième contribution est la comparaison elle-même. Le mémoire ne se contente pas de montrer qu'une représentation texte est possible. Il montre aussi ce qu'elle vaut par rapport à une entrée vidéo directe, par rapport à une variante sans descriptions visuelles, et par rapport à une simple transcription. Il ajoute en plus une lecture complémentaire sur l'ajustement fin, pour montrer qu'il existe une autre manière de déplacer le calcul.

Enfin, le travail a aussi une contribution pratique. Une partie des abstractions construites pour le jeu d'évaluation a à nouveau été utilisée dans `mecene-clips`. Cela ne remplace pas la validation scientifique, mais cela montre que la méthode est assez stable pour sortir du cadre purement expérimental.

1.5 Plan du document

Le chapitre 2 présente l'état de l'art et situe le travail par rapport à la détection de moments saillants, aux approches multimodales sur vidéos longues et aux représentations intermédiaires. Le chapitre 3 explique la logique du mémoire combiné et la manière dont l'article, le jeu d'évaluation et l'application s'articulent.

Le chapitre 4 contient l'avant-propos exigé par le protocole, puis l'article central. C'est là que sont présentés la méthode, la représentation, le jeu d'évaluation et les principaux résultats. Le chapitre 5 revient ensuite sur la portée de ces résultats, sur la campagne complémentaire d'ajustement fin et sur le transfert vers le produit. Enfin, le chapitre 6 résume les contributions validées par le mémoire et ouvre sur les prolongements les plus importants.

TABLEAU 1.1 Correspondance entre les contributions et les chapitres du mémoire

Contribution	Preuve principale	Emplacement principal
Pipeline multimodal vers texte structuré	Code du benchmark et description méthodologique	Chapitres 3 et 4
Benchmark <code>validation29</code> reproductible	Base SQLite, scripts de préparation et d'exécution	Chapitres 3 et 4
Comparaison structuré-texte vs entrée vidéo directe	Exécutions complètes sur 29 échantillons	Chapitre 4
Transfert vers une application de production	Intégration dans <code>mecene-clips</code>	Chapitre 5

CHAPITRE 2

Etat de l’art

L’état de l’art conserve ici presque entièrement la synthèse présentée dans le DPR. C’est volontaire. Cette partie du projet était déjà bien posée, et il n’y avait pas lieu de la réécrire en profondeur pour le mémoire. Nous gardons donc le corps de cette synthèse presque mot pour mot, puis nous ajoutons seulement quelques points cibles qui sont devenus importants à la lumière des résultats obtenus pendant la maîtrise.

Depuis la rédaction du DPR, trois enseignements méritent toutefois d’être explicites. D’abord, *Lost in the Middle* [24] montre que le simple fait de disposer d’un long contexte ne garantit pas que le modèle saura retrouver et utiliser l’information utile au bon endroit. Ensuite, *SHED* [14] suggère qu’un ajustement fin peut gagner beaucoup en efficacité lorsque les données sont bien choisies. Enfin, *Revisiting Catastrophic Forgetting in Large Language Model Tuning* [21] montre qu’un ajustement fin peut aussi nuire à des capacités déjà acquises lorsqu’il spécialise trop fortement un grand modèle. Ces ajouts ne remplacent pas l’état de l’art du DPR ; ils servent seulement à mieux relier cette synthèse aux résultats du mémoire.

Les travaux présentés dans cette synthèse ont été sélectionnés pour leur pertinence dans l’adaptation des méthodes d’analyse vidéo aux ressources limitées des plateformes robotiques. La conversion des données audiovisuelles en représentations textuelles pour traitement par des modèles de langage offre une alternative aux approches multimodales traditionnelles comme *MiniGPT4-Video* [2] et *Video-LLaMA* [44], qui nécessitent des ressources computationnelles importantes. En se concentrant sur la fidélité et l’exhaustivité de la représentation textuelle, ces travaux visent à démontrer que les modèles de langage peuvent identifier efficacement les moments clés d’une vidéo, même en l’absence de traitement visuel direct.

2.1 Modélisation vidéo-textuelle et multimodale pour la sélection de clips

Pour réussir à trouver les moments saillants d’une vidéo, une intelligence artificielle (IA) pourrait devoir analyser et comprendre le contenu vidéo, non seulement en termes de ce qui est vu à l’écran, mais également en intégrant les éléments textuels et auditifs de la vidéo. Cette étape explore les modèles et techniques vidéo-textuelles et multimodales qui permettent d’enrichir la pertinence et la précision de la sélection des segments dans le cadre de l’automatisation du montage.

Des modèles comme CLIP [3] (*Contrastive Language Image Pre-training*) et BuboGPT [47] jouent un rôle fondamental dans la correspondance entre le contenu visuel et les descriptions textuelles.

CLIP a été développé pour relier directement des images à des textes, permettant une correspondance directe entre des concepts visuels et des descriptions narratives. Cette capacité est précieuse pour un résumé automatique, car elle permettrait de sélectionner les segments visuels les plus pertinents par rapport aux requêtes textuelles ou aux tendances narratives [6][11]. Cependant, CLIP est principalement entraîné sur des images statiques, ce qui limite sa capacité à traiter efficacement les dimensions temporelles et narratives des vidéos.

Dans un montage vidéo, la continuité visuelle et le contexte narratif sont essentiels, et cette lacune peut réduire la pertinence des segments identifiés. BuboGPT, quant à lui, renforce cette capacité en ajoutant une couche d'ancrage visuel, permettant une identification et une localisation précises des objets dans chaque image en fonction des descriptions textuelles [9][27]. Par exemple, une scène de nature pourrait être identifiée et extraite si elle est associée à un texte comme « aventure en plein air ». Cette granularité fine est un atout, mais elle dépend fortement de la qualité des descriptions textuelles fournies. Si les textes sont vagues, ambigus ou contradictoires, le modèle risque de sélectionner des segments non pertinents, réduisant ainsi l'efficacité du montage.

Si l'image et le texte offrent des informations importantes pour la sélection des segments, l'intégration de l'audio permet une compréhension encore plus riche de la vidéo [44][13]. Les modèles Valley [26] et Video-LLaMA [44] démontrent comment des signaux auditifs peuvent être exploités en parallèle des indices visuels et textuels pour un alignement complet des modalités. Valley utilise un alignement multimodal qui intègre des signaux audio pour fournir une compréhension contextuelle approfondie des vidéos [17], tandis que Video-LLaMA emploie des modules spécialisés qui séparent et intègrent les indices visuels et auditifs en requêtes interprétables par les modèles de langage [41]. Cette approche permet de prendre en compte des éléments sonores tels que les dialogues, les changements d'intonation et la musique, qui influencent fortement l'engagement émotionnel et narratif.

Cependant, l'efficacité de ces modèles dépend de la qualité des signaux audio disponibles. Par exemple, dans des environnements bruités ou des vidéos amateurs, la performance de Valley peut diminuer, compromettant ainsi la précision de l'analyse contextuelle. De plus, Video-LLaMA, bien que très performant, est coûteux en termes de calcul, ce qui peut le rendre moins adapté à des vidéos longues ou à des systèmes nécessitant des réponses en temps réel. La fusion multimodale de ces approches (image-texte-audio) ouvre la voie à une sélection de clips qui ne se limite pas aux caractéristiques visuelles d'une vidéo, mais qui intègre une compréhension complète des signaux auditifs et textuels [38][15].

Néanmoins, l'intégration de multiples modalités peut également introduire des biais ou des conflits entre les signaux. Par exemple, une musique dramatique superposée à des visuels calmes pourrait créer une ambiguïté dans l'interprétation de la scène. La capacité des modèles à hiérarchiser ces signaux ou à arbitrer entre eux reste un défi à relever.

2.2 Localisation et segmentation temporelle des moments clés

Pour garantir une continuité narrative et un résumé fluide, il faut être capable d'identifier non seulement les moments clés dans une vidéo, mais également leurs limites temporelles précises. Les techniques de localisation temporelle et de segmentation des vidéos jouent ici un rôle essentiel, permettant à l'IA de découper les séquences tout en conservant leur sens et en respectant la chronologie narrative. Cette section explore les approches avancées de segmentation temporelle et de localisation des moments clés, nécessaires pour une sélection précise et cohérente.

Les modèles comme VTimeLLM [17] et VTG-LLM (*Video Temporal Grounding*) [12] apportent des solutions novatrices pour la délimitation précise des segments vidéo en intégrant des indicateurs temporels explicites. VTimeLLM, par exemple, utilise une stratégie d'entraînement en plusieurs étapes pour renforcer la précision temporelle, permettant de mieux comprendre les débuts et fins des segments d'intérêt [13][20]. VTG-LLM, quant à lui, exploite des incorporations (*embeddings*) de séquence-temps et des jetons de temps absolus pour ancrer précisément les moments dans le temps, évitant ainsi les erreurs de quantification qui peuvent survenir dans des vidéos complexes ou de longue durée [12][42].

Cette intégration de l'horodatage permet au modèle de maintenir une continuité temporelle, essentielle pour les montages vidéo nécessitant une précision d'alignement entre les scènes. Ces modèles démontrent l'importance de la localisation temporelle dans les vidéos longues. En intégrant l'horodatage de manière explicite, il serait alors possible non seulement de sélectionner les moments clés avec une plus grande précision, mais aussi de s'assurer que chaque segment est correctement positionné dans l'ordre narratif, évitant ainsi les coupures abruptes ou incohérentes [20][15].

Pour organiser les segments dans un ordre fluide, des modèles comme le *Moment Context Network* (MCN) [15] et 2D-TAN (*Temporal Adjacent Networks*) [46] utilisent des techniques de cartographie temporelle et contextuelle. MCN associe des caractéristiques locales et globales pour identifier des débuts et fins de moments spécifiques, en analysant non seulement chaque segment individuellement, mais aussi en tenant compte du contexte général de la vidéo [45][8]. 2D-TAN adopte une approche de cartographie bidimensionnelle pour modéliser les relations temporelles entre segments adjacents, garantissant ainsi que chaque segment sélectionné conserve une continuité narrative par rapport aux autres [16][46].

2.3 Détection des faits saillants et filtrage du bruit

Pour être capable de repérer les moments saillants et de filtrer les segments de moindre intérêt ou redondants, plusieurs modèles ont été explorés. Ils se concentrent sur la détection des faits

saillants et l'élimination des segments non pertinents, permettant ainsi une sélection précise des passages qui ont le plus de chances d'être intéressants.

HL-CLIP [13] et GPTSee [35] sont deux modèles innovants pour la détection des faits saillants. HL-CLIP utilise une technique de regroupement par saillance (*saliency pooling*) pour stabiliser la détection de moments intéressants en moyennant les scores de saillance à travers plusieurs trames adjacentes. Cette approche permet une détection plus robuste des segments pertinents, même dans des séquences complexes, et évite les sélections incohérentes [42][35]. GPTSee, quant à lui, repose sur une analyse de similarité sémantique entre les descriptions des images extraites et les requêtes textuelles pour identifier les moments saillants les plus engageants [35][25].

En ajoutant un filtrage sémantique, GPTSee affine la sélection pour ne retenir que les segments en lien direct avec les thèmes ou intentions de la narration. HL-CLIP et GPTSee démontrent comment la détection de faits saillants peut être renforcée par des scores de similarité et de saillance, améliorant ainsi la pertinence des extraits retenus pour le montage.

Dans le domaine du filtrage de contenu, LLoVi (*Language-based Long-range Video question answering framework*) [43] propose une méthode de résumé multi-étapes pour éliminer le bruit et affiner la qualité des segments choisis [26][8]. L'approche de LLoVi consiste à générer des descriptions textuelles pour chaque clip court, puis à les résumer en plusieurs étapes pour éliminer les informations redondantes ou non pertinentes. Ce processus de résumé successif permet de concentrer l'attention sur les passages ayant la plus forte valeur narrative.

2.4 Fusion multimodale et alignement pour une narration cohérente

Pour maximiser les chances qu'un passage vidéo soit réellement l'un de ses moments forts, il pourrait être utile d'intégrer des informations provenant de plusieurs modalités en une seule structure cohérente, qu'elles soient visuelles, textuelles ou auditives. La fusion multimodale et l'alignement des informations semblent donc essentiels pour sélectionner des clips à fort potentiel d'être intéressants. Dans cette section, nous explorons les techniques qui permettent d'enrichir la narration vidéo en utilisant des approches multimodales sophistiquées.

Les modèles UMT (*Unified Multi-modal Transformers*) [25] et Slot-VLM [41] offrent des solutions complètes pour intégrer des informations visuelles, textuelles et auditives dans une seule structure cohérente. UMT exploite les données audio et visuelles pour extraire des moments spécifiques en fonction des requêtes textuelles, en intégrant un générateur et un décodeur de requêtes pour transformer les attentes narratives en points de détection temporels [25]. Cette méthode de fusion permet de traiter les vidéos comme un ensemble multimodal complet, assurant que les segments sélectionnés tiennent compte de tous les signaux disponibles.

Slot-VLM [41] introduit une autre dimension avec son système de *SlowFast Slots*, qui décompose les vidéos en jetons centrés sur les objets (*slow-slots*) et jetons centrés sur les événements (*fast-slots*). Cette technique permet d’adapter l’analyse des vidéos selon la fréquence d’apparition des objets et la dynamique temporelle des événements, en maintenant une cohérence entre les objets fixes et les mouvements rapides. Cette approche est particulièrement utile pour une narration fluide, car elle prend en compte les éléments stables, comme les décors, et les éléments en mouvement, assurant une transition naturelle entre les segments.

Les modèles ExCL (*Extractive Clip Localization*) [11] et QD-DETR (*Query-Dependent DETection TRansformer*) [35] permettent d’adapter dynamiquement les choix de segments en fonction des descriptions narratives et des requêtes textuelles. ExCL utilise une approche extractive qui prédit les trames de début et de fin en fonction de la pertinence avec les descriptions narratives. Ceci permet de sélectionner des segments qui s’alignent étroitement avec les attentes narratives, assurant que chaque clip choisi apporte une valeur ajoutée à la continuité de l’histoire.

QD-DETR utilise un encodeur à attention croisée qui intègre explicitement les requêtes dans la représentation des clips vidéo, offrant un niveau d’adaptabilité élevé pour correspondre précisément aux intentions narratives des spectateurs [18]. Grâce à un mécanisme d’appariement flexible, il est possible de discriminer entre les segments en fonction de la demande, filtrant les moments qui ne correspondent pas aux critères recherchés.

2.5 Optimisation des modèles et traitement des vidéos longues

Pour les vidéos de longue durée, il serait essentiel d’optimiser les ressources sans compromettre la précision de la sélection des segments. Il faudrait non seulement pouvoir identifier les moments clés dans des vidéos longues, mais aussi le faire de manière efficace et rapide. Les modèles suivants se concentrent sur des techniques d’optimisation qui permettent un traitement plus rapide et moins gourmand en ressources, tout en maintenant une sélection de clips pertinente.

Les modèles LongVLM [39] et *Less is More*(CLIPBERT) [20] mettent en avant des techniques d’échantillonnage éparses et de segmentation optimisée pour éviter le traitement de chaque trame dans les vidéos longues. LongVLM segmente les vidéos longues en clips courts et extrait pour chaque segment les caractéristiques locales, avant de les fusionner dans un contexte global [39]. Cette approche réduit le volume de données à traiter tout en maintenant une compréhension précise des segments.

Less is More(CLIPBERT), quant à lui, utilise un échantillonnage éparses pendant l’entraînement pour capturer les informations essentielles tout en réduisant les besoins en mémoire. Lors de l’inférence, CLIPBERT applique un échantillonnage dense, permettant ainsi de conserver un haut niveau de précision dans la sélection des moments saillants sans traiter chaque trame individuel-

lement [20]. En utilisant des méthodes d'échantillonnage et de segmentation, il serait possible de traiter les vidéos longues de manière efficace, en s'assurant que seuls les segments pertinents sont extraits. Par exemple, dans un enregistrement de caméra de surveillance ou dans un flux vidéo de la caméra embarquée d'un robot de plusieurs heures, cette optimisation permettrait de cibler des moments clés sans engorger les ressources de traitement.

Les modèles VTG-LLM [12] et VTimeLLM [17] utilisent des techniques de compression des données visuelles pour réduire la surcharge de traitement sans sacrifier la qualité de l'information. VTG-LLM introduit une compression par compartiment (*slot*) qui regroupe les informations visuelles en blocs, permettant un échantillonnage étendu avec une capacité de traitement plus élevée [12]. Cette technique est particulièrement utile pour les vidéos longues et complexes, où chaque bloc compressé conserve des détails essentiels pour la narration.

VTimeLLM, de son côté, utilise une stratégie d'entraînement par étapes pour améliorer la localisation temporelle dans des vidéos longues, permettant ainsi de mieux appréhender les séquences d'événements sans pertes de données importantes [17]. Grâce à des jetons compressés, ce modèle permet de traiter des vidéos volumineuses tout en conservant une précision optimale. En utilisant des techniques de compression et de traitement par *slots*, il serait possible de gérer de grandes quantités de données sans ralentir le processus de sélection, tout en assurant la précision nécessaire pour maintenir l'intérêt narratif et visuel des clips.

Ainsi, les techniques d'optimisation proposées par LongVLM [39], *Less is More*(CLIPBERT) [20], VTG-LLM [12], et VTimeLLM [17] permettent de réduire considérablement la complexité de traitement dans des vidéos longues, tout en maintenant la qualité de sélection des segments pertinents.

Depuis la rédaction du DPR, *Lost in the Middle* [24] ajoute toutefois une nuance importante à cette famille d'approches. Réduire, compresser ou structurer le contexte ne sert pas seulement à faire entrer l'information dans la fenêtre du modèle. Cela sert aussi à augmenter les chances que l'information utile soit effectivement retrouvée et exploitée au bon endroit. Ce point éclaire directement les résultats du mémoire, où l'ajout de davantage de texte visuel n'améliore pas automatiquement la sélection finale.

2.6 Analyse comparative approfondie des solutions existantes et différenciations de la solution proposée

Les plateformes d'édition vidéo automatisée reposent sur une série de technologies et d'approches IA variées pour analyser, sélectionner et transformer des vidéos longues en clips courts adaptés aux réseaux sociaux. Descript [7] se distingue dans le domaine de l'édition vidéo en proposant une interface qui permet de modifier directement le contenu vidéo à partir de la transcription texte, une innovation qui rend l'édition de contenu aussi intuitive que la modification d'un document

texte. En intégrant une transcription rapide et précise des fichiers audio et vidéo, Descript simplifie la création de contenu en offrant une base textuelle pour éditer et réviser les enregistrements. La simplicité d'utilisation et la rapidité de la transcription permettent aux utilisateurs d'éditer les vidéos de manière efficace, sans avoir à manipuler directement les clips vidéo. Cette approche basée sur le texte, bien que puissante, enlève tout l'aspect visuel de la vidéo et requiert souvent une deuxième édition visuelle pour les détails plus fins.

Captions.ai [4], 2short.ai [1], Ssemble [33] et OpusClip [29] automatisent l'extraction des moments clés d'une vidéo en analysant des indicateurs d'engagement et de viralité pour sélectionner les segments qui ont le plus de potentiel de capter l'attention d'une personne qui regarde la vidéo. Ces outils scannent le contenu vidéo et identifient automatiquement les moments saillants en fonction de critères préétablis, offrant aux créateurs un moyen rapide de créer des clips engageants. Ces technologies permettent un gain de temps considérable pour les créateurs de contenu, réduisant la nécessité d'explorer manuellement la vidéo pour trouver les moments engageants.

2short.ai [1], Framedrop [10], Powder [30] et Munch [28] se concentrent sur des techniques de détection et de retouche visuelle, comme le suivi facial ou l'ajout d'effets visuels et sonores. Par exemple, 2short.ai utilise la technologie de suivi facial pour garder le focus sur les intervenants principaux, ce qui améliore l'impact visuel, tandis que Powder [30] se concentre sur les enregistrements de jeux vidéo en détectant les moments d'action et en appliquant des modèles de montage spécifiques au contenu de jeu. Ces outils permettent d'améliorer l'impact visuel en utilisant des ajustements centrés sur les éléments clés, comme les visages ou les objets importants, tout en optimisant la vidéo pour des plateformes spécifiques. Par contre, ces fonctionnalités peuvent être restreintes à des types de contenu particuliers, ce qui limite leur utilisation pour des vidéos plus variées.

Klap [19], SendShort [32] et Recast Studio [34] permettent aux utilisateurs de personnaliser les clips en ajoutant des effets visuels et des légendes afin de renforcer l'identité visuelle du contenu. Bien que chaque plateforme offre des options de personnalisation, elles sont souvent limitées à des ajustements de base et peuvent nécessiter des compétences en édition pour des modifications avancées. Cette personnalisation permet aux utilisateurs de mettre encore plus en valeur une partie de la vidéo, comme pour un robot qui voudrait mettre un carré rouge autour de la chose précise qu'il a remarquée qu'était anormale.

Ces plateformes d'édition vidéo automatisée présentent des avantages notables qui les rendent intéressants pour des utilisateurs voulant générer rapidement des clips à partir de longs vidéos. La majorité des plateformes existantes offrent une interface intuitive, simplifiant l'édition vidéo même pour les utilisateurs novices. L'automatisation des tâches de segmentation, d'extraction de moments clés et d'ajout de sous-titres réduit le besoin de compétences avancées en montage vidéo. Ceci rend ces plateformes idéales pour ceux qui souhaitent produire rapidement des clips sans maîtriser les outils d'édition traditionnels.

Les outils d'ajustement et d'optimisation sont spécifiquement conçus pour maximiser l'attention, en créant des clips dynamiques qui captent l'attention de l'audience. Un robot qui génère un clip de ce genre aurait plus de chance que son clip soit écouté au complet, ce qui maximiserait le transfert d'information humain-machine. Avec la mondialisation du contenu numérique, plusieurs plateformes, comme Captions.ai [4], OpusClip [29] et Framedrop [10], ont intégré le support de plusieurs langues. Cette fonctionnalité permet aux utilisateurs de s'adresser à des audiences diversifiées et d'augmenter leur portée. Les plateformes sont capables de générer des sous-titres dans plusieurs langues et d'inclure des options de traduction, rendant le contenu plus accessible et inclusif.

Les résultats de la maîtrise ajoutent ici un deuxième levier qui n'était pas encore visible dans le DPR. SHED [14] montre qu'un ajustement fin bien ciblé peut gagner beaucoup en efficacité lorsque les données sont bien choisies, alors que Revisiting Catastrophic Forgetting in Large Language Model Tuning [21] rappelle qu'un ajustement fin peut aussi nuire lorsqu'il spécialise trop fortement un grand modèle. Cette double lecture aide à situer la campagne complémentaire menée sur plusieurs variantes Gemini : pour certains modèles, l'amélioration vient d'un meilleur alignement ; pour d'autres, elle vient plutôt d'un meilleur contexte.

2.7 Conclusion de l'état de l'art

L'état de l'art du DPR faisait déjà ressortir un point central : il existe de nombreuses approches prometteuses pour représenter, segmenter, filtrer et résumer des vidéos longues, mais ces approches restent souvent coûteuses, multimodales et difficiles à utiliser telles quelles dans des systèmes contraints. Les ajouts récents ne changent pas ce constat. Ils le précisent. Lost in the Middle [24] rappelle que la forme du contexte compte autant que sa richesse. SHED [14] et Revisiting Catastrophic Forgetting in Large Language Model Tuning [21] montrent de leur côté que le compromis entre contexte et ajustement fin dépend aussi de la taille du modèle. C'est exactement dans cette lacune que s'inscrit le mémoire : comparer des représentations textuelles issues d'une chaîne multimodale à une entrée vidéo directe, tout en mesurant leur coût et leur réutilisabilité dans le temps.

CHAPITRE 3

Articulation du memoire combine

Ce chapitre sert à clarifier la structure du document. Le point important est simple : le coeur scientifique du travail tient dans un seul article, mais le mémoire reste nécessaire pour expliquer d'où vient la question, ce que l'article couvre, ce qu'il ne couvre pas, et pourquoi l'ensemble forme un seul projet cohérent.

3.1 Pourquoi un memoire combine centré sur un seul article

Le format retenu est un mémoire combiné centré sur un seul article. Ce choix vient directement de la nature du projet. Il n'y a pas ici plusieurs contributions indépendantes qui justifieraient plusieurs articles distincts. Il y a une seule question centrale, un seul jeu d'évaluation principal, une seule chaîne de traitement et une seule famille de représentations à comparer. Tout cela forme un bloc scientifique unique.

L'article suffit donc pour porter la preuve expérimentale principale. Il permet de montrer comment la vidéo est transformée en texte, comment cette représentation est utilisée, et quels résultats elle donne sur le jeu `validation29`. Le mémoire, de son côté, garde un rôle essentiel : il reprend la logique du DPR, situe le travail dans une perspective plus large de coût et de ressources, et discute la portée du projet au-delà de la seule expérience centrale.

3.2 Lien entre l'article, l'infrastructure de représentation et l'application

L'article repose directement sur l'infrastructure du dossier `benchmark` dans `mecene-clips`. C'est là que se trouvent le jeu d'évaluation, les contextes, les profils de modèles, les exécutions et les coûts. Cette infrastructure n'est pas un simple détail d'implémentation. Elle fait partie de la contribution, parce qu'elle rend la comparaison reproductible et permet de suivre proprement les itérations qui ont mené à la représentation retenue.

L'application `mecene-clips` joue un autre rôle. Elle montre que les choix faits pour le benchmark peuvent aussi vivre dans un produit. Cela donne du poids à l'idée que la représentation construite est assez stable pour être réutilisée dans un vrai système logiciel. Il faut toutefois garder la distinction suivante : le benchmark sert à prouver scientifiquement quelque chose ; l'application sert à montrer que ce quelque chose peut être transféré.

3.3 Ce que l'article couvre, et ce que le memoire ajoute

L'article couvre la partie la plus resserrée du travail. Il présente le jeu d'évaluation, la chaîne de traitement, la représentation textuelle, le protocole de comparaison et les résultats. Autrement dit, il répond à la question : comment cette approche fonctionne-t-elle, et qu'est-ce qu'elle donne ?

Le mémoire ajoute ce que l'article, à lui seul, ne dirait pas assez bien. Il revient d'abord au DPR et à la question initiale de réduction du coût. Il explique ensuite pourquoi cette question est pertinente pour des systèmes contraints, notamment en robotique. Enfin, il discute ce que les résultats permettent vraiment d'affirmer, les limites du jeu d'évaluation, et la place du transfert vers le produit.

En bref, l'article porte la preuve centrale. Le mémoire porte la thèse générale du projet.

3.4 Etat actuel des preuves

L'état actuel des preuves peut se lire assez simplement. D'abord, l'infrastructure est en place : le jeu `validation29` est stabilisé, les coûts sont centralisés dans la base, et les vues de rapport permettent de régénérer les tableaux du mémoire. Ensuite, il y a tout le travail exploratoire. Il a servi à tester rapidement plusieurs représentations pour voir lesquelles méritaient d'être poussées plus loin.

Les preuves principales viennent toutefois des exécutions complètes et des ablations contrôlées. Sur les exécutions 29/29, la transcription brute sous **Gemini 3.1 Flash Lite** atteint 0.323, la représentation `typed-v1` sous **Grok 4.1 Fast** atteint 0.301, et l'entrée vidéo directe sous **Gemini 3.1 Flash Lite** atteint 0.273. Dans l'ablation contrôlée sous Gemini, la variante `typed-novlm-v1` atteint 0.315, alors que la variante `typed-v1` avec descriptions visuelles textuelles tombe à 0.240 lorsque l'item non aligné est compté à zéro.

Il faut ajouter à cela la base historique `test_llms.db`. Elle ne remplace pas la preuve principale, mais elle ajoute une information importante sur l'ajustement fin. Elle montre que le déplacement du calcul peut aussi se faire en amont, dans le modèle lui-même, et que cette stratégie ne fonctionne pas de la même manière selon la taille du modèle. C'est ce point qui reliera plus tard le mémoire à une lecture plus système, et pas seulement à une lecture de benchmark.

CHAPITRE 4

Article central

Avant-propos

Titre provisoire de l'article : Représentations textuelles structurées issues d'une chaîne multimodale pour la détection de moments saillants dans de longues vidéos

Auteurs pressentis : Alexandre Lafleur ; François Grondin

Affiliations et statuts pressentis : Alexandre Lafleur, étudiant à la maîtrise, Département de génie électrique et de génie informatique, Université de Sherbrooke ; François Grondin, professeur, Département de génie électrique et de génie informatique, Université de Sherbrooke

Etat de l'article : manuscrit en préparation, non soumis au moment du dépôt de cette version du mémoire

Revue visée : revue internationale en intelligence artificielle appliquée ; la cible finale sera fixée avec la direction au moment de la soumission

Date de soumission ou d'acceptation : sans objet à ce stade ; la soumission est prévue après le gel final des figures, des tableaux et des derniers contrôles expérimentaux

Référence de l'article accepté ou publié : sans objet à ce stade

Contribution de l'article au mémoire : l'article porte la contribution scientifique centrale du mémoire. Il présente la chaîne de transformation vidéo vers texte, la structuration persistante des artefacts en base, le jeu d'évaluation `validation29`, les comparaisons quantitatives entre représentations textuelles et entrée vidéo directe, ainsi que les enseignements complémentaires tirés d'une campagne historique d'ajustement fin de modèles Gemini.

Nature de la version insérée dans le mémoire : le manuscrit inséré ci-dessous est une version adaptée au format du mémoire et rédigée en français. Une soumission ultérieure pourra être traduite en anglais et reformatée selon les exigences de la revue retenue, sans modification du noyau méthodologique ni des résultats principaux rapportés ici.

4.1 Introduction

Les synthèses de Tang et al. [36], de Zhou et al. [48] et de Wadekar et al. [37], ainsi que l’architecture Video-LLaMA [44], montrent qu’analyser une vidéo longue directement avec un modèle multimodal est aujourd’hui possible, mais coûteux. Si l’on veut traiter beaucoup de vidéos, ou si l’on veut le faire avec une machine limitée, ce coût devient rapidement un vrai problème. C’est encore plus vrai quand la tâche finale est simple à formuler : choisir un seul bon moment dans une vidéo de plusieurs minutes.

Une première solution consiste à ne garder que la transcription. C’est beaucoup moins cher, mais cela enlève une partie de l’information utile. Un moment fort ne dépend pas seulement de ce qui est dit. Il peut dépendre d’un changement de scène, d’un cadrage, d’une personne qui apparaît, d’une réaction visuelle, ou d’un contraste entre le verbal et le visuel. À l’inverse, garder la vidéo jusqu’au bout laisse ce signal disponible, mais oblige à payer une inférence plus lourde à chaque exécution.

L’idée de cet article est de prendre une voie intermédiaire. Au lieu de demander au modèle final de raisonner directement sur la vidéo, nous transformons la vidéo en un état textuel structuré. Cet état garde l’ordre temporel, les scènes, la parole et certains indices visuels. Ensuite, différentes vues textuelles peuvent être dérivées de cet état et envoyées à un sélectionneur textuel. La vue la plus complète est `timeline-scenes-dialogue-typed-v1`. D’autres vues plus simples, comme `transcript-v1` et `typed-novlm-v1`, permettent de voir ce que chaque niveau de représentation apporte vraiment.

La contribution de l’article est donc triple. Nous présentons d’abord un jeu d’évaluation reproductible de 29 paires segment source / clip de référence. Nous décrivons ensuite une chaîne de traitement qui transforme la vidéo en données textuelles persistantes. Enfin, nous comparons plusieurs façons d’utiliser ces données, et nous montrons que des conditions texte d’abord dépassent l’entrée vidéo directe sur le jeu d’évaluation retenu. Le point important n’est pas seulement qu’une représentation texte fonctionne. C’est qu’elle peut fonctionner tout en étant beaucoup plus facile à réutiliser dans le temps.

4.2 Travaux connexes

Le travail s’inscrit d’abord dans la littérature sur la localisation temporelle et la détection de moments saillants. Localizing Moments in Video with Natural Language [15], ExCL [11], QV-Highlights [18] et Towards a Complete Benchmark on Video Moment Localization [5] montrent qu’il faut non seulement trouver le bon passage, mais aussi bien le déliminer dans le temps. Cette distinction est importante pour nous, parce qu’un bon extrait doit être proche du clip de référence à la fois dans son contenu et dans ses bornes temporelles.

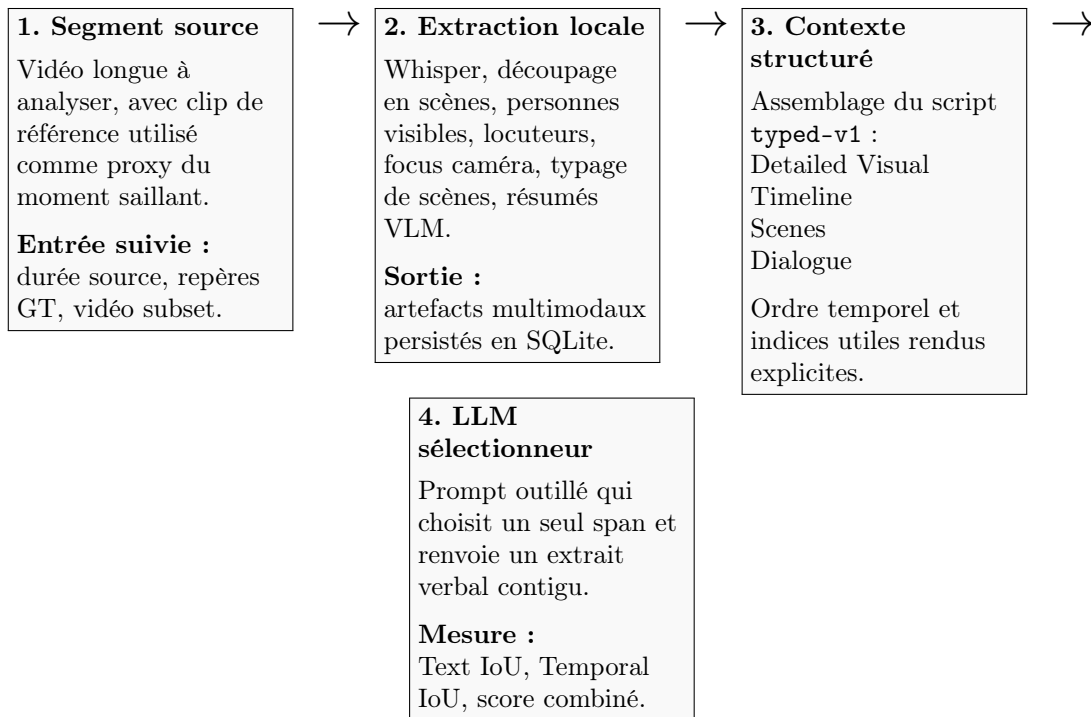


FIGURE 4.1 Vue d'ensemble du pipeline proposé, depuis le segment source jusqu'au span final sélectionné.

Le travail s'inscrit aussi dans la littérature sur les grands modèles vision-langage appliqués aux vidéos longues. Video-LLaMA [44], VTimeLLM [17], VTG-LLM [12], LongVLM [39], VideoLLM [6], Retrieval-based Video Language Model for Efficient Long Video Question Answering [40] et LLMs Meet Long Video [22] montrent bien qu'il est possible de raisonner sur des vidéos complexes avec des modèles très puissants. Le problème, pour notre question, n'est pas qu'elles ne fonctionnent pas. Le problème est plutôt leur coût et leur lourdeur lorsqu'on veut les utiliser souvent ou dans un système contraint. Lost in the Middle [24] renforce ce point en montrant que, même lorsque l'information tient dans un long contexte, elle n'est pas exploitée de manière uniforme par le modèle. Cela rend particulièrement importante la forme sous laquelle on présente l'information.

Enfin, CLIPBERT [20], UMT [25] et Slot-VLM [41] montrent qu'il est possible de compresser le signal vidéo avant la décision finale. Notre travail se situe dans cette direction, mais avec une différence importante : la représentation finale n'est pas cachée dans le modèle. Elle est lisible, stockée en base et réutilisable. C'est cette propriété qui manque souvent dans les approches plus directes, et c'est elle que nous voulons mettre de l'avant ici.

4.3 Jeu d'évaluation et construction des données

Le jeu d'évaluation principal est `validation29`. Il contient 29 paires composées d'un segment source relativement long et d'un clip de référence plus court provenant du même contenu. Les

TABLEAU 4.1 Statistiques descriptives du benchmark `validation29`

Paires	Durée source moyenne (s)	Durée source min-max (s)	Durée GT moyenne (s)	Durée GT min-max (s)	Couverture VLM
29	320.5	120.1-605.0	53.5	17.3-75.0	29/29

segments source durent en moyenne 320.5 s, alors que les clips de référence durent 53.5 s en moyenne. Le but est simple : retrouver, dans le segment source, le passage le plus proche possible du clip de référence.

Ce choix a deux avantages. D’abord, il donne une tâche concrète, proche d’un besoin réel de découpage. Ensuite, il permet de comparer plusieurs représentations sur exactement les mêmes cas. Tout est stocké dans SQLite : les vidéos, les échantillons, les contextes, les profils de modèles, les consignes, les exécutions, les coûts et les scores par cas. Cette structure est importante, parce qu’elle permet de refaire les tableaux, de revoir les itérations et de distinguer les essais rapides des comparaisons vraiment défendables.

4.4 Chaîne de prétraitement multimodal

La chaîne de traitement suit une logique simple. On commence par transcrire l’audio avec Whisper [31]. Ensuite, on découpe la vidéo en scènes et on ajoute plusieurs analyses visuelles : personnes visibles, visages, locuteur actif, cadrage et descriptions visuelles. Chaque étape produit des données intermédiaires qui sont conservées en base.

Le point important n’est pas seulement qu’il y a plusieurs modules. C’est que leurs sorties sont normalisées dans une même structure. Cela permet de reconstruire plusieurs vues textuelles sans devoir tout recalculer. En pratique, la chaîne sert donc à fabriquer un état vidéo textuel que l’on peut ensuite relire et transformer selon la tâche.

4.5 Représentation textuelle structurée

La vue la plus riche de cet état est `timeline-scenes-dialogue-typed-v1`. Elle garde la chronologie, les scènes, les blocs de dialogue et certains indices visuels. Ce n’est pas un résumé libre. C’est une structure de travail. Le modèle final peut y voir où une scène commence, qui parle, qui est visible et quels indices visuels ressortent à ce moment-là.

Il faut bien distinguer deux choses. D’un côté, cette vue est celle qui représente le mieux l’état complet de la vidéo. De l’autre, ce n’est pas elle qui donne le meilleur score dans toutes les comparaisons. C’est précisément pour cela que nous la comparons à d’autres vues. `typed-novlm-v1` garde la structure, mais enlève les descriptions visuelles textuelles. `transcript-v1` garde seulement la parole. Cette famille de vues permet de voir plus clairement ce qui aide vraiment.

TABLEAU 4.2 Composantes principales du pipeline et sorties persistées

Etape	Rôle	Sorties utiles pour la représentation
Whisper / diarization	Transcription et alignement de la parole	mots horodatés, segmentation des locuteurs
Scene detection	Découpage temporel	bornes de scènes
YOLO / faces / ASD	Visages, activité des locuteurs, association personnes	personnes visibles, locuteurs probables, activité
Scene classification	Typage A-roll / B-roll	type de scène et personnes visibles
Camera focus	Indice de cadrage et continuité	segments de focus caméra
VLM summaries	Description visuelle textuelle	descriptions d'images, résumés de scènes
TOON script	Représentation textuelle compacte	dialogue et structure scénique utilisables par le sélectionneur

TABLEAU 4.3 Variantes de contexte disponibles sur l'ensemble complet

Contexte	Couverture	Taille moyenne (car.)	Min	Max
typed-timestamps-v1	29	30923	9826	81154
typed-numbered-v1	29	30916	9797	81361
typed-v1	29	30662	9800	80132
typed-novlm-v1	29	10112	3077	35306
detailed-script-v1	29	9220	2279	44159
no-vlm-v1	29	9204	2706	30983
detailed-vlm-script-v1	29	8595	2372	23420
transcript-v1	29	5072	1841	11197

4.6 Configuration du sélectionneur et métriques d'évaluation

Les comparaisons sont organisées en trois niveaux. Le premier niveau est exploratoire : il sert à tester rapidement des variantes de contexte et de consigne sur peu de cas. Le deuxième niveau regroupe les exécutions complètes, qui servent aux conclusions principales. Le troisième niveau est une ablation contrôlée sous `google/gemini-3.1-flash-lite-preview`, où seule la représentation change.

Dans cette ablation, quatre conditions sont comparées : la transcription brute `transcript-v1`, la variante structurée sans descriptions visuelles `typed-novlm-v1`, la variante structurée avec descriptions visuelles `typed-v1`, et l'entrée vidéo directe. Le modèle sélectionneur, la logique de

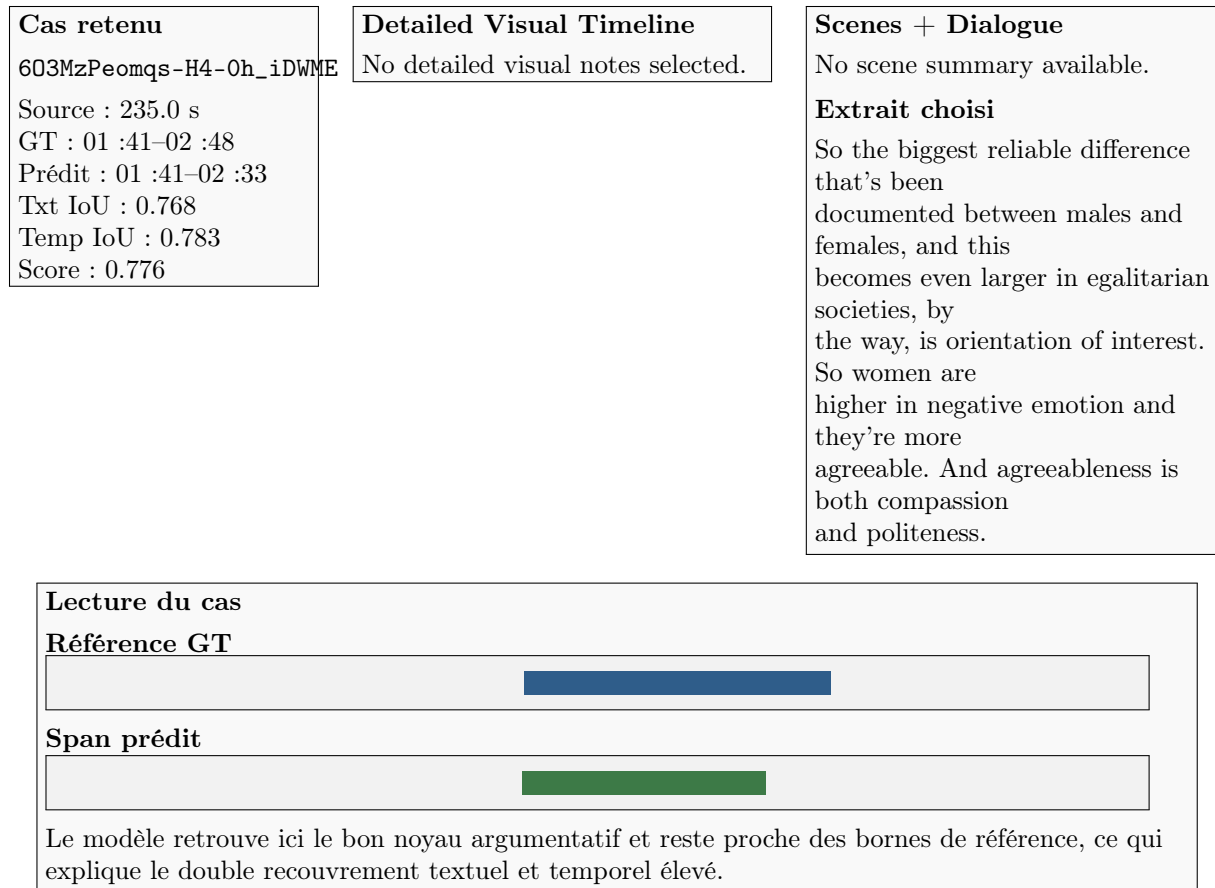


FIGURE 4.2 Exemple concret de transformation d'une vidéo en contexte structuré, puis en span sélectionné par le modèle.

sortie et le jeu d'évaluation restent les mêmes. C'est ce qui permet d'isoler proprement l'effet de la représentation.

L'évaluation repose sur deux mesures principales : le *text IoU*, qui mesure le recouvrement textuel avec la référence, et le *temporal IoU*, qui mesure le recouvrement temporel. Le score combiné est la moyenne des deux. Nous rapportons aussi les coûts, à la fois pour le sélectionneur seul et pour une première exécution incluant la création des données lorsque cette étape existe.

4.7 Résultats quantitatifs

Les résultats se lisent en trois temps. Le premier est exploratoire. Il montre comment la représentation a évolué. Les premières variantes très simples donnent des scores faibles. En structurant davantage la chronologie, les scènes et le dialogue, les scores montent progressivement jusqu'à 0.528 sur cinq cas. Ce n'est pas une conclusion finale, mais c'est important pour comprendre pourquoi certaines représentations ont été retenues et d'autres abandonnées.

TABLEAU 4.4 Synthèse des pilotes exploratoires utilisés pour faire évoluer la représentation

Contexte	Prompt pilote	Modèle pilote	n pilote	Score combiné	n max
transcript-v1	transcript-selector-v1-tool-v1	gemini-3.1-flash-lite	1	0.301	1
scene-grouped-dialogue-script-v1	selector-v2	claude-sonnet-4.6	5	0.470	5
scene-grouped-v1	selector-v2	gpt-5.3-codex	5	0.150	5
timeline-scenes-inline-v1	selector-v2	claude-sonnet-4.6	5	0.324	5
scenes-dialogue-inline-v1	selector-v2	claude-sonnet-4.6	5	0.434	5
timeline-dialogue-inline-v1	selector-v2	claude-sonnet-4.6	5	0.471	5
scene-details-dialogue-inline-v1	selector-v2	gemini-3.1-flash-lite	5	0.333	5
typed-v1	selector-v2	gemini-3.1-flash-lite	5	0.528	28
typed-numbered-v1	selector-sentences-v1	gemini-3.1-flash-lite	5	0.308	5
typed-timestamps-v1	selector-timestamps-v1	claude-sonnet-4.6 (r :med)	5	0.422	15
no-vlm-v1	scenes-selector-tool-v1	gemini-3.1-flash-lite	24	0.343	24
typed-novlm-v1	selector-v2-tool-v1	gemini-3.1-flash-lite	28	0.319	28

Le deuxième temps est celui des exécutions complètes. Sur `validation29`, le meilleur score complet observé est obtenu par la transcription brute sous **Gemini 3.1 Flash Lite**, avec 0.323. La meilleure exécution complète de **typed-v1** atteint 0.301 sous **Grok 4.1 Fast**. L'entrée vidéo directe sous **Gemini 3.1 Flash Lite** atteint 0.273. Ce que ces chiffres montrent, c'est d'abord qu'une approche texte d'abord est tout à fait viable. Ils montrent aussi que la vue la plus riche de l'état vidéo n'est pas forcément celle qui maximise le score brut du sélectionneur.

Le troisième temps est l'ablation contrôlée sous Gemini. C'est elle qui permet de comprendre ce qui se passe vraiment. La transcription brute atteint 0.323. La variante structurée sans descriptions visuelles atteint 0.315. L'entrée vidéo directe reste à 0.273. Et la variante **typed-v1** avec descriptions visuelles textuelles descend à 0.240 lorsque l'échec d'alignement restant est compté à zéro. La lecture la plus simple est donc la suivante : la structure temporelle et dialoguée reste utile, mais les descriptions visuelles textuelles actuelles n'aident pas le sélectionneur. Elles alourdissent plutôt le contexte sans gain net. *Lost in the Middle* [24] va dans le même sens : ajouter de l'information ne suffit pas, encore faut-il que le modèle sache la retrouver et l'utiliser au bon moment.

Le coût confirme cette lecture. Si l'on regarde seulement le sélectionneur final, les approches textuelles coûtent beaucoup moins cher que l'entrée vidéo directe. Si l'on ajoute le coût de création

TABLEAU 4.5 Jalons où un changement de représentation ou de prompt améliore le meilleur score exploratoire connu

Date	Contexte	Prompt	Modèle	n	Score
2026-03-01	transcript-v1	basic-selector	llama-3.3-70b-versatile	1	0.031
2026-03-03	scene-grouped-dialogue-script-v1	selector-v2	gpt-5.3-codex	5	0.152
2026-03-04	scene-grouped-dialogue-script-v1	selector-v2	claude-sonnet-4.6	5	0.470
2026-03-04	timeline-dialogue-inline-v1	selector-v2	claude-sonnet-4.6	5	0.471
2026-03-04	typed-v1	selector-v2	gemini-3.1-flash-lite	5	0.528

TABLEAU 4.6 Conditions complètes sur 29 échantillons retenues pour les revendications principales

Condition	Modèle	Contexte	Txt IoU	Temp IoU	Score	Tokens	Run/video	Contexte/video	1er passage
Structured text	gemini-3.1-flash-lite	transcript-v1	0.388	0.257	0.323	2047	0.001	0.004	
Structured text	grok-4.1-fast	typed-v1	0.372	0.230	0.301	11885	0.003	0.005	
Direct video	gemini-3.1-flash-lite	video-direct-v1	0.338	0.208	0.273	29191	0.008	0.000	

des données, la transcription brute reste la condition la plus économique sur une première exécution, alors que les vues structurées rejoignent l'ordre de grandeur de l'entrée vidéo directe. Cela ne retire pas leur intérêt. Cela veut dire que leur valeur devient surtout claire lorsqu'on réutilise le même état vidéo plusieurs fois.

Une base historique complémentaire, `test_llms.db`, permet d'ajouter un autre angle d'analyse. Elle montre l'effet de l'ajustement fin sur plusieurs variantes Gemini, et elle est pertinente parce qu'elle a représenté un coût amont d'environ 1000 USD en crédits Google. Le cas le plus frappant est **Gemini 2.5 Flash**, qui passe d'environ 0.300 à 0.437 après ajustement fin texte. En revanche, **Flash-Lite** passe de 0.361 à 0.316. La conclusion proposée est qu'il existe une limite de capacité : **Flash-Lite** semble trop petit pour vraiment apprendre la tâche, alors que **Flash** semble être au bon niveau de taille pour en bénéficier. SHED [14] va dans le même sens en montrant qu'un ajustement fin bien ciblé peut tirer beaucoup de valeur d'un ensemble de données choisi avec soin plutôt que d'un volume maximal.

Cette base permet aussi de voir l'effet d'un premier enrichissement par objets. Une variante différentielle reste presque neutre, alors qu'une variante plus lourde dégrade le score. Enfin, sur **Gemini 2.5 Pro**, le modèle de base atteint 0.392, la version ajustée sur le texte seul tombe à 0.363, et la version ajustée avec texte et objets remonte à 0.405. La lecture la plus convaincante est donc la suivante : les grands modèles profitent davantage d'un meilleur contexte que d'un ajustement fin trop étroit, alors que certains modèles plus petits peuvent bénéficier d'un meilleur alignement. Revisiting Catastrophic Forgetting in Large Language Model Tuning [21] est cohérent

TABLEAU 4.7 Comparaison contrôlée sous Gemini 3.1 Flash Lite : même modèle, même protocole de sortie, et variation explicite de la représentation d’entrée

Condition	Couverture	Txt IoU	Temp IoU	Score	Tokens	Run/video	Contexte/video	1er
Structured text + VLM	29 cas (1 échec d’alignement compté à 0)	0.310	0.170	0.240	10053	0.003	0.005	
Structured text sans VLM	29 cas (28 run principal + 1 retry ciblé)	0.382	0.248	0.315	4433	0.001	0.005	
Transcript brut	29 cas (run complet)	0.388	0.257	0.323	2047	0.001	0.004	
Entrée vidéo directe	29 cas (run complet)	0.338	0.208	0.273	29191	0.008	0.000	

TABLEAU 4.8 Impact du fine-tuning sur les petites variantes Gemini 2.5, avec les mêmes 29 cas de validation lorsqu’ils sont disponibles

Variante	n	IoU moy.	Δ vs base	Temps (s)	Coût / 100 vid.
Flash de base	29	0.300	0.000	2.0	0.127
Flash fine-tune texte	27	0.437	0.137	21.6	0.110
Flash-Lite de base	29	0.361	0.000	2.0	0.032
Flash-Lite fine-tune texte	29	0.316	-0.045	1.2	0.027

avec cette baisse après ajustement fin texte seul, puisqu’il montre qu’une spécialisation trop serrée peut dégrader des capacités déjà acquises lors de l’ajustement d’un grand modèle.

4.8 Analyse des échecs et discussion

Les meilleurs cas montrent que les représentations textuelles peuvent vraiment porter un bon raisonnement. Quand la structure du contexte est bonne, le modèle retrouve non seulement le bon sujet, mais aussi le bon moment.

Les échecs, eux, suivent des motifs assez clairs. Il y a d’abord les cas où le bon passage est trouvé de manière approximative, mais mal délimité dans le temps. Il y a ensuite les cas où le modèle choisit un passage voisin, plausible, mais moins bon que le bon moment. Enfin, il y a les cas où la représentation est trop chargée et où les descriptions visuelles deviennent plus distrayantes qu’utiles.

Le point important est que ces échecs ne disent pas seulement « il manque de l’information ». Ils montrent surtout que la forme de l’information compte. C’est exactement ce que la campagne sur l’ajustement fin vient renforcer. Le vrai problème n’est pas simplement d’avoir plus de contexte ou moins de contexte. Le vrai problème est de donner à chaque modèle le type d’aide qu’il sait exploiter. Lost in the Middle [24] va dans ce sens. Revisiting Catastrophic Forgetting in Large Language Model Tuning [21] y conduit aussi : un modèle peut avoir accès à plus d’information ou être plus spécialisé, sans pour autant mieux s’en servir.

4.9 Conclusion

Cet article montre qu’une approche texte d’abord peut servir de support principal à la sélection de moments saillants dans des vidéos longues. Sur `validation29`, plusieurs conditions textuelles



FIGURE 4.3 Comparaison de deux cas de succès et de deux cas d'échec du meilleur run structuré complet. Les succès combinent recouvrement thématique et calibration temporelle ; les échecs gardent parfois un signal sémantique partiel mais ratent la bonne fenêtre temporelle.

TABLEAU 4.9 Premiers essais d’augmentation visuelle par objets dans le contexte textuel

Variante	n	IoU moy.	Δ vs texte	Car. entrée	Temps (s)
Texte seul	29	0.369	0.000	5088	15.2
Texte + objets différentiels 7 s	29	0.369	0.001	7009	15.7
Texte + objets complets 7 s	29	0.343	-0.026	7398	14.8

TABLEAU 4.10 Comparaison des variantes Gemini 2.5 Pro : base, fine-tuning et entrée vidéo directe

Variante	n	IoU moy.	Δ vs base	Temps (s)	Coût / 100 vid.
Pro de base	29	0.392	0.000	22.1	0.841
Pro fine-tune texte	29	0.363	-0.028	26.3	0.879
Pro fine-tune texte + objets	29	0.405	0.013	23.6	0.879
Pro entree video directe	28	0.358	-0.033	45.6	cout non journalise

font mieux que l’entrée vidéo directe. Cela suffit déjà à montrer qu’il n’est pas nécessaire de garder toute l’inférence multimodale jusqu’à la fin.

Mais la conclusion la plus importante est ailleurs. Transformer la vidéo en un état textuel structuré change la nature du problème. Au lieu de refaire une analyse lourde à chaque fois, on obtient une base de travail que l’on peut relire, comparer et réutiliser. C’est cette idée qui donne le plus de valeur à la représentation **typed-v1**, même si sa forme actuelle n’est pas encore optimale pour le sélectionneur final.

La suite logique du travail est donc claire. Il faut d’abord mieux choisir quel signal visuel vaut la peine d’être textualisé. Il faut ensuite continuer à distinguer, selon la taille du modèle, ce qui doit être réglé par le contexte et ce qui doit être réglé par l’ajustement fin. C’est à cette condition qu’une approche texte d’abord pourra vraiment devenir une solution robuste pour des systèmes contraints.

TABLEAU 4.11 Taxonomie initiale des échecs à valider dans l'analyse qualitative

Type d'échec	Description opérationnelle	Preuve attendue
Mauvaise frontière temporelle	Le bon sujet est choisi, mais le span ne recouvre pas la référence	IoU temporel faible avec similarité textuelle non nulle
Mauvais pic local	Le modèle s'arrête sur un segment voisin moins fort	Comparaison qualitative GT / prédiction
Signal visuel insuffisant	La transcription seule ou un contexte partiel manque un indice de mise en scène	Gain après ajout des résumés visuels
Biais dialogue-only	Le clip choisi est sémantiquement correct mais visuellement faible	Cas où le texte est plausible sans appui visuel clair
Sensibilité au contexte	Le résultat varie selon la forme du contexte plus que selon le contenu	Comparaison entre variantes de contexte

CHAPITRE 5

Discussion generale et transfert

Le chapitre précédent montrait les résultats. Le but ici est de revenir à la logique du projet. Il faut voir ce que ces résultats confirment par rapport au DPR, ce qu'ils ne permettent pas encore d'affirmer, et ce qu'ils changent dans la manière de penser une analyse vidéo avec peu de ressources.

5.1 Retour sur le DPR

Le DPR partait d'une intuition simple : au lieu de faire raisonner directement un modèle multi-modal lourd sur la vidéo, il devrait être possible de transformer la vidéo en texte, puis de confier l'analyse finale à un modèle textuel moins coûteux. Le travail réalisé confirme que cette intuition allait dans la bonne direction.

En même temps, la recherche a clarifié cette intuition. Le projet n'a pas seulement produit une représentation texte. Il a produit un jeu d'évaluation, une base de données de suivi, une estimation des coûts, et plusieurs vues textuelles qui permettent de comprendre ce qui aide réellement le modèle final. C'est important, parce que cela transforme une intuition de faisabilité en une comparaison mesurable.

5.2 Portée des résultats actuels

La première chose à garder en tête est que tous les résultats de la base n'ont pas la même valeur. Les essais sur un ou cinq cas ont servi à itérer rapidement. Ils sont utiles pour raconter le cheminement, mais ils ne doivent pas porter les conclusions principales. Les conclusions principales viennent des exécutions complètes et des ablations contrôlées.

Sur cette base, trois points ressortent clairement. D'abord, l'approche texte d'abord fonctionne. Sur `validation29`, la transcription brute et la variante structurée sans descriptions visuelles dépassent l'entrée vidéo directe dans la comparaison contrôlée sous Gemini. Ensuite, la représentation `typed-v1` reste importante, non parce qu'elle serait la meilleure partout, mais parce qu'elle représente la vue la plus riche et la plus réutilisable de l'état vidéo. Enfin, la textualisation visuelle actuelle ne semble pas aider. Dans sa forme actuelle, elle ajoute surtout du bruit et du coût. *Lost in the Middle* [24] est cohérent avec cette lecture, puisqu'il montre que les longs contextes ne sont pas exploités uniformément par les modèles lorsque l'information pertinente est noyée dans une grande quantité de texte.

Le point sur les coûts demande une lecture un peu plus nuancée. Si l'on regarde seulement l'appel final au sélectionneur, les approches textuelles coûtent beaucoup moins cher que l'entrée vidéo directe. Si l'on ajoute le coût de création des données sur une première exécution, la transcription brute reste la meilleure affaire, alors que les vues structurées reviennent à peu près dans le même ordre de grandeur que l'entrée vidéo directe. Cela veut dire que l'intérêt des vues structurées apparaît surtout quand on réutilise la même représentation plusieurs fois.

5.3 Enseignements complémentaires sur l'ajustement fin

La base `test_llms.db` ajoute un deuxième message important. Elle montre que le calcul peut être déplacé non seulement dans la représentation, mais aussi dans l'ajustement fin du modèle. Autrement dit, au lieu de payer plus cher à chaque inférence, on peut parfois payer en amont pour mieux aligner un modèle moins coûteux sur la tâche.

Le cas le plus parlant est **Gemini 2.5 Flash**. Il part bas, autour de 0.300, puis monte à 0.437 après ajustement fin texte. Cela suggère que ce modèle a la bonne taille pour apprendre une tâche précise sans perdre sa capacité utile de généralisation. SHED [14] va dans le même sens, puisqu'il montre qu'un ajustement fin peut gagner beaucoup en efficacité lorsque les données sont bien choisies et bien calibrées pour la tâche.

Le cas de **Flash-Lite** montre la limite. Lui ne s'améliore pas. Il baisse même après ajustement fin. La conclusion qui en ressort est qu'il y a un seuil de capacité sous lequel un modèle reste trop petit pour vraiment apprendre ce qu'on lui demande, même si on essaie de le spécialiser.

Le cas de **Gemini 2.5 Pro** montre l'autre extrême. Le modèle de base est déjà fort. Quand on l'ajuste seulement sur le texte, il perd. Quand on lui ajoute plutôt un contexte plus riche avec des objets, il remonte. Cela suggère qu'un grand modèle profite plus d'un meilleur contexte que d'un ajustement fin trop étroit. Dit autrement : plus un modèle est gros, plus sa force semble être de raisonner sur plusieurs possibilités ; trop le contraindre peut donc lui enlever une partie de cet avantage. *Revisiting Catastrophic Forgetting in Large Language Model Tuning* [21] est compatible avec cette interprétation.

5.4 Lien avec l'application de production

Le transfert vers **mecene-clips** est important, mais il faut bien dire ce qu'il montre et ce qu'il ne montre pas. Il montre que les représentations et la logique de sélection construites dans le benchmark sont assez stables pour être reprises dans une application réelle. C'est une bonne indication que le travail ne tient pas seulement dans un contexte de laboratoire.

Par contre, ce transfert ne remplace pas la preuve scientifique. Une application de production doit surtout arbitrer entre latence, robustesse, maintenance et expérience utilisateur. Le benchmark,

lui, sert à comparer proprement des conditions et à mesurer ce qu’elles coûtent. Il faut donc lire le transfert comme une preuve de pertinence pratique, pas comme une seconde preuve expérimentale.

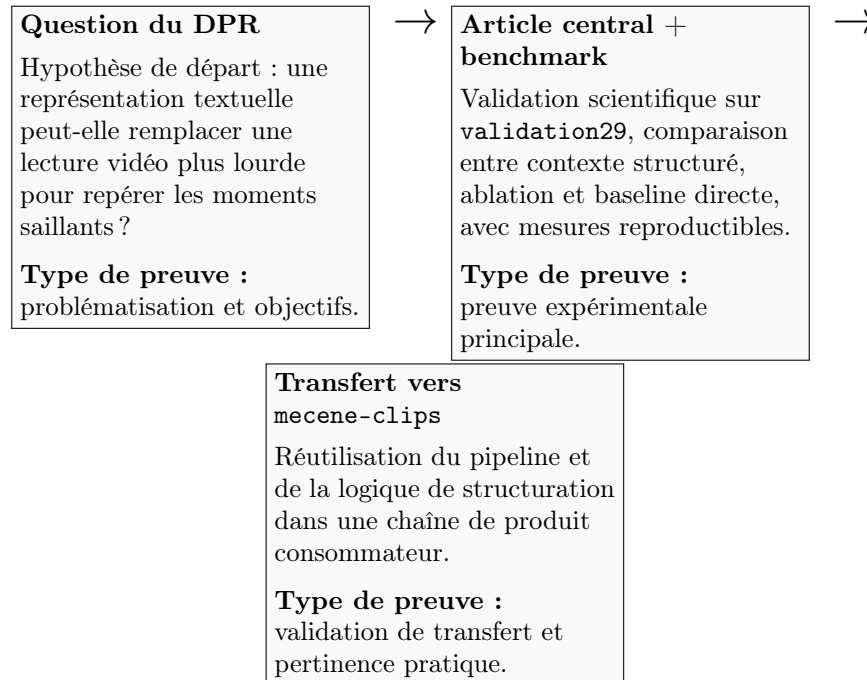


FIGURE 5.1 Positionnement respectif du DPR, de l’article central et du transfert vers l’application de production.

5.5 Limites et menaces a la validité

La première limite est la taille du jeu d’évaluation. Vingt-neuf paires suffisent pour faire ressortir des tendances nettes, mais pas pour couvrir toute la diversité des vidéos longues. La deuxième limite est le domaine lui-même. On reste proche du découpage de clips grand public, ce qui est cohérent avec l’application visée, mais ne couvre pas encore tous les cas plus difficiles que l’on pourrait trouver en robotique ou en perception embarquée.

Une autre limite importante vient de la forme actuelle du signal visuel textuel. L’ablation montre qu’il n’aide pas dans l’état présent du système. Cela ne veut pas dire qu’aucun signal visuel textuel ne pourra aider. Cela veut dire que cette manière précise de le produire et de l’injecter n’est pas encore la bonne.

Enfin, la campagne sur l’ajustement fin est très informative, mais elle reste une campagne complémentaire sur une base historique distincte. Elle renforce une lecture système du travail, sans changer la preuve principale, qui reste celle du jeu `validation29`.

5.6 Travaux futurs

La priorité la plus directe est de mieux choisir le signal visuel à transmettre. Le résultat actuel montre assez clairement que la solution n'est pas de mettre plus de descriptions. Il faut plutôt trouver quelles informations visuelles sont vraiment utiles à la décision finale.

Le deuxième axe est de mieux exploiter l'idée d'état persistant. Une fois la vidéo transformée en données textuelles structurées, on peut s'en servir pour autre chose que choisir un seul moment : annotation, recherche, révision, ou aide au montage. C'est là que l'amortissement du coût de préparation devient vraiment intéressant.

Le troisième axe est plus proche de la motivation initiale du projet. Il faudra tester cette même logique sur des données moins proches du découpage de clips et plus proches de la robotique, où le signal verbal est parfois faible et où l'information importante peut être davantage visuelle ou contextuelle. C'est à ce moment-là qu'on pourra vraiment mesurer jusqu'où l'approche texte d'abord reste valide.

CHAPITRE 6

Conclusion generale

La question de départ du mémoire était la suivante : est-ce qu’une vidéo longue peut être représentée sous forme textuelle de manière assez bonne pour qu’un modèle textuel puisse en extraire un moment saillant, tout en coûtant moins cher qu’une approche multimodale directe ? Les travaux réalisés permettent maintenant de répondre oui, mais avec une nuance importante sur le type de représentation qui aide vraiment.

6.1 Réponse à la question de recherche

La réponse générale est positive. Sur `validation29`, plusieurs conditions textuelles dépassent l’entrée vidéo directe. Cela veut dire qu’il n’est pas nécessaire, pour cette tâche, de garder toute l’analyse vidéo multimodale jusqu’au dernier moment. Une approche texte d’abord peut suffire.

La nuance importante est la suivante. Ce n’est pas simplement « plus la représentation est riche, mieux c’est ». Dans l’état actuel du système, la transcription brute est la meilleure condition contrôlée, la variante structurée sans descriptions visuelles suit de près, et la textualisation visuelle actuelle ne semble pas aider. Donc le vrai message n’est pas seulement qu’une représentation texte fonctionne. C’est qu’il faut bien choisir ce que l’on met dans cette représentation.

Il faut ajouter une deuxième nuance. La valeur de la représentation structurée ne se limite pas à son score brut. Elle tient aussi au fait qu’elle produit un état persistant de la vidéo, que l’on peut conserver, relire et réutiliser. C’est ce qui rend l’approche intéressante dans une logique système, surtout si la même vidéo doit ensuite servir à plusieurs traitements.

Enfin, la campagne complémentaire sur l’ajustement fin montre que le problème ne se résume pas à choisir entre texte et vidéo. Selon la taille du modèle, il peut être plus intelligent de déplacer une partie du calcul dans l’ajustement fin, ou au contraire de garder un modèle plus général et de lui fournir un meilleur contexte. `Flash-Lite` semble trop petit pour en tirer un vrai gain. `Flash` semble être au bon niveau de capacité. `Pro`, lui, profite surtout d’un contexte plus riche.

6.2 Contributions validées par le mémoire

Le mémoire valide d’abord une idée simple mais importante : une approche texte d’abord peut rester compétitive pour la sélection de moments saillants dans des vidéos longues. Il valide ensuite la chaîne qui permet d’arriver à ce résultat : transcription, structuration temporelle, enrichissement visuel contrôlé, stockage en base et comparaison reproductible.

Le mémoire valide aussi une contribution plus large que prévu au départ. En construisant cette représentation, le projet ne produit pas seulement un contexte pour un modèle. Il produit une base textuelle de la vidéo. Cela ouvre la porte à une logique de réutilisation que l'entrée vidéo directe ne permet pas aussi facilement.

Enfin, le travail valide une manière plus rigoureuse de suivre les itérations. Le jeu d'évaluation, la base SQLite, les vues de rapport et les tableaux générés permettent de distinguer proprement ce qui relève de l'exploration rapide, de la comparaison principale et du diagnostic plus fin. Cela compte, parce que la qualité de la représentation est justement le coeur scientifique du projet.

6.3 Perspectives

La suite la plus directe consiste à mieux choisir l'information visuelle à transmettre. Les résultats actuels montrent qu'ajouter du texte visuel ne suffit pas. Il faut plutôt trouver quelle information visuelle aide vraiment le modèle, et sous quelle forme.

La deuxième perspective consiste à exploiter davantage la représentation comme état persistant. Une fois qu'une vidéo a été transformée en structure textuelle, elle peut servir à plusieurs tâches, pas seulement à choisir un clip. C'est probablement là que la valeur pratique de l'approche deviendra la plus forte.

La troisième perspective est de revenir encore plus près de la motivation initiale du DPR. Il faudra tester cette logique sur des données plus proches de la robotique et des systèmes embarqués, où les contraintes de calcul sont encore plus fortes et où l'information utile n'est pas toujours principalement verbale. Si l'approche reste bonne dans ce contexte, alors le projet aura vraiment montré qu'une représentation textuelle peut devenir une alternative crédible à l'analyse vidéo directe dans des systèmes contraints.

LISTE DES RÉFÉRENCES

- [1] 2SHORT : 2short tool. [En ligne]. Disponible : <https://2short.ai>. Consulté le 2024-11-04.
- [2] K. ATAALLAH, X. SHEN, E. ABDELRAHMAN, E. SLEIMAN, D. ZHU, J. DING et M. ELHOSEINY : Minigt4-video : Advancing multimodal llms for video understanding with interleaved visual-textual tokens. *arXiv preprint arXiv :2404.03413*, 2024.
- [3] M. BAIN, A. NAGRANI, G. VAROL et A. ZISSERMAN : A clip-hitchhiker’s guide to long video retrieval. *arXiv preprint*, arXiv :2205.08508, 2022.
- [4] CAPTIONS : Captions tool. [En ligne]. Disponible : <https://www.captions.ai/tools/ai-clip-generator>. Consulté le 2024-11-04.
- [5] J. CHAE, D. KIM, K. KIM, D. LEE, S. LEE, S. HA, J. MUN, W. KANG, B. ROH et J. LEE : Towards a complete benchmark on video moment localization. *Dans Proceedings of the International Conference on Artificial Intelligence and Statistics*, volume 238, pages 4168–4176. Machine Learning Research, 2024.
- [6] G. CHEN, Y.-D. ZHENG, J. WANG, J. XU, Y. HUANG, J. PAN, Y. WANG, Y. WANG, Y. QIAO, T. LU et L. WANG : VideoLLM : Modeling video sequence with large language models. *arXiv preprint*, arXiv :2305.13292, 2023.
- [7] DESCRIPT : Descript tool. [En ligne]. Disponible : <https://www.descript.com/>. Consulté le 2024-11-04.
- [8] C. FAN, X. ZHU, W. LI, C. FANG, G. LIN, R. YANG et D. THALMANN : Heterogeneous memory enhanced multimodal attention model for video question answering. *Dans Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 1999–2007, 2019.
- [9] W. FENG, X. WANG, H. CHEN, Z. ZHANG, Z. SONG, Y. ZHOU et W. ZHU : LLM4vg : Large language models evaluation for video grounding. *arXiv preprint arXiv :2312.14206*, 2023.
- [10] FRAMEDROP : Framedrop tool. [En ligne]. Disponible : <https://www.framedrop.ai/>. Consulté le 2024-11-04.
- [11] S. GHOSH, A. AGARWAL, Z. PAREKH et A. HAUPTMANN : Excl : Extractive clip localization using natural language descriptions. *Dans Proceedings of the Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies, Volume 1*, pages 1984–1990. Association for Computational Linguistics, 2019.
- [12] Y. GUO, J. LIU, M. LI, X. TANG, X. CHEN et B. ZHAO : Vtg-LLM : Integrating timestamp knowledge into video LLMs for enhanced video temporal grounding. *arXiv preprint arXiv :2405.13382*, 2024.
- [13] D. HAN, S. SEO, E. PARK, S.-U. NAM et N. KWAK : Unleash the potential of clip for video highlight detection. *arXiv preprint arXiv :2404.01745*, 2024.
- [14] Y. HE, Z. WANG, Z. SHEN, G. SUN, Y. DAI, Y. WU, H. WANG et A. LI : Shed : Shapley-based automated dataset refinement for instruction fine-tuning. *Dans Advances in Neural Information Processing Systems*, 2024.
- [15] L. A. HENDRICKS, O. WANG, E. SHECHTMAN, J. SIVIC, T. DARRELL et B. RUSSELL : Localizing moments in video with natural language. *Dans Proceedings of the IEEE International Conference on Computer Vision*, pages 5804–5813, 2017.

-
- [16] R. HU, H. XU, M. ROHRBACH, J. FENG, K. SAENKO et T. DARRELL : Natural language object retrieval. *Dans Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 4555–4564, 2016.
 - [17] B. HUANG, X. WANG, H. CHEN, Z. SONG et W. ZHU : VtimeLLM : Empower LLM to grasp video moments. *Dans Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14271–14280, 2024.
 - [18] M. Bansal J. LEI, T. L. Berg : Qvhighlights : Detecting moments and highlights in videos via natural language queries. *Dans Proceedings of the International Conference on Neural Information Processing Systems*, pages 11846–11858. Neural Information Processing Systems, 2021.
 - [19] Klap : Klap tool. [En ligne]. Disponible : <https://klap.app>. Consulté le 2024-11-04.
 - [20] J. LEI, L. LI, L. ZHOU, Z. GAN, T. L. BERG, M. BANSAL et J. LIU : Less is more : CLIPBERT for video-and-language learning via sparse sampling. *Dans Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 7327–7337, 2021.
 - [21] H. LI, L. DING, M. FANG et D. TAO : Revisiting catastrophic forgetting in large language model tuning. *Dans Findings of the Association for Computational Linguistics : EMNLP 2024*, pages 4297–4308. Association for Computational Linguistics, 2024.
 - [22] Y. LI, X. CHEN, B. HU et M. ZHANG : LLMs meet long video : Advancing long video question answering with an interactive visual adapter in LLMs. *arXiv preprint*, arXiv :2402.13546, 2024.
 - [23] W. LIANG, L. YU, L. LUO, S. IYER, N. DONG, C. ZHOU, G. GHOSH, M. LEWIS, W. t. YIH, L. ZETTLEMOYER et X. V. LIN : Mixture-of-transformers : A sparse and scalable architecture for multi-modal foundation models. *Transactions on Machine Learning Research*, 2025.
 - [24] N. F. LIU, K. LIN, J. HEWITT, A. PARANJAPE, M. BEVILACQUA, F. PETRONI et P. LIANG : Lost in the middle : How language models use long contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173, 2024.
 - [25] Y. LIU, S. LI, Y. WU, C. W. CHEN, Y. SHAN et X. QIE : Umt : Unified multi-modal transformers for joint video moment retrieval and highlight detection. *Dans Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 3032–3041, 2022.
 - [26] R. LUO, Z. ZHAO, M. YANG, J. DONG, D. LI, P. LU, T. WANG, L. HU, M. QIU et Z. WEI : Valley : Video assistant with large language model enhanced ability. *arXiv preprint arXiv :2306.07207*, 2023.
 - [27] S. MUNASINGHE, R. THUSHARA, M. MAAZ, H. A. RASHEED, S. KHAN, M. SHAH et F. KHAN : Pg-video-llava : Pixel grounding large video-language models. *arXiv preprint arXiv :2311.13435*, 2023.
 - [28] MUNCH : Munch tool. [En ligne]. Disponible : <https://www.getmunch.com>. Consulté le 2024-11-04.
 - [29] OPUSCLIP : Opusclip tool. [En ligne]. Disponible : <https://www.opus.pro>. Consulté le 2024-11-04.
 - [30] POWDER : Powder tool. [En ligne]. Disponible : <https://powder.gg>. Consulté le 2024-11-04.
 - [31] A. RADFORD, J. KIM, T. XU, G. BROCKMAN, C. MCLEAVEY et I. SUTSKEVER : Whisper : Robust speech recognition via large-scale weak supervision. *Dans Proceedings of the International Conference on Machine Learning*, pages 28492–28518, 2023.
 - [32] SENDSHORT : Sendshort tool. [En ligne]. Disponible : <https://sendshort.ai>. Consulté le 2024-11-04.
-

-
- [33] SSEMBLE : Ssemble tool. [En ligne]. Disponible : <https://www.ssemble.com>. Consulté le 2024-11-04.
 - [34] Recast STUDIO : Recast studio tool. [En ligne]. Disponible : <https://recast.studio>. Consulté le 2024-11-04.
 - [35] Y. SUN, Y. XU, Z. XIE, Y. SHU et S. DU : Gptsee : Enhancing moment retrieval and highlight detection via description-based similarity features. *Dans Proceedings of the IEEE Signal Processing Letters*, pages 521–525, 2024.
 - [36] Y. TANG, J. BI, S. XU, L. SONG, S. LIANG, T. WANG, D. ZHANG, J. AN, J. LIN, R. ZHU, A. VOSOUGHI, C. HUANG, Z. ZHANG, F. ZHENG, J. ZHANG, P. LUO, J. LUO et C. XU : Video understanding with large language models : A survey. *arXiv preprint*, arXiv :2312.17432, 2023.
 - [37] S. N. WADEKAR, A. CHAURASIA, A. CHADHA et E. CULURCIELLO : The evolution of multimodal model architectures. *arXiv preprint arXiv :2405.17927*, 2024.
 - [38] Y. WANG, X. MENG, J. LIANG, Y. WANG, Q. LIU et D. ZHAO : Hawkeye : Training video-text LLMs for grounding text in videos. *arXiv preprint arXiv :2403.10228*, 2024.
 - [39] Y. WENG, M. HAN, H. HE, X. CHANG et B. ZHUANG : Longvlm : Efficient long video understanding via large language models. *Dans Proceedings of the European Conference on Computer Vision*, 2024.
 - [40] J. XU, C. LAN, W. XIE, X. CHEN et Y. LU : Retrieval-based video language model for efficient long video question answering. *arXiv preprint*, arXiv :2312.04931, 2023.
 - [41] J. XU, C. LAN, W. XIE, X. CHEN et Y. LU : Slot-vlm : Slowfast slots for video-language modeling. *arXiv preprint arXiv :2402.13088*, 2024.
 - [42] H. YOU, H. ZHANG, Z. GAN, X. DU, B. ZHANG, Z. WANG, L. CAO, S.-F. CHANG et Y. YANG : Ferret : Refer and ground anything anywhere at any granularity. *arXiv preprint arXiv :2310.07704*, 2023.
 - [43] C. ZHANG, T. LU, M. M. ISLAM, Z. WANG, S. YU, M. BANSAL et G. BERTASIUS : A simple LLM framework for long-range video question-answering. *arXiv preprint*, arXiv :2312.17235, 2023.
 - [44] H. ZHANG, X. LI et L. BING : Video-llama : An instruction-tuned audio-visual language model for video understanding. *Dans Proceedings of the Conference on Empirical Methods in Natural Language Processing : System Demonstrations*, pages 543–553. Association for Computational Linguistics, 2023.
 - [45] K. ZHANG, W.-L. CHAO, F. SHA et K. GRAUMAN : Video summarization with long short-term memory. *Dans Proceedings of the European Conference on Computer Vision*, pages 766–782. Springer, 2016.
 - [46] S. ZHANG, H. PENG, J. FU et J. LUO : Learning 2D temporal adjacent networks for moment localization with natural language. *Dans Proceedings of the AAAI Conference on Artificial Intelligence*, pages 12870–12877, 2020.
 - [47] Y. ZHAO, Z. LIN, D. ZHOU, Z. HUANG, J. FENG et B. KANG : Bubogpt : Enabling visual grounding in multi-modal LLMs. *arXiv preprint arXiv :2307.08581*, 2023.
 - [48] P. ZHOU, L. WANG, Z. LIU, Y. HAO, P. HUI, S. TARKOMA et J. KANGASHARJU : A survey on generative ai and LLM for video generation, understanding, and streaming. *arXiv preprint*, arXiv :2404.16038, 2024.
-

