

UNIVERSITÉ DE SHERBROOKE
Faculté de génie
Département de génie électrique et de génie informatique

DÉTECTION DES MOMENTS SAILLANTS D'UNE VIDÉO EN UTILISANT UNE REPRÉSENTATION TEXTUELLE STRUCTURÉE

Mémoire de maîtrise
Spécialité : génie électrique

Alexandre LAFLEUR

Sherbrooke (Québec) Canada

Mars 2026

MEMBRES DU JURY

François GRONDIN

Directeur

François MICHAUD

Évaluateur

François FERLAND

Évaluateur

RÉSUMÉ

Ce mémoire étudie la possibilité de représenter un segment vidéo long par une structure textuelle suffisamment riche pour permettre à un grand modèle de langage textuel d'identifier automatiquement un moment saillant. La contribution centrale du travail est un pipeline qui transforme un segment vidéo en représentation textuelle structurée combinant transcription, segmentation en scènes, association personnes-visages-locuteurs, indices de cadrage et résumés visuels issus d'un modèle vision-langage. Cette représentation est ensuite utilisée comme contexte d'entrée pour un modèle sélectionneur de clips.

L'évaluation repose sur un benchmark de 29 paires composées d'un segment source et d'un clip de référence correspondant. Les résultats consolidés actuellement montrent qu'une condition textuelle structurée complète atteint un score combiné moyen de 0.301 sur l'ensemble complet, contre 0.273 pour une condition baseline en entrée vidéo directe. Le mémoire adopte un format combiné centré sur un article unique; les chapitres entourant l'article situent la contribution, documentent le benchmark et discutent le transfert vers une application de production.

Mots-clés : Intelligence artificielle, LLM, analyse vidéo, représentation textuelle, benchmark

ABSTRACT

Salient Moment Detection in Long Videos with a Structured Textual Representation

This memoir studies whether a long video segment can be converted into a structured textual representation rich enough for a text-only large language model to automatically recover a salient moment. The core contribution is a pipeline that converts video into structured text by combining transcription, scene segmentation, person-face-speaker association, camera-focus cues, and visual summaries produced by a vision-language model. The resulting representation is then used as context for a clip-selection model.

Evaluation currently relies on a benchmark of 29 source-segment / reference-clip pairs. Consolidated results show that the full structured-text condition reaches a mean combined score of 0.301 on the complete set, compared with 0.273 for a direct-video baseline. The memoir follows a combined format centered on one article; the surrounding chapters position the contribution, document the benchmark, and discuss transfer toward a production application.

Keywords: artificial intelligence, LLM, video analysis, textual representation, benchmark

REMERCIEMENTS

Ce fichier contient un espace réservé pour les remerciements finaux. Remplacer ce texte par une version d'une page maximum avant le dépôt.

TABLE DES MATIÈRES

1	Introduction	1
1.1	Mise en contexte et problématique	1
1.2	Question de recherche	2
1.3	Objectifs du projet de recherche	2
1.4	Contributions originales	3
1.5	Plan du document	4
2	Etat de l’art	5
2.1	Détection de moments saillants dans les vidéos longues	5
2.2	Raisonnement sur vidéos longues avec grands modèles de langage et modèles vision-langage	6
2.3	Représentations multimodales vers texte et états persistants	7
2.4	Robotique, systèmes incarnés et analogues pratiques	7
2.5	Lacune ciblée par le mémoire	8
3	Articulation du memoire combine	9
3.1	Pourquoi un memoire combine centré sur un seul article	9
3.2	Lien entre l’article, l’infrastructure de représentation et l’application	9
3.3	Ce que l’article couvre, et ce que le memoire ajoute	10
3.4	Etat actuel des preuves	10
4	Article central	11
4.1	Introduction	12
4.2	Travaux connexes	12
4.3	Jeu d’évaluation et construction des données	13
4.4	Chaîne de prétraitement multimodal	14
4.5	Représentation textuelle structurée	15
4.6	Configuration du sélectionneur et métriques d’évaluation	15
4.7	Résultats quantitatifs	16
4.8	Analyse des échecs et discussion	20
4.9	Conclusion	20
5	Discussion generale et transfert	23
5.1	Retour sur le DPR	23
5.2	Portée des résultats actuels	23
5.3	Enseignements complémentaires sur l’ajustement fin	24
5.4	Lien avec l’application de production	24
5.5	Limites et menaces a la validité	25
5.6	Travaux futurs	26
6	Conclusion generale	27

6.1	Réponse à la question de recherche	27
6.2	Contributions validées par le mémoire	27
6.3	Perspectives	28

LISTE DES RÉFÉRENCES	29
-----------------------------	-----------

LISTE DES FIGURES

4.1	Vue d'ensemble du pipeline proposé, depuis le segment source jusqu'au span final sélectionné.	13
4.2	Exemple concret de transformation d'une vidéo en contexte structuré, puis en span sélectionné par le modèle.	16
4.3	Comparaison de deux cas de succès et de deux cas d'échec du meilleur run structuré complet. Les succès combinent recouvrement thématique et calibration temporelle ; les échecs gardent parfois un signal sémantique partiel mais ratent la bonne fenêtre temporelle.	19
5.1	Positionnement respectif du DPR, de l'article central et du transfert vers l'application de production.	25

LISTE DES TABLEAUX

1.1	Correspondance entre les contributions et les chapitres du mémoire	3
4.1	Statistiques descriptives du benchmark validation29	13
4.2	Composantes principales du pipeline et sorties persistées	14
4.3	Variantes de contexte disponibles sur l'ensemble complet	15
4.4	Synthèse des pilotes exploratoires utilisés pour faire évoluer la représentation	17
4.5	Jalons où un changement de représentation ou de prompt améliore le meilleur score exploratoire connu	18
4.6	Conditions complètes sur 29 échantillons retenues pour les revendications principales	18
4.7	Comparaison contrôlée sous Gemini 3.1 Flash Lite : même modèle, même protocole de sortie, et variation explicite de la représentation d'entrée . . .	20
4.8	Impact du fine-tuning sur les petites variantes Gemini 2.5, avec les mêmes 29 cas de validation lorsqu'ils sont disponibles	20
4.9	Premiers essais d'augmentation visuelle par objets dans le contexte textuel	21
4.10	Comparaison des variantes Gemini 2.5 Pro : base, fine-tuning et entrée vidéo directe	21
4.11	Taxonomie initiale des échecs à valider dans l'analyse qualitative	22

LISTE DES ACRONYMES

LLM	Grand modèle de langage
IA	Intelligence artificielle
VTG	Ancrage temporel dans la vidéo (<i>Video Temporal Grounding</i>)
TAN	Réseaux temporels adjacents (<i>Temporal Adjacent Networks</i>)
LLoVi	Questions-réponses vidéo (<i>Language-based Long-range Video question answering</i>)
ExCL	Localisation extractive de segments vidéo (<i>Extractive Clip Localization</i>)
QD-DETR	Transformeur de détection adaptatif (<i>Query-Dependent DETection TRansformer</i>)
VLM	Modèle vision-langage
TOON	Token-Oriented Object Notation
IoU	Intersection over Union
ASD	Active Speaker Detection
API	Interface de programmation applicative
GT	Ground truth / référence annotée

CHAPITRE 1

Introduction

L'analyse de longues vidéos pose un problème assez simple à comprendre. Plus la vidéo est longue, plus il faut traiter d'information. Si l'on utilise directement un modèle multimodal pour tout analyser, le coût en calcul, en jetons et en argent monte rapidement [20, 27, 21]. Cela devient vite difficile à justifier dans des contextes où les ressources sont limitées, par exemple pour un service qui doit traiter beaucoup de vidéos, ou pour un système embarqué qui ne dispose pas d'une grosse capacité de calcul.

Le problème n'est pas que les approches multimodales directes ne fonctionnent pas. Au contraire, elles sont puissantes. Le problème est plutôt qu'elles sont lourdes. Leur architecture est plus complexe qu'un grand modèle de langage textuel, parce qu'elles doivent encoder plusieurs modalités puis les fusionner [21]. Cette complexité entraîne plus de calcul, plus de coût et une difficulté plus grande à les utiliser dans des systèmes contraints [14]. Si l'objectif est de choisir un bon moment dans une vidéo, il devient alors légitime de se demander s'il est vraiment nécessaire de garder toute cette complexité jusqu'au dernier moment.

Le point de départ de ce mémoire est justement là. L'idée est de déplacer une partie du travail d'analyse vers une représentation textuelle structurée de la vidéo, puis de laisser le choix final à un modèle textuel. Autrement dit, au lieu de demander au modèle final de regarder directement la vidéo, on lui donne une version textuelle organisée de ce que la vidéo contient. L'hypothèse est qu'une telle représentation peut conserver l'information utile tout en coûtant moins cher à exploiter qu'une entrée vidéo directe [26, 9, 5].

1.1 Mise en contexte et problématique

Une transcription brute ne suffit pas toujours. Elle garde les paroles, mais elle perd beaucoup de ce qui rend un moment fort dans une vidéo : les changements de scène, les personnes visibles, certains gestes, le cadrage ou le contraste entre ce que l'on voit et ce que l'on entend. Si l'on veut qu'un modèle textuel fasse un bon travail, il faut donc lui donner plus qu'une simple transcription. En même temps, si on lui donne trop d'information ou une information mal organisée, le contexte devient lourd, bruité et plus difficile à utiliser.

La vraie question du mémoire est donc la suivante : comment transformer une vidéo en texte de manière assez riche pour garder les bons indices, mais assez claire et assez compacte pour que le modèle final puisse encore prendre une bonne décision ?

Pour répondre à cette question, le mémoire utilise la détection de moments saillants comme tâche de validation. Cette tâche est un bon choix parce qu'elle est concrète, exigeante et mesurable. Il ne suffit pas de comprendre de quoi parle une vidéo. Il faut aussi être capable de choisir un bon passage et de le situer correctement dans le temps [8, 4, 10, 1]. Si la représentation texte est mauvaise, l'erreur se voit tout de suite dans l'extrait choisi.

1.2 Question de recherche

La question de recherche du mémoire peut être formulée ainsi :

Comment représenter une longue vidéo sous forme textuelle de manière assez fidèle et assez structurée pour qu'un grand modèle de langage puisse identifier un moment saillant avec une qualité comparable à une approche multimodale directe, tout en consommant beaucoup moins de ressources ?

Cette question a deux dimensions. La première porte sur la représentation elle-même : qu'est-ce qu'il faut garder de la vidéo, sous quelle forme, et avec quel niveau de détail ? La deuxième porte sur l'utilisation de cette représentation : est-ce qu'un modèle textuel peut vraiment s'en servir pour choisir le bon moment ?

L'article central du mémoire traite cette question en insistant davantage sur la représentation comme état textuel durable. Le mémoire, dans son ensemble, garde un angle un peu plus large : le compromis entre qualité de sélection, coût et possibilité de déploiement dans des systèmes contraints.

1.3 Objectifs du projet de recherche

L'objectif général est de montrer qu'une représentation textuelle structurée peut servir de support principal à la sélection de moments saillants dans de longues vidéos, avec une performance compétitive et un coût plus faible qu'une entrée vidéo directe.

Cet objectif se décline en plusieurs sous-objectifs :

1. construire une chaîne de traitement capable de transformer une vidéo en données textuelles et temporelles persistantes ;
 2. définir une représentation textuelle structurée qui conserve l'ordre temporel, les scènes, le dialogue et certains indices visuels ;
 3. mettre en place un jeu d'évaluation reproductible et une base de données permettant de comparer plusieurs représentations, plusieurs consignes et plusieurs familles de modèles ;
 4. mesurer le compromis entre qualité de sélection, volume de contexte, temps de réponse et coût ;
-

5. examiner, dans une campagne complémentaire, si l’ajustement fin de modèles plus petits peut lui aussi servir à déplacer une partie du calcul vers l’amont.

Ces objectifs ne sont plus seulement des intentions. La chaîne a été construite, le jeu `validation29` a été monté, plusieurs conditions ont été comparées, et une campagne historique sur l’ajustement fin des modèles Gemini a pu être réintégrée à l’analyse.

1.4 Contributions originales

Les contributions du mémoire se situent à plusieurs niveaux. La première est la construction d’une chaîne locale qui transforme la vidéo en texte structuré exploitable par un modèle textuel. La deuxième est la mise en place d’un jeu d’évaluation reproductible, avec une base SQLite qui conserve les contextes, les exécutions, les coûts et les scores.

La troisième contribution est la comparaison elle-même. Le mémoire ne se contente pas de montrer qu’une représentation texte est possible. Il montre aussi ce qu’elle vaut par rapport à une entrée vidéo directe, par rapport à une variante sans descriptions visuelles, et par rapport à une simple transcription. Il ajoute en plus une lecture complémentaire sur l’ajustement fin, pour montrer qu’il existe une autre manière de déplacer le calcul.

Enfin, le travail a aussi une contribution pratique. Une partie des abstractions construites pour le jeu d’évaluation a à nouveau été utilisée dans `mecene-clips`. Cela ne remplace pas la validation scientifique, mais cela montre que la méthode est assez stable pour sortir du cadre purement expérimental.

TABLEAU 1.1 Correspondance entre les contributions et les chapitres du mémoire

Contribution	Preuve principale	Emplacement principal
Pipeline multimodal vers texte structuré	Code du benchmark et description méthodologique	Chapitres 3 et 4
Benchmark <code>validation29</code> reproductible	Base SQLite, scripts de préparation et d’exécution	Chapitres 3 et 4
Comparaison structuré-texte vs entrée vidéo directe	Exécutions complètes sur 29 échantillons	Chapitre 4
Transfert vers une application de production	Intégration dans <code>mecene-clips</code>	Chapitre 5

1.5 Plan du document

Le chapitre 2 présente l'état de l'art et situe le travail par rapport à la détection de moments saillants, aux approches multimodales sur vidéos longues et aux représentations intermédiaires. Le chapitre 3 explique la logique du mémoire combiné et la manière dont l'article, le jeu d'évaluation et l'application s'articulent.

Le chapitre 4 contient l'avant-propos exigé par le protocole, puis l'article central. C'est là que sont présentés la méthode, la représentation, le jeu d'évaluation et les principaux résultats. Le chapitre 5 revient ensuite sur la portée de ces résultats, sur la campagne complémentaire d'ajustement fin et sur le transfert vers le produit. Enfin, le chapitre 6 résume les contributions validées par le mémoire et ouvre sur les prolongements les plus importants.

CHAPITRE 2

Etat de l'art

L'état de l'art pertinent pour ce mémoire ne relève pas d'un seul sous-domaine. Il se situe au croisement de la localisation temporelle, de la détection de moments saillants, du raisonnement sur vidéos longues par grands modèles, et des représentations intermédiaires capables de condenser une vidéo sans en annuler le signal utile. Cette revue est donc organisée autour d'une question unique : quelle forme de représentation permet de conserver l'information nécessaire à la sélection d'un moment saillant, tout en restant compatible avec des contraintes fortes de coût, de latence et de puissance machine ?

Depuis la rédaction du DPR, trois points méritent toutefois d'être ajoutés pour mieux situer les résultats obtenus. D'abord, disposer d'un long contexte ne garantit pas que le modèle saura vraiment exploiter l'information utile lorsqu'elle est dispersée dans la séquence [15]. Ensuite, des travaux récents sur l'ajustement fin montrent que la qualité et la sélection des données comptent souvent davantage que leur simple volume [7]. Enfin, d'autres travaux montrent qu'un ajustement fin peut aussi dégrader des capacités déjà acquises lorsqu'il spécialise trop fortement le modèle [12]. Ces ajouts ne changent pas la structure générale de l'état de l'art du DPR, mais ils permettent de mieux lire les résultats du présent mémoire.

2.1 Détection de moments saillants dans les vidéos longues

La sélection d'un moment saillant dans une vidéo longue appartient à une famille de problèmes où il faut localiser temporellement un segment pertinent plutôt que produire une décision globale sur l'ensemble de la séquence. Les premiers travaux sur la localisation de moments par langage naturel montrent déjà que la difficulté ne tient pas seulement à la compréhension sémantique du contenu, mais aussi à l'estimation correcte des bornes temporelles [8, 4]. Des travaux plus récents, comme QVHighlights ou le jeu d'évaluation proposé par Chae et al., confirment que l'évaluation pertinente doit tenir compte à la fois du contenu choisi et de son recouvrement temporel avec la référence [10, 1].

Dans les vidéos longues, cette difficulté est accentuée par la coexistence de plusieurs pics locaux d'intérêt. Plusieurs segments peuvent paraître plausibles à l'échelle locale, tout en n'étant pas le meilleur choix pour un extrait autonome. Les travaux en détection de highlights et en localisation de moments montrent ainsi que la hiérarchisation de passages concurrents est aussi importante que la détection du bon thème [16, 19, 6]. Cette propriété explique pourquoi la qualité de la repré-

sensation intermédiaire devient une variable scientifique centrale : une représentation insuffisante peut perdre le bon signal ; une représentation trop abondante peut au contraire noyer la décision dans des indices concurrents.

Pour le présent mémoire, la détection de moments saillants ne constitue pas une fin en soi. Elle sert de tâche aval exigeante pour évaluer une représentation vidéo transformée en texte. Si cette représentation préserve effectivement les indices utiles, un sélectionneur textuel doit pouvoir retrouver un passage proche du clip de référence. Si elle les déforme ou les disperse, l'écart apparaîtra immédiatement dans les mesures de recouvrement temporel et textuel.

2.2 Raisonnement sur vidéos longues avec grands modèles de langage et modèles vision-langage

La progression récente des grands modèles de langage et des modèles vision-langage a profondément changé la compréhension vidéo. Les enquêtes de Tang et al. et de Zhou et al. montrent que ces modèles permettent d'unifier des tâches auparavant traitées séparément, qu'il s'agisse de question-réponse, de résumé, de localisation ou de raisonnement multimodal [20, 27]. Des architectures comme Video-LLaMA illustrent bien ce potentiel en rendant possible une interaction de haut niveau avec des contenus audiovisuels [26].

Le traitement de vidéos longues soulève toutefois une difficulté bien documentée : il faut comprimer, échantillonner ou hiérarchiser l'information avant la décision finale. LongVLM, VideoLLM, les approches de question-réponse sur vidéo longue fondées sur la recherche, ainsi que les variantes introduisant explicitement des repères temporels, poursuivent toutes cet objectif sous des formes différentes [23, 2, 24, 13, 9, 5]. Le constat commun est clair : la vidéo longue ne peut pas être injectée telle quelle dans le modèle sans mécanisme de réduction ou d'organisation.

Cette difficulté ne concerne pas seulement la taille de la fenêtre de contexte. Liu et al. montrent que, même lorsque le contexte tient dans le modèle, l'information située au milieu de longues séquences est souvent moins bien exploitée que celle placée au début ou à la fin [15]. Pour le présent mémoire, ce point est central : ajouter plus de descriptions textuelles n'est pas automatiquement synonyme de meilleur raisonnement si la forme globale du contexte devient plus difficile à utiliser.

Pour le mémoire, cette littérature ne justifie pas un rejet des approches multimodales directes. Elle montre plutôt qu'elles sont puissantes mais structurellement coûteuses. Même lorsqu'elles produisent un bon raisonnement, elles exigent un budget de contexte et une infrastructure d'inférence qui deviennent rapidement prohibitifs dès que les requêtes se multiplient, que la latence compte, ou que l'exécution doit rester compatible avec une machine contrainte. C'est dans cet espace que s'inscrit la présente recherche : non pas contre la compréhension multimodale, mais contre l'idée qu'elle doive rester entièrement directe jusqu'au dernier étage de décision.

2.3 Représentations multimodales vers texte et états persistants

Une vidéo peut être comprimée de plusieurs façons : par échantillonnage visuel, par fusion multimodale interne, par recherche hiérarchique, ou par textualisation progressive. Des travaux comme CLIPBERT montrent déjà qu'un échantillonnage parcimonieux peut suffire à préserver une partie importante du signal utile [11]. UMT et Slot-VLM vont plus loin en structurant les interactions entre modalités pour mieux guider des tâches de localisation et de compréhension [16, 25]. Whisper, de son côté, rend très abordable la production d'un socle verbal horodaté fiable [18].

Ce mémoire prolonge cette logique dans une direction particulière : la représentation finale remise au modèle de décision est entièrement textuelle. Le texte n'est cependant pas traité comme un simple résumé libre. Il sert de support de structuration. Les scènes, les transitions, les prises de parole, les personnes visibles et certains indices visuels y sont organisés dans un ordre stable, persistant en base de données et réutilisable par d'autres consignes ou d'autres modèles. Cette distinction est importante : l'objectif n'est pas seulement de raccourcir la vidéo, mais de la transformer en un état logiciel exploitable dans le temps.

La littérature offre plusieurs intuitions voisines, par exemple sur le rôle de la mémoire, de la structuration interne ou des représentations intermédiaires [3, 16]. Ce qui manque toutefois est une comparaison explicite entre une telle représentation textuelle persistante et une entrée vidéo directe, sur une tâche concrète et sous contrainte de ressources. C'est précisément la lacune empirique à laquelle le mémoire cherche à répondre.

2.4 Robotique, systèmes incarnés et analogues pratiques

La pertinence du problème dépasse le seul cas du découpage de clips. Dans un système robotique ou embarqué, la perception vidéo longue doit souvent être condensée avant d'être exploitée par un raisonnement de plus haut niveau, faute de quoi le coût de calcul, la latence et la dépendance à une infrastructure distante deviennent vite incompatibles avec les contraintes de déploiement. Des plateformes expérimentales robotiques rappellent cette réalité très concrète : la puissance disponible à bord est finie, et l'architecture logicielle doit choisir où placer le calcul [17].

Le domaine du découpage automatique de vidéos agit ici comme analogue pratique. Il impose un besoin opérationnel clair, proche d'une tâche de perception appliquée : repérer rapidement un passage utile dans une séquence longue et transformer cette décision en action logicielle. Des travaux comme LAVE montrent d'ailleurs que l'assistance à l'édition vidéo par grands modèles constitue un terrain crédible pour articuler perception, langage et action [22]. Le clipping n'est donc pas un simple cas d'usage commercial ; il fournit un environnement de mesure pour une question plus générale de compréhension vidéo sous contraintes.

2.5 Lacune ciblée par le mémoire

L'examen de la littérature fait ressortir trois manques articulés. Premièrement, il existe encore peu de comparaisons propres entre une représentation textuelle issue d'une chaîne multimodale et une entrée vidéo directe, sur une tâche aval identique et avec des mesures de coût explicites. Deuxièmement, les travaux existants décrivent rarement la représentation intermédiaire comme un artefact persistant, consultable et réutilisable dans un dispositif logiciel plus large. Troisièmement, la littérature documente encore peu le lien entre qualité de représentation, taille du modèle final et choix entre enrichissement de contexte ou ajustement fin du modèle. Les travaux récents sur la sélection des données d'ajustement fin et sur l'oubli catastrophique montrent pourtant que cette question devient importante dès qu'on cherche un compromis robuste entre qualité, coût et spécialisation du modèle [7, 12].

Le mémoire répond à cette lacune en proposant un jeu d'évaluation reproductible, une base SQLite centralisant les représentations et les résultats, une famille de représentations textuelles comparables, ainsi qu'une campagne complémentaire sur l'ajustement fin de plusieurs modèles Gemini. L'article central s'intéresse plus particulièrement à la représentation vidéo transformée en texte comme état persistant ; le mémoire, dans son ensemble, porte la thèse plus large du compromis qualité/coût sous contrainte de ressources.

CHAPITRE 3

Articulation du memoire combine

Ce chapitre sert à clarifier la structure du document. Le point important est simple : le coeur scientifique du travail tient dans un seul article, mais le mémoire reste nécessaire pour expliquer d'où vient la question, ce que l'article couvre, ce qu'il ne couvre pas, et pourquoi l'ensemble forme un seul projet cohérent.

3.1 Pourquoi un memoire combine centré sur un seul article

Le format retenu est un mémoire combiné centré sur un seul article. Ce choix vient directement de la nature du projet. Il n'y a pas ici plusieurs contributions indépendantes qui justifieraient plusieurs articles distincts. Il y a une seule question centrale, un seul jeu d'évaluation principal, une seule chaîne de traitement et une seule famille de représentations à comparer. Tout cela forme un bloc scientifique unique.

L'article suffit donc pour porter la preuve expérimentale principale. Il permet de montrer comment la vidéo est transformée en texte, comment cette représentation est utilisée, et quels résultats elle donne sur le jeu `validation29`. Le mémoire, de son côté, garde un rôle essentiel : il reprend la logique du DPR, situe le travail dans une perspective plus large de coût et de ressources, et discute la portée du projet au-delà de la seule expérience centrale.

3.2 Lien entre l'article, l'infrastructure de représentation et l'application

L'article repose directement sur l'infrastructure du dossier `benchmark` dans `mecene-clips`. C'est là que se trouvent le jeu d'évaluation, les contextes, les profils de modèles, les exécutions et les coûts. Cette infrastructure n'est pas un simple détail d'implémentation. Elle fait partie de la contribution, parce qu'elle rend la comparaison reproductible et permet de suivre proprement les itérations qui ont mené à la représentation retenue.

L'application `mecene-clips` joue un autre rôle. Elle montre que les choix faits pour le benchmark peuvent aussi vivre dans un produit. Cela donne du poids à l'idée que la représentation construite est assez stable pour être réutilisée dans un vrai système logiciel. Il faut toutefois garder la distinction suivante : le benchmark sert à prouver scientifiquement quelque chose ; l'application sert à montrer que ce quelque chose peut être transféré.

3.3 Ce que l'article couvre, et ce que le memoire ajoute

L'article couvre la partie la plus resserrée du travail. Il présente le jeu d'évaluation, la chaîne de traitement, la représentation textuelle, le protocole de comparaison et les résultats. Autrement dit, il répond à la question : comment cette approche fonctionne-t-elle, et qu'est-ce qu'elle donne ?

Le mémoire ajoute ce que l'article, à lui seul, ne dirait pas assez bien. Il revient d'abord au DPR et à la question initiale de réduction du coût. Il explique ensuite pourquoi cette question est pertinente pour des systèmes contraints, notamment en robotique. Enfin, il discute ce que les résultats permettent vraiment d'affirmer, les limites du jeu d'évaluation, et la place du transfert vers le produit.

En bref, l'article porte la preuve centrale. Le mémoire porte la thèse générale du projet.

3.4 Etat actuel des preuves

L'état actuel des preuves peut se lire assez simplement. D'abord, l'infrastructure est en place : le jeu `validation29` est stabilisé, les coûts sont centralisés dans la base, et les vues de rapport permettent de régénérer les tableaux du mémoire. Ensuite, il y a tout le travail exploratoire. Il a servi à tester rapidement plusieurs représentations pour voir lesquelles méritaient d'être poussées plus loin.

Les preuves principales viennent toutefois des exécutions complètes et des ablations contrôlées. Sur les exécutions 29/29, la transcription brute sous **Gemini 3.1 Flash Lite** atteint 0.323, la représentation `typed-v1` sous **Grok 4.1 Fast** atteint 0.301, et l'entrée vidéo directe sous **Gemini 3.1 Flash Lite** atteint 0.273. Dans l'ablation contrôlée sous Gemini, la variante `typed-novlm-v1` atteint 0.315, alors que la variante `typed-v1` avec descriptions visuelles textuelles tombe à 0.240 lorsque l'item non aligné est compté à zéro.

Il faut ajouter à cela la base historique `test_llms.db`. Elle ne remplace pas la preuve principale, mais elle ajoute une information importante sur l'ajustement fin. Elle montre que le déplacement du calcul peut aussi se faire en amont, dans le modèle lui-même, et que cette stratégie ne fonctionne pas de la même manière selon la taille du modèle. C'est ce point qui reliera plus tard le mémoire à une lecture plus système, et pas seulement à une lecture de benchmark.

CHAPITRE 4

Article central

Avant-propos

Titre provisoire de l'article : Représentations textuelles structurées issues d'une chaîne multimodale pour la détection de moments saillants dans de longues vidéos

Auteurs pressentis : Alexandre Lafleur ; François Grondin

Affiliations et statuts pressentis : Alexandre Lafleur, étudiant à la maîtrise, Département de génie électrique et de génie informatique, Université de Sherbrooke ; François Grondin, professeur, Département de génie électrique et de génie informatique, Université de Sherbrooke

Etat de l'article : manuscrit en préparation, non soumis au moment du dépôt de cette version du mémoire

Revue visée : revue internationale en intelligence artificielle appliquée ; la cible finale sera fixée avec la direction au moment de la soumission

Date de soumission ou d'acceptation : sans objet à ce stade ; la soumission est prévue après le gel final des figures, des tableaux et des derniers contrôles expérimentaux

Référence de l'article accepté ou publié : sans objet à ce stade

Contribution de l'article au mémoire : l'article porte la contribution scientifique centrale du mémoire. Il présente la chaîne de transformation vidéo vers texte, la structuration persistante des artefacts en base, le jeu d'évaluation `validation29`, les comparaisons quantitatives entre représentations textuelles et entrée vidéo directe, ainsi que les enseignements complémentaires tirés d'une campagne historique d'ajustement fin de modèles Gemini.

Nature de la version insérée dans le mémoire : le manuscrit inséré ci-dessous est une version adaptée au format du mémoire et rédigée en français. Une soumission ultérieure pourra être traduite en anglais et reformatée selon les exigences de la revue retenue, sans modification du noyau méthodologique ni des résultats principaux rapportés ici.

4.1 Introduction

Analyser une vidéo longue directement avec un modèle multimodal est aujourd’hui possible, mais c’est coûteux [20, 27, 26, 21]. Si l’on veut traiter beaucoup de vidéos, ou si l’on veut le faire avec une machine limitée, ce coût devient rapidement un vrai problème. C’est encore plus vrai quand la tâche finale est simple à formuler : choisir un seul bon moment dans une vidéo de plusieurs minutes.

Une première solution consiste à ne garder que la transcription. C’est beaucoup moins cher, mais cela enlève une partie de l’information utile. Un moment fort ne dépend pas seulement de ce qui est dit. Il peut dépendre d’un changement de scène, d’un cadrage, d’une personne qui apparaît, d’une réaction visuelle, ou d’un contraste entre le verbal et le visuel. À l’inverse, garder la vidéo jusqu’au bout laisse ce signal disponible, mais oblige à payer une inférence plus lourde à chaque exécution.

L’idée de cet article est de prendre une voie intermédiaire. Au lieu de demander au modèle final de raisonner directement sur la vidéo, nous transformons la vidéo en un état textuel structuré. Cet état garde l’ordre temporel, les scènes, la parole et certains indices visuels. Ensuite, différentes vues textuelles peuvent être dérivées de cet état et envoyées à un sélectionneur textuel. La vue la plus complète est `timeline-scenes-dialogue-typed-v1`. D’autres vues plus simples, comme `transcript-v1` et `typed-novlm-v1`, permettent de voir ce que chaque niveau de représentation apporte vraiment.

La contribution de l’article est donc triple. Nous présentons d’abord un jeu d’évaluation reproductible de 29 paires segment source / clip de référence. Nous décrivons ensuite une chaîne de traitement qui transforme la vidéo en données textuelles persistantes. Enfin, nous comparons plusieurs façons d’utiliser ces données, et nous montrons que des conditions texte d’abord dépassent l’entrée vidéo directe sur le jeu d’évaluation retenu. Le point important n’est pas seulement qu’une représentation texte fonctionne. C’est qu’elle peut fonctionner tout en étant beaucoup plus facile à réutiliser dans le temps.

4.2 Travaux connexes

Le travail s’inscrit d’abord dans la littérature sur la localisation temporelle et la détection de moments saillants. Ces travaux montrent qu’il faut non seulement trouver le bon passage, mais aussi bien le délimiter dans le temps [8, 4, 10, 1]. Cette distinction est importante pour nous, parce qu’un bon extrait doit être proche du clip de référence à la fois dans son contenu et dans ses bornes temporelles.

Le travail s’inscrit aussi dans la littérature sur les grands modèles vision-langage appliqués aux vidéos longues. Des approches comme Video-LLaMA, VTimeLLM, VTG-LLM, LongVLM ou les approches fondées sur la recherche montrent bien qu’il est possible de raisonner sur des vidéos

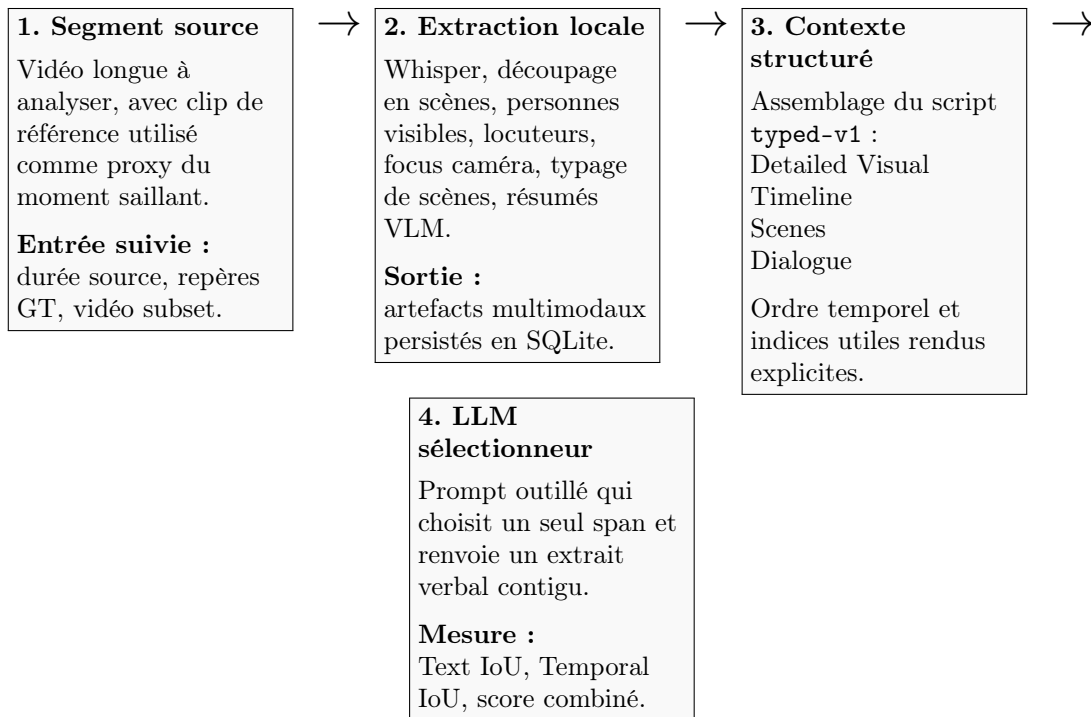


FIGURE 4.1 Vue d'ensemble du pipeline proposé, depuis le segment source jusqu'au span final sélectionné.

complexes avec des modèles très puissants [26, 9, 5, 23, 2, 24, 13]. Le problème, pour notre question, n'est pas qu'elles ne fonctionnent pas. Le problème est plutôt leur coût et leur lourdeur lorsqu'on veut les utiliser souvent ou dans un système contraint. Ce point est renforcé par des travaux montrant que, même lorsque l'information tient dans un long contexte, elle n'est pas exploitée de manière uniforme par le modèle [15]. Cela rend particulièrement importante la forme sous laquelle on présente l'information.

Enfin, plusieurs travaux montrent qu'il est possible de compresser le signal vidéo avant la décision finale [11, 16, 25]. Notre travail se situe dans cette direction, mais avec une différence importante : la représentation finale n'est pas cachée dans le modèle. Elle est lisible, stockée en base et réutilisable. C'est cette propriété qui manque souvent dans les approches plus directes, et c'est elle que nous voulons mettre de l'avant ici.

4.3 Jeu d'évaluation et construction des données

TABLEAU 4.1 Statistiques descriptives du benchmark validation29

Paires	Durée source moyenne (s)	Durée source min-max (s)	Durée GT moyenne (s)	Durée GT min-max (s)	Couverture VLM
29	320.5	120.1-605.0	53.5	17.3-75.0	29/29

Le jeu d'évaluation principal est `validation29`. Il contient 29 paires composées d'un segment source relativement long et d'un clip de référence plus court provenant du même contenu. Les segments source durent en moyenne 320.5 s, alors que les clips de référence durent 53.5 s en moyenne. Le but est simple : retrouver, dans le segment source, le passage le plus proche possible du clip de référence.

Ce choix a deux avantages. D'abord, il donne une tâche concrète, proche d'un besoin réel de découpage. Ensuite, il permet de comparer plusieurs représentations sur exactement les mêmes cas. Tout est stocké dans SQLite : les vidéos, les échantillons, les contextes, les profils de modèles, les consignes, les exécutions, les coûts et les scores par cas. Cette structure est importante, parce qu'elle permet de refaire les tableaux, de revoir les itérations et de distinguer les essais rapides des comparaisons vraiment défendables.

4.4 Chaîne de prétraitement multimodal

La chaîne de traitement suit une logique simple. On commence par transcrire l'audio avec Whisper [18]. Ensuite, on découpe la vidéo en scènes et on ajoute plusieurs analyses visuelles : personnes visibles, visages, locuteur actif, cadrage et descriptions visuelles. Chaque étape produit des données intermédiaires qui sont conservées en base.

Le point important n'est pas seulement qu'il y a plusieurs modules. C'est que leurs sorties sont normalisées dans une même structure. Cela permet de reconstruire plusieurs vues textuelles sans devoir tout recalculer. En pratique, la chaîne sert donc à fabriquer un état vidéo textuel que l'on peut ensuite relire et transformer selon la tâche.

TABLEAU 4.2 Composantes principales du pipeline et sorties persistées

Etape	Rôle	Sorties utiles pour la représentation
Whisper / diarization	Transcription et alignement de la parole	mots horodatés, segmentation des locuteurs
Scene detection	Découpage temporel	bornes de scènes
YOLO / faces / ASD	Visages, activité des locuteurs, association personnes	personnes visibles, locuteurs probables, activité
Scene classification	Typage A-roll / B-roll	type de scène et personnes visibles
Camera focus	Indice de cadrage et continuité	segments de focus caméra
VLM summaries	Description visuelle textuelle	descriptions d'images, résumés de scènes
TOON script	Représentation textuelle compacte	dialogue et structure scénique utilisables par le sélectionneur

4.5 Représentation textuelle structurée

TABLEAU 4.3 Variantes de contexte disponibles sur l'ensemble complet

Contexte	Couverture	Taille moyenne (car.)	Min	Max
typed-timestamps-v1	29	30923	9826	81154
typed-numbered-v1	29	30916	9797	81361
typed-v1	29	30662	9800	80132
typed-novlm-v1	29	10112	3077	35306
detailed-script-v1	29	9220	2279	44159
no-vm-v1	29	9204	2706	30983
detailed-vm-script-v1	29	8595	2372	23420
transcript-v1	29	5072	1841	11197

La vue la plus riche de cet état est **timeline-scenes-dialogue-typed-v1**. Elle garde la chronologie, les scènes, les blocs de dialogue et certains indices visuels. Ce n'est pas un résumé libre. C'est une structure de travail. Le modèle final peut y voir où une scène commence, qui parle, qui est visible et quels indices visuels ressortent à ce moment-là.

Il faut bien distinguer deux choses. D'un côté, cette vue est celle qui représente le mieux l'état complet de la vidéo. De l'autre, ce n'est pas elle qui donne le meilleur score dans toutes les comparaisons. C'est précisément pour cela que nous la comparons à d'autres vues. **typed-novlm-v1** garde la structure, mais enlève les descriptions visuelles textuelles. **transcript-v1** garde seulement la parole. Cette famille de vues permet de voir plus clairement ce qui aide vraiment.

4.6 Configuration du sélectionneur et métriques d'évaluation

Les comparaisons sont organisées en trois niveaux. Le premier niveau est exploratoire : il sert à tester rapidement des variantes de contexte et de consigne sur peu de cas. Le deuxième niveau regroupe les exécutions complètes, qui servent aux conclusions principales. Le troisième niveau est une ablation contrôlée sous `google/gemini-3.1-flash-lite-preview`, où seule la représentation change.

Dans cette ablation, quatre conditions sont comparées : la transcription brute **transcript-v1**, la variante structurée sans descriptions visuelles **typed-novlm-v1**, la variante structurée avec descriptions visuelles **typed-v1**, et l'entrée vidéo directe. Le modèle sélectionneur, la logique de sortie et le jeu d'évaluation restent les mêmes. C'est ce qui permet d'isoler proprement l'effet de la représentation.

L'évaluation repose sur deux mesures principales : le *text IoU*, qui mesure le recouvrement textuel avec la référence, et le *temporal IoU*, qui mesure le recouvrement temporel. Le score combiné est

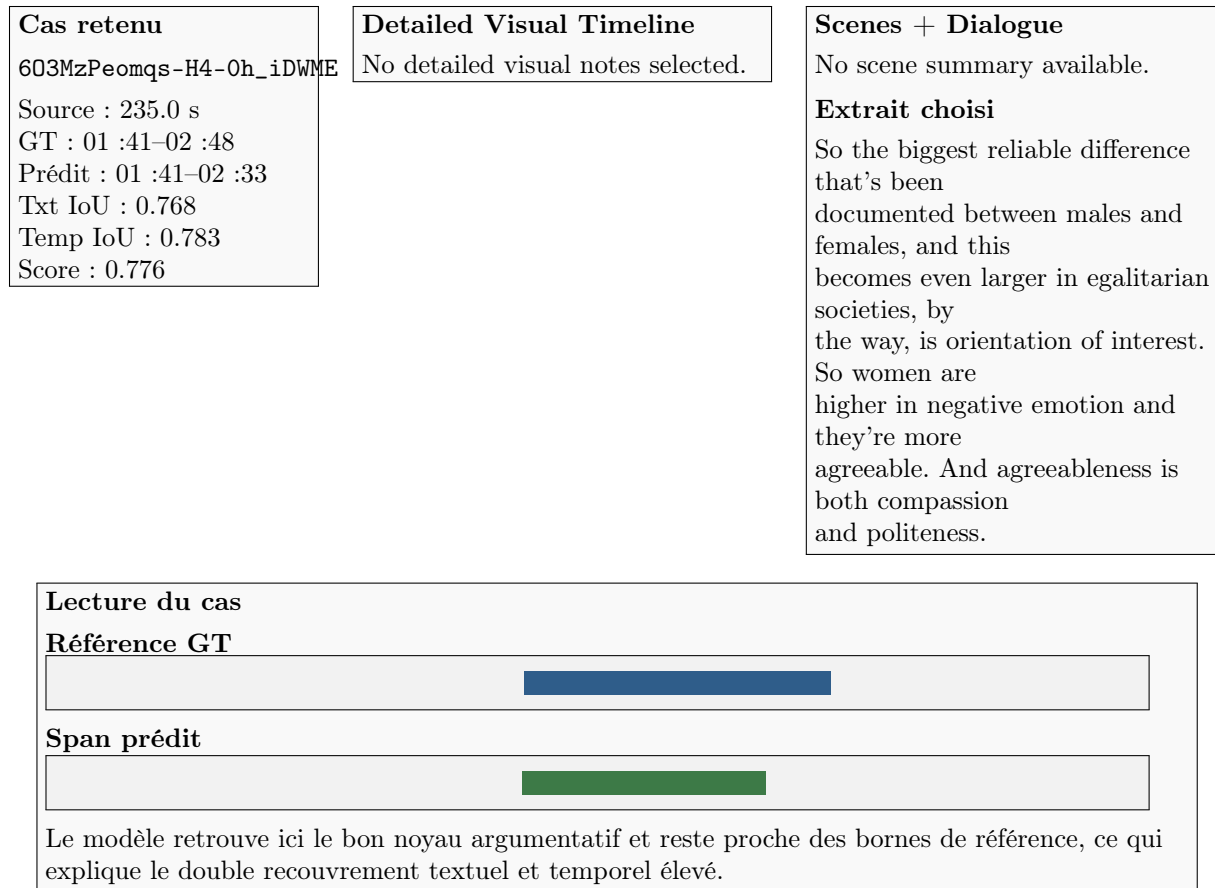


FIGURE 4.2 Exemple concret de transformation d'une vidéo en contexte structuré, puis en span sélectionné par le modèle.

la moyenne des deux. Nous rapportons aussi les coûts, à la fois pour le sélectionneur seul et pour une première exécution incluant la création des données lorsque cette étape existe.

4.7 Résultats quantitatifs

Les résultats se lisent en trois temps. Le premier est exploratoire. Il montre comment la représentation a évolué. Les premières variantes très simples donnent des scores faibles. En structurant davantage la chronologie, les scènes et le dialogue, les scores montent progressivement jusqu'à 0.528 sur cinq cas. Ce n'est pas une conclusion finale, mais c'est important pour comprendre pourquoi certaines représentations ont été retenues et d'autres abandonnées.

Le deuxième temps est celui des exécutions complètes. Sur `validation29`, le meilleur score complet observé est obtenu par la transcription brute sous `Gemini 3.1 Flash Lite`, avec 0.323. La meilleure exécution complète de `typed-v1` atteint 0.301 sous `Grok 4.1 Fast`. L'entrée vidéo directe sous `Gemini 3.1 Flash Lite` atteint 0.273. Ce que ces chiffres montrent, c'est d'abord qu'une approche texte d'abord est tout à fait viable. Ils montrent aussi que la vue la plus riche de l'état vidéo n'est pas forcément celle qui maximise le score brut du sélectionneur.

TABLEAU 4.4 Synthèse des pilotes exploratoires utilisés pour faire évoluer la représentation

Contexte	Prompt pilote	Modèle pilote	n pilote	Score combiné	n max
transcript-v1	transcript-selector-v1-tool-v1	gemini-3.1-flash-lite	1	0.301	1
scene-grouped-dialogue-script-v1	selector-v2	claude-sonnet-4.6	5	0.470	5
scene-grouped-v1	selector-v2	gpt-5.3-codex	5	0.150	5
timeline-scenes-inline-v1	selector-v2	claude-sonnet-4.6	5	0.324	5
scenes-dialogue-inline-v1	selector-v2	claude-sonnet-4.6	5	0.434	5
timeline-dialogue-inline-v1	selector-v2	claude-sonnet-4.6	5	0.471	5
scene-details-dialogue-inline-v1	selector-v2	gemini-3.1-flash-lite	5	0.333	5
typed-v1	selector-v2	gemini-3.1-flash-lite	5	0.528	28
typed-numbered-v1	selector-sentences-v1	gemini-3.1-flash-lite	5	0.308	5
typed-timestamps-v1	selector-timestamps-v1	claude-sonnet-4.6 (r :med)	5	0.422	15
no-vlm-v1	scenes-selector-tool-v1	gemini-3.1-flash-lite	24	0.343	24
typed-novlm-v1	selector-v2-tool-v1	gemini-3.1-flash-lite	28	0.319	28

Le troisième temps est l’ablation contrôlée sous Gemini. C’est elle qui permet de comprendre ce qui se passe vraiment. La transcription brute atteint 0.323. La variante structurée sans descriptions visuelles atteint 0.315. L’entrée vidéo directe reste à 0.273. Et la variante **typed-v1** avec descriptions visuelles textuelles descend à 0.240 lorsque l’échec d’alignement restant est compté à zéro. La lecture la plus simple est donc la suivante : la structure temporelle et dialoguée reste utile, mais les descriptions visuelles textuelles actuelles n’aident pas le sélectionneur. Elles alourdissent plutôt le contexte sans gain net. Ce résultat va dans le même sens que les travaux sur l’usage des longs contextes : ajouter de l’information ne suffit pas, encore faut-il que le modèle sache la retrouver et l’utiliser au bon moment [15].

Le coût confirme cette lecture. Si l’on regarde seulement le sélectionneur final, les approches textuelles coûtent beaucoup moins cher que l’entrée vidéo directe. Si l’on ajoute le coût de création des données, la transcription brute reste la condition la plus économique sur une première exécution, alors que les vues structurées rejoignent l’ordre de grandeur de l’entrée vidéo directe. Cela ne retire pas leur intérêt. Cela veut dire que leur valeur devient surtout claire lorsqu’on réutilise le même état vidéo plusieurs fois.

Une base historique complémentaire, `test_llms.db`, permet d’ajouter un autre angle d’analyse. Elle montre l’effet de l’ajustement fin sur plusieurs variantes Gemini, et elle est pertinente parce

TABLEAU 4.5 Jalons où un changement de représentation ou de prompt améliore le meilleur score exploratoire connu

Date	Contexte	Prompt	Modèle	n	Score
2026-03-01	transcript-v1	basic-selector	llama-3.3-70b-versatile	1	0.031
2026-03-03	scene-grouped-dialogue-script-v1	selector-v2	gpt-5.3-codex	5	0.152
2026-03-04	scene-grouped-dialogue-script-v1	selector-v2	claude-sonnet-4.6	5	0.470
2026-03-04	timeline-dialogue-inline-v1	selector-v2	claude-sonnet-4.6	5	0.471
2026-03-04	typed-v1	selector-v2	gemini-3.1-flash-lite	5	0.528

TABLEAU 4.6 Conditions complètes sur 29 échantillons retenues pour les revendications principales

Condition	Modèle	Contexte	Txt IoU	Temp IoU	Score	Tokens	Run/video	Contexte/video	1er passage
Structured text	gemini-3.1-flash-lite	transcript-v1	0.388	0.257	0.323	2047	0.001	0.004	
Structured text	grok-4.1-fast	typed-v1	0.372	0.230	0.301	11885	0.003	0.005	
Direct video	gemini-3.1-flash-lite	video-direct-v1	0.338	0.208	0.273	29191	0.008	0.000	

qu'elle a représenté un coût amont d'environ 1000 USD en crédits Google. Le cas le plus frappant est **Gemini 2.5 Flash**, qui passe d'environ 0.300 à 0.437 après ajustement fin texte. En revanche, **Flash-Lite** passe de 0.361 à 0.316. La conclusion proposée est qu'il existe une limite de capacité : **Flash-Lite** semble trop petit pour vraiment apprendre la tâche, alors que **Flash** semble être au bon niveau de taille pour en bénéficier. Ce type de gain rejoint des travaux récents montrant qu'un ajustement fin bien ciblé peut tirer beaucoup de valeur d'un ensemble de données choisi avec soin plutôt que d'un volume maximal [7].

Cette base permet aussi de voir l'effet d'un premier enrichissement par objets. Une variante différentielle reste presque neutre, alors qu'une variante plus lourde dégrade le score. Enfin, sur **Gemini 2.5 Pro**, le modèle de base atteint 0.392, la version ajustée sur le texte seul tombe à 0.363, et la version ajustée avec texte et objets remonte à 0.405. La lecture la plus convaincante est donc la suivante : les grands modèles profitent davantage d'un meilleur contexte que d'un ajustement fin trop étroit, alors que certains modèles plus petits peuvent bénéficier d'un meilleur alignement. Cette baisse après ajustement fin texte seul est cohérente avec des travaux montrant qu'une spécialisation trop serrée peut dégrader des capacités déjà acquises lors de l'ajustement d'un grand modèle [12].



FIGURE 4.3 Comparaison de deux cas de succès et de deux cas d'échec du meilleur run structuré complet. Les succès combinent recouvrement thématique et calibration temporelle ; les échecs gardent parfois un signal sémantique partiel mais ratent la bonne fenêtre temporelle.

TABLEAU 4.7 Comparaison contrôlée sous Gemini 3.1 Flash Lite : même modèle, même protocole de sortie, et variation explicite de la représentation d’entrée

Condition	Couverture	Txt IoU	Temp IoU	Score	Tokens	Run/video	Contexte/video	1er pas
Structured text + VLM	29 cas (1 échec d’alignement compté à 0)	0.310	0.170	0.240	10053	0.003	0.005	
Structured text sans VLM	29 cas (28 run principal + 1 retry ciblé)	0.382	0.248	0.315	4433	0.001	0.005	
Transcript brut	29 cas (run complet)	0.388	0.257	0.323	2047	0.001	0.004	
Entrée vidéo directe	29 cas (run complet)	0.338	0.208	0.273	29191	0.008	0.000	

TABLEAU 4.8 Impact du fine-tuning sur les petites variantes Gemini 2.5, avec les mêmes 29 cas de validation lorsqu’ils sont disponibles

Variante	n	IoU moy.	Δ vs base	Temps (s)	Coût / 100 vid.
Flash de base	29	0.300	0.000	2.0	0.127
Flash fine-tune texte	27	0.437	0.137	21.6	0.110
Flash-Lite de base	29	0.361	0.000	2.0	0.032
Flash-Lite fine-tune texte	29	0.316	-0.045	1.2	0.027

4.8 Analyse des échecs et discussion

Les meilleurs cas montrent que les représentations textuelles peuvent vraiment porter un bon raisonnement. Quand la structure du contexte est bonne, le modèle retrouve non seulement le bon sujet, mais aussi le bon moment.

Les échecs, eux, suivent des motifs assez clairs. Il y a d’abord les cas où le bon passage est trouvé de manière approximative, mais mal délimité dans le temps. Il y a ensuite les cas où le modèle choisit un passage voisin, plausible, mais moins bon que le bon moment. Enfin, il y a les cas où la représentation est trop chargée et où les descriptions visuelles deviennent plus distrayantes qu’utiles.

Le point important est que ces échecs ne disent pas seulement « il manque de l’information ». Ils montrent surtout que la forme de l’information compte. C’est exactement ce que la campagne sur l’ajustement fin vient renforcer. Le vrai problème n’est pas simplement d’avoir plus de contexte ou moins de contexte. Le vrai problème est de donner à chaque modèle le type d’aide qu’il sait exploiter. Les travaux sur les longs contextes et sur l’oubli catastrophique vont dans le même sens : un modèle peut avoir accès à plus d’information ou être plus spécialisé, sans pour autant mieux s’en servir [15, 12].

4.9 Conclusion

Cet article montre qu’une approche texte d’abord peut servir de support principal à la sélection de moments saillants dans des vidéos longues. Sur `validation29`, plusieurs conditions textuelles font mieux que l’entrée vidéo directe. Cela suffit déjà à montrer qu’il n’est pas nécessaire de garder toute l’inférence multimodale jusqu’à la fin.

TABLEAU 4.9 Premiers essais d’augmentation visuelle par objets dans le contexte textuel

Variante	n	IoU moy.	Δ vs texte	Car. entrée	Temps (s)
Texte seul	29	0.369	0.000	5088	15.2
Texte + objets différentiels 7 s	29	0.369	0.001	7009	15.7
Texte + objets complets 7 s	29	0.343	-0.026	7398	14.8

TABLEAU 4.10 Comparaison des variantes Gemini 2.5 Pro : base, fine-tuning et entrée vidéo directe

Variante	n	IoU moy.	Δ vs base	Temps (s)	Coût / 100 vid.
Pro de base	29	0.392	0.000	22.1	0.841
Pro fine-tune texte	29	0.363	-0.028	26.3	0.879
Pro fine-tune texte + objets	29	0.405	0.013	23.6	0.879
Pro entree video directe	28	0.358	-0.033	45.6	cout non journalise

Mais la conclusion la plus importante est ailleurs. Transformer la vidéo en un état textuel structuré change la nature du problème. Au lieu de refaire une analyse lourde à chaque fois, on obtient une base de travail que l’on peut relire, comparer et réutiliser. C’est cette idée qui donne le plus de valeur à la représentation **typed-v1**, même si sa forme actuelle n’est pas encore optimale pour le sélectionneur final.

La suite logique du travail est donc claire. Il faut d’abord mieux choisir quel signal visuel vaut la peine d’être textualisé. Il faut ensuite continuer à distinguer, selon la taille du modèle, ce qui doit être réglé par le contexte et ce qui doit être réglé par l’ajustement fin. C’est à cette condition qu’une approche texte d’abord pourra vraiment devenir une solution robuste pour des systèmes contraints.

TABLEAU 4.11 Taxonomie initiale des échecs à valider dans l'analyse qualitative

Type d'échec	Description opérationnelle	Preuve attendue
Mauvaise frontière temporelle	Le bon sujet est choisi, mais le span ne recouvre pas la référence	IoU temporel faible avec similarité textuelle non nulle
Mauvais pic local	Le modèle s'arrête sur un segment voisin moins fort	Comparaison qualitative GT / prédiction
Signal visuel insuffisant	La transcription seule ou un contexte partiel manque un indice de mise en scène	Gain après ajout des résumés visuels
Biais dialogue-only	Le clip choisi est sémantiquement correct mais visuellement faible	Cas où le texte est plausible sans appui visuel clair
Sensibilité au contexte	Le résultat varie selon la forme du contexte plus que selon le contenu	Comparaison entre variantes de contexte

CHAPITRE 5

Discussion generale et transfert

Le chapitre précédent montrait les résultats. Le but ici est de revenir à la logique du projet. Il faut voir ce que ces résultats confirment par rapport au DPR, ce qu'ils ne permettent pas encore d'affirmer, et ce qu'ils changent dans la manière de penser une analyse vidéo avec peu de ressources.

5.1 Retour sur le DPR

Le DPR partait d'une intuition simple : au lieu de faire raisonner directement un modèle multi-modal lourd sur la vidéo, il devrait être possible de transformer la vidéo en texte, puis de confier l'analyse finale à un modèle textuel moins coûteux. Le travail réalisé confirme que cette intuition allait dans la bonne direction.

En même temps, la recherche a clarifié cette intuition. Le projet n'a pas seulement produit une représentation texte. Il a produit un jeu d'évaluation, une base de données de suivi, une estimation des coûts, et plusieurs vues textuelles qui permettent de comprendre ce qui aide réellement le modèle final. C'est important, parce que cela transforme une intuition de faisabilité en une comparaison mesurable.

5.2 Portée des résultats actuels

La première chose à garder en tête est que tous les résultats de la base n'ont pas la même valeur. Les essais sur un ou cinq cas ont servi à itérer rapidement. Ils sont utiles pour raconter le cheminement, mais ils ne doivent pas porter les conclusions principales. Les conclusions principales viennent des exécutions complètes et des ablations contrôlées.

Sur cette base, trois points ressortent clairement. D'abord, l'approche texte d'abord fonctionne. Sur `validation29`, la transcription brute et la variante structurée sans descriptions visuelles dépassent l'entrée vidéo directe dans la comparaison contrôlée sous Gemini. Ensuite, la représentation `typed-v1` reste importante, non parce qu'elle serait la meilleure partout, mais parce qu'elle représente la vue la plus riche et la plus réutilisable de l'état vidéo. Enfin, la textualisation visuelle actuelle ne semble pas aider. Dans sa forme actuelle, elle ajoute surtout du bruit et du coût. Cette lecture est cohérente avec des travaux montrant que les longs contextes ne sont pas exploités uniformément par les modèles, surtout lorsque l'information pertinente est noyée dans une grande quantité de texte [15].

Le point sur les coûts demande une lecture un peu plus nuancée. Si l'on regarde seulement l'appel final au sélectionneur, les approches textuelles coûtent beaucoup moins cher que l'entrée vidéo directe. Si l'on ajoute le coût de création des données sur une première exécution, la transcription brute reste la meilleure affaire, alors que les vues structurées reviennent à peu près dans le même ordre de grandeur que l'entrée vidéo directe. Cela veut dire que l'intérêt des vues structurées apparaît surtout quand on réutilise la même représentation plusieurs fois.

5.3 Enseignements complémentaires sur l'ajustement fin

La base `test_llms.db` ajoute un deuxième message important. Elle montre que le calcul peut être déplacé non seulement dans la représentation, mais aussi dans l'ajustement fin du modèle. Autrement dit, au lieu de payer plus cher à chaque inférence, on peut parfois payer en amont pour mieux aligner un modèle moins coûteux sur la tâche.

Le cas le plus parlant est **Gemini 2.5 Flash**. Il part bas, autour de 0.300, puis monte à 0.437 après ajustement fin texte. Cela suggère que ce modèle a la bonne taille pour apprendre une tâche précise sans perdre sa capacité utile de généralisation. Cela rejoint aussi des travaux comme SHED, qui montrent qu'un ajustement fin peut gagner beaucoup en efficacité lorsque les données sont bien choisies et bien calibrées pour la tâche [7].

Le cas de **Flash-Lite** montre la limite. Lui ne s'améliore pas. Il baisse même après ajustement fin. La conclusion qui en ressort est qu'il y a un seuil de capacité sous lequel un modèle reste trop petit pour vraiment apprendre ce qu'on lui demande, même si on essaie de le spécialiser.

Le cas de **Gemini 2.5 Pro** montre l'autre extrême. Le modèle de base est déjà fort. Quand on l'ajuste seulement sur le texte, il perd. Quand on lui ajoute plutôt un contexte plus riche avec des objets, il remonte. Cela suggère qu'un grand modèle profite plus d'un meilleur contexte que d'un ajustement fin trop étroit. Dit autrement : plus un modèle est gros, plus sa force semble être de raisonner sur plusieurs possibilités ; trop le contraindre peut donc lui enlever une partie de cet avantage. Cette interprétation est compatible avec des travaux récents sur l'oubli catastrophique lors de l'ajustement fin des grands modèles [12].

5.4 Lien avec l'application de production

Le transfert vers `mecene-clips` est important, mais il faut bien dire ce qu'il montre et ce qu'il ne montre pas. Il montre que les représentations et la logique de sélection construites dans le benchmark sont assez stables pour être reprises dans une application réelle. C'est une bonne indication que le travail ne tient pas seulement dans un contexte de laboratoire.

Par contre, ce transfert ne remplace pas la preuve scientifique. Une application de production doit surtout arbitrer entre latence, robustesse, maintenance et expérience utilisateur. Le benchmark,

lui, sert à comparer proprement des conditions et à mesurer ce qu'elles coûtent. Il faut donc lire le transfert comme une preuve de pertinence pratique, pas comme une seconde preuve expérimentale.

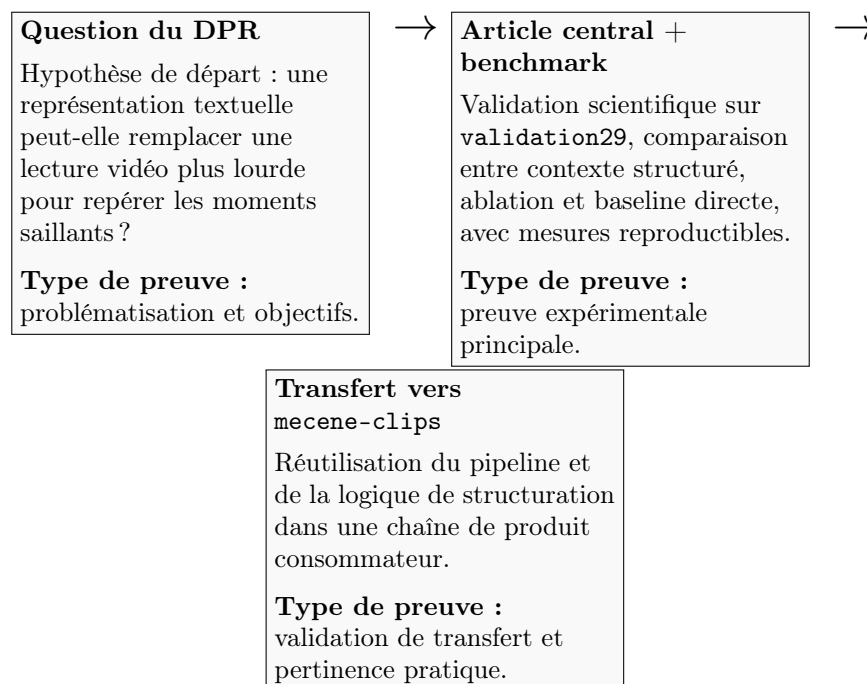


FIGURE 5.1 Positionnement respectif du DPR, de l'article central et du transfert vers l'application de production.

5.5 Limites et menaces a la validité

La première limite est la taille du jeu d'évaluation. Vingt-neuf paires suffisent pour faire ressortir des tendances nettes, mais pas pour couvrir toute la diversité des vidéos longues. La deuxième limite est le domaine lui-même. On reste proche du découpage de clips grand public, ce qui est cohérent avec l'application visée, mais ne couvre pas encore tous les cas plus difficiles que l'on pourrait trouver en robotique ou en perception embarquée.

Une autre limite importante vient de la forme actuelle du signal visuel textuel. L'ablation montre qu'il n'aide pas dans l'état présent du système. Cela ne veut pas dire qu'aucun signal visuel textuel ne pourra aider. Cela veut dire que cette manière précise de le produire et de l'injecter n'est pas encore la bonne.

Enfin, la campagne sur l'ajustement fin est très informative, mais elle reste une campagne complémentaire sur une base historique distincte. Elle renforce une lecture système du travail, sans changer la preuve principale, qui reste celle du jeu **validation29**.

5.6 Travaux futurs

La priorité la plus directe est de mieux choisir le signal visuel à transmettre. Le résultat actuel montre assez clairement que la solution n'est pas de mettre plus de descriptions. Il faut plutôt trouver quelles informations visuelles sont vraiment utiles à la décision finale.

Le deuxième axe est de mieux exploiter l'idée d'état persistant. Une fois la vidéo transformée en données textuelles structurées, on peut s'en servir pour autre chose que choisir un seul moment : annotation, recherche, révision, ou aide au montage. C'est là que l'amortissement du coût de préparation devient vraiment intéressant.

Le troisième axe est plus proche de la motivation initiale du projet. Il faudra tester cette même logique sur des données moins proches du découpage de clips et plus proches de la robotique, où le signal verbal est parfois faible et où l'information importante peut être davantage visuelle ou contextuelle. C'est à ce moment-là qu'on pourra vraiment mesurer jusqu'où l'approche texte d'abord reste valide.

CHAPITRE 6

Conclusion generale

La question de départ du mémoire était la suivante : est-ce qu’une vidéo longue peut être représentée sous forme textuelle de manière assez bonne pour qu’un modèle textuel puisse en extraire un moment saillant, tout en coûtant moins cher qu’une approche multimodale directe ? Les travaux réalisés permettent maintenant de répondre oui, mais avec une nuance importante sur le type de représentation qui aide vraiment.

6.1 Réponse à la question de recherche

La réponse générale est positive. Sur `validation29`, plusieurs conditions textuelles dépassent l’entrée vidéo directe. Cela veut dire qu’il n’est pas nécessaire, pour cette tâche, de garder toute l’analyse vidéo multimodale jusqu’au dernier moment. Une approche texte d’abord peut suffire.

La nuance importante est la suivante. Ce n’est pas simplement « plus la représentation est riche, mieux c’est ». Dans l’état actuel du système, la transcription brute est la meilleure condition contrôlée, la variante structurée sans descriptions visuelles suit de près, et la textualisation visuelle actuelle ne semble pas aider. Donc le vrai message n’est pas seulement qu’une représentation texte fonctionne. C’est qu’il faut bien choisir ce que l’on met dans cette représentation.

Il faut ajouter une deuxième nuance. La valeur de la représentation structurée ne se limite pas à son score brut. Elle tient aussi au fait qu’elle produit un état persistant de la vidéo, que l’on peut conserver, relire et réutiliser. C’est ce qui rend l’approche intéressante dans une logique système, surtout si la même vidéo doit ensuite servir à plusieurs traitements.

Enfin, la campagne complémentaire sur l’ajustement fin montre que le problème ne se résume pas à choisir entre texte et vidéo. Selon la taille du modèle, il peut être plus intelligent de déplacer une partie du calcul dans l’ajustement fin, ou au contraire de garder un modèle plus général et de lui fournir un meilleur contexte. `Flash-Lite` semble trop petit pour en tirer un vrai gain. `Flash` semble être au bon niveau de capacité. `Pro`, lui, profite surtout d’un contexte plus riche.

6.2 Contributions validées par le mémoire

Le mémoire valide d’abord une idée simple mais importante : une approche texte d’abord peut rester compétitive pour la sélection de moments saillants dans des vidéos longues. Il valide ensuite la chaîne qui permet d’arriver à ce résultat : transcription, structuration temporelle, enrichissement visuel contrôlé, stockage en base et comparaison reproductible.

Le mémoire valide aussi une contribution plus large que prévu au départ. En construisant cette représentation, le projet ne produit pas seulement un contexte pour un modèle. Il produit une base textuelle de la vidéo. Cela ouvre la porte à une logique de réutilisation que l'entrée vidéo directe ne permet pas aussi facilement.

Enfin, le travail valide une manière plus rigoureuse de suivre les itérations. Le jeu d'évaluation, la base SQLite, les vues de rapport et les tableaux générés permettent de distinguer proprement ce qui relève de l'exploration rapide, de la comparaison principale et du diagnostic plus fin. Cela compte, parce que la qualité de la représentation est justement le coeur scientifique du projet.

6.3 Perspectives

La suite la plus directe consiste à mieux choisir l'information visuelle à transmettre. Les résultats actuels montrent qu'ajouter du texte visuel ne suffit pas. Il faut plutôt trouver quelle information visuelle aide vraiment le modèle, et sous quelle forme.

La deuxième perspective consiste à exploiter davantage la représentation comme état persistant. Une fois qu'une vidéo a été transformée en structure textuelle, elle peut servir à plusieurs tâches, pas seulement à choisir un clip. C'est probablement là que la valeur pratique de l'approche deviendra la plus forte.

La troisième perspective est de revenir encore plus près de la motivation initiale du DPR. Il faudra tester cette logique sur des données plus proches de la robotique et des systèmes embarqués, où les contraintes de calcul sont encore plus fortes et où l'information utile n'est pas toujours principalement verbale. Si l'approche reste bonne dans ce contexte, alors le projet aura vraiment montré qu'une représentation textuelle peut devenir une alternative crédible à l'analyse vidéo directe dans des systèmes contraints.

LISTE DES RÉFÉRENCES

- [1] J. CHAE, D. KIM, K. KIM, D. LEE, S. LEE, S. HA, J. MUN, W. KANG, B. ROH et J. LEE : Towards a complete benchmark on video moment localization. *Dans Proceedings of the International Conference on Artificial Intelligence and Statistics*, volume 238, pages 4168–4176. Machine Learning Research, 2024.
- [2] G. CHEN, Y.-D. ZHENG, J. WANG, J. XU, Y. HUANG, J. PAN, Y. WANG, Y. WANG, Y. QIAO, T. LU et L. WANG : VideoLLM : Modeling video sequence with large language models. *arXiv preprint*, arXiv :2305.13292, 2023.
- [3] C. FAN, X. ZHU, W. LI, C. FANG, G. LIN, R. YANG et D. THALMANN : Heterogeneous memory enhanced multimodal attention model for video question answering. *Dans Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 1999–2007, 2019.
- [4] S. GHOSH, A. AGARWAL, Z. PAREKH et A. HAUPTMANN : Excl : Extractive clip localization using natural language descriptions. *Dans Proceedings of the Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies, Volume 1*, pages 1984–1990. Association for Computational Linguistics, 2019.
- [5] Y. GUO, J. LIU, M. LI, X. TANG, X. CHEN et B. ZHAO : Vtg-LLM : Integrating timestamp knowledge into video LLMs for enhanced video temporal grounding. *arXiv preprint arXiv :2405.13382*, 2024.
- [6] D. HAN, S. SEO, E. PARK, S.-U. NAM et N. KWAK : Unleash the potential of clip for video highlight detection. *arXiv preprint arXiv :2404.01745*, 2024.
- [7] Y. HE, Z. WANG, Z. SHEN, G. SUN, Y. DAI, Y. WU, H. WANG et A. LI : Shed : Shapley-based automated dataset refinement for instruction fine-tuning. *Dans Advances in Neural Information Processing Systems*, 2024.
- [8] L. A. HENDRICKS, O. WANG, E. SHECHTMAN, J. SIVIC, T. DARRELL et B. RUSSELL : Localizing moments in video with natural language. *Dans Proceedings of the IEEE International Conference on Computer Vision*, pages 5804–5813, 2017.
- [9] B. HUANG, X. WANG, H. CHEN, Z. SONG et W. ZHU : VtimeLLM : Empower LLM to grasp video moments. *Dans Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14271–14280, 2024.
- [10] M. Bansal J. LEI, T. L. Berg : Qvhighlights : Detecting moments and highlights in videos via natural language queries. *Dans Proceedings of the International Conference on Neural Information Processing Systems*, pages 11846–11858. Neural Information Processing Systems, 2021.
- [11] J. LEI, L. LI, L. ZHOU, Z. GAN, T. L. BERG, M. BANSAL et J. LIU : Less is more : CLIPBERT for video-and-language learning via sparse sampling. *Dans Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 7327–7337, 2021.
- [12] H. LI, L. DING, M. FANG et D. TAO : Revisiting catastrophic forgetting in large language model tuning. *Dans Findings of the Association for Computational Linguistics : EMNLP 2024*, pages 4297–4308. Association for Computational Linguistics, 2024.
- [13] Y. LI, X. CHEN, B. HU et M. ZHANG : LLMs meet long video : Advancing long video question answering with an interactive visual adapter in LLMs. *arXiv preprint*, arXiv :2402.13546, 2024.

-
- [14] W. LIANG, L. YU, L. LUO, S. IYER, N. DONG, C. ZHOU, G. GHOSH, M. LEWIS, W. t. YIH, L. ZETTLEMOYER et X. V. LIN : Mixture-of-transformers : A sparse and scalable architecture for multi-modal foundation models. *Transactions on Machine Learning Research*, 2025.
 - [15] N. F. LIU, K. LIN, J. HEWITT, A. PARANJPE, M. BEVILACQUA, F. PETRONI et P. LIANG : Lost in the middle : How language models use long contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173, 2024.
 - [16] Y. LIU, S. LI, Y. WU, C. W. CHEN, Y. SHAN et X. QIE : Umt : Unified multi-modal transformers for joint video moment retrieval and highlight detection. *Dans Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 3032–3041, 2022.
 - [17] M.-A. MAHEUX, C. CAYA, D. LÉTOURNEAU et F. MICHAUD : T-top, a sar experimental platform. *Dans Proceedings of the 2022 ACM/IEEE International Conference on Human-Robot Interaction*, pages 904–908, 2022.
 - [18] A. RADFORD, J. KIM, T. XU, G. BROCKMAN, C. MCLEAVEY et I. SUTSKEVER : Whisper : Robust speech recognition via large-scale weak supervision. *Dans Proceedings of the International Conference on Machine Learning*, pages 28492–28518, 2023.
 - [19] Y. SUN, Y. XU, Z. XIE, Y. SHU et S. DU : Gptsee : Enhancing moment retrieval and highlight detection via description-based similarity features. *Dans Proceedings of the IEEE Signal Processing Letters*, pages 521–525, 2024.
 - [20] Y. TANG, J. BI, S. XU, L. SONG, S. LIANG, T. WANG, D. ZHANG, J. AN, J. LIN, R. ZHU, A. VOSOUGHI, C. HUANG, Z. ZHANG, F. ZHENG, J. ZHANG, P. LUO, J. LUO et C. XU : Video understanding with large language models : A survey. *arXiv preprint*, arXiv :2312.17432, 2023.
 - [21] S. N. WADEKAR, A. CHAURASIA, A. CHADHA et E. CULURCIELLO : The evolution of multimodal model architectures. *arXiv preprint arXiv :2405.17927*, 2024.
 - [22] B. WANG, Y. LI, Z. LV, H. XIA, Y. XU et R. SODHI : Lave : LLM-powered agent assistance and language augmentation for video editing. *Dans Proceedings of the International Conference on Intelligent User Interfaces*, pages 699–714. Association for Computing Machinery, 2024.
 - [23] Y. WENG, M. HAN, H. HE, X. CHANG et B. ZHUANG : Longvlm : Efficient long video understanding via large language models. *Dans Proceedings of the European Conference on Computer Vision*, 2024.
 - [24] J. XU, C. LAN, W. XIE, X. CHEN et Y. LU : Retrieval-based video language model for efficient long video question answering. *arXiv preprint*, arXiv :2312.04931, 2023.
 - [25] J. XU, C. LAN, W. XIE, X. CHEN et Y. LU : Slot-vlm : Slowfast slots for video-language modeling. *arXiv preprint arXiv :2402.13088*, 2024.
 - [26] H. ZHANG, X. LI et L. BING : Video-llama : An instruction-tuned audio-visual language model for video understanding. *Dans Proceedings of the Conference on Empirical Methods in Natural Language Processing : System Demonstrations*, pages 543–553. Association for Computational Linguistics, 2023.
 - [27] P. ZHOU, L. WANG, Z. LIU, Y. HAO, P. HUI, S. TARKOMA et J. KANGASHARJU : A survey on generative ai and LLM for video generation, understanding, and streaming. *arXiv preprint*, arXiv :2404.16038, 2024.
-